

머신러닝을 위한 선형대수학

11 편미분 기초

목차 11 편미분 기초


1. 다변수 함수
2. 편미분과 전미분
3. 테일러 급수(Taylor Series)
4. 컨벡스 함수(Convex function)
5. 제약 조건이 없는 최적화 (Unconstrained Optimization)
6. 라그랑주 승수법(Lagrange multiplier method)

1. 다변수 함수



11.1 다변수 함수 $f : R^n \rightarrow R^m$

(1) $f : R \rightarrow R$




$$f(x) = x^2$$

$$f(x) = x^3$$

$$f(x) = \ln x^2, \quad x \neq 0$$



(2) $f : R^2 \rightarrow R$




$$f(x, y) = x^2 + y^2$$

$$f(x, y) = x \cos y$$

$$f(x, y) = \sqrt{x^2 + y^2}$$




(3) $f : R^3 \rightarrow R$



$$f : R^n \rightarrow R : (x_1, x_2, \dots, x_n) \rightarrow f(x_1, x_2, \dots, x_n)$$



(4) $f : \mathbb{R} \rightarrow \mathbb{R}^2$




$$f(x) = (x, x^2)$$

$$f(x) = (\cos x, \sin x)$$

$$f(x) = (f_1(x), f_2(x))$$



(5) $f : \mathbb{R} \rightarrow \mathbb{R}^3$




$$\begin{aligned} f(t) &= (t, t^2, t^3) \\ &= (f_1(t), f_2(t), f_3(t)) \end{aligned}$$

$$f : \mathbb{R} \rightarrow \mathbb{R}^m : t \rightarrow (f_1(t), f_2(t), \dots, f_m(t))$$



$$f : R^n \rightarrow R^m$$

$$(1) f : R^2 \rightarrow R^3$$



$$f(x, y) = (x, y, x^2 + y^2)$$

$$f(x, y) = (xy, y, \sqrt{x^2 + y^2})$$



$$\begin{pmatrix} a & b \\ c & d \\ e & f \end{pmatrix} : R^2 \rightarrow R^3 : \begin{pmatrix} x \\ y \end{pmatrix} \rightarrow \begin{pmatrix} a & b \\ c & d \\ e & f \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} ax + by \\ cx + dy \\ ex + fy \end{pmatrix}$$

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : R^2 \rightarrow R^2 : \begin{pmatrix} x \\ y \end{pmatrix} \rightarrow \begin{pmatrix} a & b \\ c & d \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} ax + by \\ cx + dy \end{pmatrix}$$

$$\begin{pmatrix} a & b & c \\ d & e & f \\ g & h & k \end{pmatrix} : R^3 \rightarrow R : (x \ y \ z) \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & k \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = (x \ y \ z) \begin{pmatrix} ax + by + cz \\ dx + ey + fz \\ gx + hy + kz \end{pmatrix}$$

$$= x(ax + by + cz) + y(dx + ey + fz) + z(gx + hy + kz)$$



다변수 함수 정리

$$R^2 \rightarrow R^3: \quad f(x, y) = (f_1(x, y), f_2(x, y), f_3(x, y))$$

$$R^2 \rightarrow R^4: \quad f(x, y) = (f_1(x, y), f_2(x, y), f_3(x, y), f_4(x, y))$$

$$R^3 \rightarrow R^4: \quad f(x, y, z) = (f_1(x, y, z), f_2(x, y, z), f_3(x, y, z), f_4(x, y, z))$$

$\vdots$

$$f : R^n \rightarrow R^m:$$

$$f(x_1, x_2, \dots, x_n) = (f_1(x_1, x_2, \dots, x_n), f_2(x_1, x_2, \dots, x_n), \dots, f_m(x_1, x_2, \dots, x_n))$$



11.1 다변수 함수(Multi Variable Functions)의 정의: $f : R^n \rightarrow R^m$

지금까지 우리는 정의역 공역이 모두 실수의 부분집합인 함수들 만 다루어 왔다. 즉, 변수가 한 개인 함수 만 공부 했다. 변수가 여러 개인 함수들도 당연히 존재한다. 그리고 최적화 이론에서는 많은 변수를 가지는 함수들의 최솟값이 되게 하는 최소자를 구하는 게 핵심 주제이다. 지금부터 하나씩 공부해 보자.

평면에서 실수로 가는 함수, 공간에서 실수로 가는 함수들도 자연스럽게 생각해 볼 수 있다. 평면이란 단순히 변수가 2개인 경우 (x, y) 이고 공간이란 변수가 (x, y, z) 을 의미한다. 함수란 정의역의 원소를 공역의 하나의 원소에 대응만 되면 된다.



11.1-1. 이변수 함수(function of two variables) $f : R^2 \rightarrow R : (x, y) \mapsto f(x, y)$

변수가 2 개이므로 이변수 함수(function of two variables)라고 부른다. 예를 들어보면 아래와 같다.

예제 1: (1) $f(x, y) = x^2 + y^2$ 이는 $\mathbf{x} = (x, y)$ 로 표시하면 $f(\mathbf{x}) = \|\mathbf{x}\|^2 = x^2 + y^2$ 로 표현되기도 한다. 함수 $g(x, y) = g(\mathbf{x}) = \|\mathbf{x}\| = \sqrt{x^2 + y^2}$ 는 평면의 점들을 원점에서 그 점까지의 거리를 계산하는 이변수 함수이다.

(2) $f(x, y) = (x \ y) \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} + (1 \ 2) \begin{pmatrix} x \\ y \end{pmatrix} + 3$ 인 모양의 함수도 종종 볼수 있다.

보통 이러한 함수를 2차 형식(quadratic form)이라 부른다.

행렬 계산 (이론3 참고)에 의해서 $(x \ y) \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 2x^2 + 3y^2 + 2xy,$

$(1 \ 2) \begin{pmatrix} x \\ y \end{pmatrix} = x + 2y$ 이다. 따라서 $f(x, y) = 2x^2 + 3y^2 + 2xy + x + 2y + 3$ 이다.



정의역을 $y = mx$ 인 직선식으로 제한하면

$$\begin{aligned} f(x, mx) &= 2x^2 + 3(mx)^2 + 2x(mx) + x + 2(mx) + 3 \\ &= (3m^2 + 2m + 2)x^2 + (2m + 1)x + 3 \text{이다.} \end{aligned}$$

2차 함수의 형태를 가지고 있다.



예제1의 (1)에서 함수 f 는 정의역을 R^2 에서 단위원 $D = \{(x, y) \mid x^2 + y^2 \leq 1\}$

(원 점이 중심이고 반지름이 1 원)의 내부로 제한해도

$f : D \rightarrow R : (x, y) \mapsto f(x, y) = x^2 + y^2$ 여전히 이변수 함수이다. 하지만 강제로 정의역

의 영역을 제한해야 하는 경우도 있다. $f(x, y) = \frac{\sqrt{x+y+1}}{x-1}$ 라고 하면, $(1, y)$ 인 점의

함숫값은 정의 되지 않으므로 정의역은 제한된다. 즉,

$D = \{(x, y) \mid x + y + 1 \geq 0, x \neq 1\}$ 인 경우로 제한된다.

$f(x, y) = x \ln(y^2 - x)$ 인 경우도 $\ln(y^2 - x)$ 는 $y^2 - x > 0$ 일 때 정의되므로 f 의 정의역은 $D = \{(x, y) \mid x < y^2\}$ 이다. 이런 사실을 종합하면 이변수 함수는 아래와 같이 정의된다.



11.1-2 정의: 이변수 함수(function of two variables) f 는 집합 $D (D \subset \mathbb{R}^2)$ 의 실수의 각 순서쌍 (x, y) 에 단 하나의 실수를 대응시키는 규칙으로 $f(x, y)$ 와 같이 나타낸다. 집합 D 는 f 의 정의역(domain)이고 치역(range)은 f 가 취하는 실수값들의 집합이다. $f : D \rightarrow \mathbb{R}$ 이고 치역은 $\{f(x, y) \mid (x, y) \in D\}$ 이다.

일반적인 점 (x, y) 에서 f 에 의해 정해진 값을 명확히 표시하기 위해 종종 $z = f(x, y)$ 로 쓰기도 한다. 변수 x 와 y 는 독립변수라 부르고 z 는 x, y 에 따라 결정되므로 종속변수라 부른다.



11.1-3 삼변수 함수(function of three variables)

$$f : R^3 \rightarrow R : (x, y, z) \mapsto f(x, y, z)$$

변수가 3 개 이므로 삼변 수 함수(function of three variables)라고 부른다.

예제 2: (1) 이변수 함수와 유사하게 3개의 변수에 대해서 정의된 함수 들이다.

$f(x, y, z) = x^2 + y^2 + z^2$ 이는 $\mathbf{x} = (x, y, z)$ 로 표시하면

$f(\mathbf{x}) = \|\mathbf{x}\|^2 = x^2 + y^2 + z^2$ 로 표현 되기도 한다.

$g(x, y, z) = g(\mathbf{x}) = \|\mathbf{x}\| = \sqrt{x^2 + y^2 + z^2}$ 는 공간의 한 점에서 원점
까지의 거리를 계산하는 이변수 함수이다.

(2) 이변수와 같이 삼변수에서도 **2차 형식(quadratic form)함수**가 정의된다.

$$f(x, y, z) = (x \ y \ z) \begin{pmatrix} 2 & 0 & 1 \\ 0 & 3 & -1 \\ 1 & -1 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} + (1 \ 2 \ -1) \begin{pmatrix} x \\ y \\ z \end{pmatrix} + 5$$

$$= 2x^2 + 3y^2 + z^2 + 2xz - 2yz + x + 2y - z + 5$$

정의역을 원점을 지나는 직선 $(a, b, c)t, t \in R$ 으로 제한하면

$f(at, bt, ct)$ 는 t 에 대한 2차 함수이다.



11.1-4 n 변수함수 (function of n variables)

$$f : R^n \rightarrow R : (x_1, x_2, \dots, x_n) \mapsto f(x_1, x_2, \dots, x_n)$$

n 변수함수 (function of n variables)는 n 개의 실수 순서쌍 $(x_1, x_2, \dots, x_n)$ 이 한 실수 값 $z = f(x_1, x_2, \dots, x_n)$ 에 대응하는 규칙이다. 이러한 n 개의 순서쌍 전체의 집합을 R^n 으로 표시한다. $R^n = \{(x_1, x_2, \dots, x_n) \mid x_i \in R, i = 1, 2, \dots, n\}$ 이고 이때 함수 $f : R^n \rightarrow R$ 로 표시한다. 앞서와 같이 정의역을 $D \subset R^n$ 로 제한 해서 생각해도 된다.

예제3: 다음은 n 변수함수들 이다.

$$f(x_1, x_2, \dots, x_n) = x_1^2 + x_2^2 + \dots + x_n^2,$$

$$g(x_1, x_2, \dots, x_n) = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2},$$

A 을 $n \times n$ 행렬이라고 하자. $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$, $\mathbf{b} = (b_1, b_2, \dots, b_n)^\top$ 라 하면, n 변수 이차형식 함수는 다음과 같이 정의된다.

$$f(\mathbf{x}) = \mathbf{x}^\top A \mathbf{x} + \mathbf{b}^\top \mathbf{x} + c.$$

보통 A 가 $A^\top = A$ 인 대칭행렬인 경우가 주로 등장 한다.



11.1-5 매개변수로 불리는 함수

앞에서는 정의역의 차원을 실수에서 평면, 공간, 다변수로 늘이는 함수들을 생각해 봤다. 이번에는 반대로 정의역을 실수로 하고 공역을 평면, 공간으로 확장하는 함수들의 모양을 살펴보자. 이들 함수들의 보통 매개변수 함수라 부른다.

예제 4: $f: R \rightarrow R^2 : t \mapsto (f_1(t), f_2(t))$

이 경우는 보통 정의역 원소를 x 로 표시 하는 것 보다 많은 책에서 t 로 표시한다. 공역이 평면, (x, y) 이니 두 개의 함수 $f_1(t), f_2(t)$ 가 필요하다. 가장 쉬운 예는 $f(t) = (t, t)$, 또는 $g(t) = (\cos t, \sin t)$ 이다. 사실 어렵지 않게 $f: R \rightarrow R^3 : t \mapsto (f_1(t), f_2(t), f_3(t))$ 의 함수들도 생각해 볼 수 있다.

$f(t) = (t, t^2, t^3)$, $g(t) = (t, \cos t, \sin t)$. 이 경우도 공역의 변수를 n 개로 확장 할 수 있다 $f: R \rightarrow R^n : t \mapsto (f_1(t), f_2(t), \dots, f_n(t))$. 여기서 $f_i(t)$ 을 성분함수라 하는데 성분함수는 실수에서 실수로의 함수이다.



11.1-6 일반적인 다변수 함수

마지막으로 살펴볼 예는 $f: R^2 \rightarrow R^2$, $f: R^3 \rightarrow R^2$, $f: R^2 \rightarrow R^3$ 스타일의 함수이다.

먼저 $f: R^2 \rightarrow R^2$ 형태의 함수를 보면, 이는 평면의 2개의 변수를 받아서 다시 2개의 평면 좌표에 대응하는 함수이다. 가장 쉬운 예는 평행이동이다. $f(x, y) = (x + 2, y + 2)$. 하지만 다른 예도 얼마든지 있다.

$$f(x, y) = (x^2 - y^2, 2xy), f(x, y) = (xy^2, x \ln y), \dots$$

이들 함수의 특징은 두 변수 (x, y) 을 받아 X 좌표와 Y 좌표의 값을 주는 것이다. $f(x, y) = (x^2 - y^2, 2xy)$ 인 경우 $f_1(x, y) = x^2 - y^2$, $f_2(x, y) = 2xy$ 라 하면, $f_1(x, y) = x^2 - y^2$ 는 평면의 원소를 X 좌표로 보내는 함수이고 $f_2(x, y) = 2xy$ 의 함수는 평면의 원소를 Y 좌표로 보내는 함수이다.

따라서 $f: R^2 \rightarrow R^2$ 의 함수는 $f(x, y) = (f_1(x, y), f_2(x, y))$ 의 형태로 표시된다.

$x = (x, y)$ 라 하면 $f(x) = (f_1(x), f_2(x))$ 라 표시한다.



11.1-7 정의: 다변수 함수(Multi Variable function)

앞의 예제를 통해서 본 것처럼 다음과 같이 일반적인 다변수 함수를 정의할 수 있다:

$n, m \in \mathbb{N}$ 에 대하여

$$f : \mathbb{R}^n \rightarrow \mathbb{R}^m : (x_1, x_2, \dots, x_n) \mapsto$$

$$f(x_1, x_2, \dots, x_n) = (f_1(x_1, x_2, \dots, x_n), f_2(x_1, x_2, \dots, x_n), \dots, f_m(x_1, x_2, \dots, x_n)).$$


(단, $f_i : \mathbb{R}^n \rightarrow \mathbb{R}, i = 1, \dots, m$.)

$\mathbf{x} = (x_1, x_2, \dots, x_n)$ 라 하면 $f(\mathbf{x}) = (f_1(\mathbf{x}), f_2(\mathbf{x}), \dots, f_m(\mathbf{x}))$




11.1-8 함수의 그래프


함수의 그래프를 그릴 수 있는 경우는 함수의 종류가 $f : R \rightarrow R$ 또는 $f : R^2 \rightarrow R$ 인 경우이다. $f : R \rightarrow R$ 인 경우는 평면에 그래프를 그리는 방법으로 많이 공부해왔다. $f : R^2 \rightarrow R$ 은 공간에 그래프를 그리게 된다. (x, y) 의 값을 받아서 이것의 높이 값 $z = f(x, y)$ 을 그려주는 것이다.




[$f(x, y) = x^2 + y^2$ 의 그래프]



[$f(x, y) = \sqrt{x^2 + y^2}$ 의 그래프]



$$[f(x, y) = (x \ y) \begin{pmatrix} 2 & 1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} + (1 \ 2) \begin{pmatrix} x \\ y \end{pmatrix} + 3]$$




$$[f(x, y) = \frac{7xy}{e^{x^2 + y^2}}]$$

2. 편미분과 전미분



11.2-3 정의[편미분(partial derivative)]:

편미분의 정의는 $f : R^n \rightarrow R$ 인 함수에서만 정의된다. 즉, 공역이 실수 R 인 경우이다. 먼저 $f : R^2 \rightarrow R$ 에서 편미분의 정의를 이해하고, 이를 바탕으로 쉽게 $f : R^n \rightarrow R$ 으로 확장하면 된다.




점 $(a, b) \in R^2$ 에서 (a, b) 을 지나고 X 축에 평행한 직선은 (x, b) , $x \in R$ 로 표현하자. 이때, $g_b(x) = f(x, b)$ 하면 $g_b : R \rightarrow R$ 의 함수가 된다. g_b 함수의 $x = a$ 에서 미분의 정의를 생각하면

$$g_b'(a) = \lim_{h \rightarrow 0} \frac{g_b(a+h) - g_b(a)}{h} = \lim_{h \rightarrow 0} \frac{f(a+h, b) - f(a, b)}{h}$$

이다. $g_b'(a)$ 값이 존재하면 함수 $f(x, y)$ 의 점 $(a, b) \in R^2$ 의 x 에 관한 편미분이 가능하다고 정의한다.



아래 그림은 (a,b) 을 지나고 $\langle XOZ \rangle$ 에 평행한 평면으로 곡면을 자른 단면을 x 축 방향으로 미분한 것이다.



이때, 기호표시는

$$\frac{\partial f(a,b)}{\partial x}, f_x(a,b), z_x(a,b)$$

등으로 나타낸다.



같은 생각으로 $g_a(y) = f(a, y)$ 에서 $y = b$ 에서의 미분을 생각할 수 있다.

$$g_a'(b) = \lim_{h \rightarrow 0} \frac{g_a(b+h) - g_a(b)}{h} = \lim_{h \rightarrow 0} \frac{f(a, b+h) - f(a, b)}{h}$$

$g_a'(b)$ 값이 존재하면, 함수 $f(x, y)$ 의 점 $(a, b) \in R^2$ 의 y 에 관한 편미분이 가능 하다고 정의한다. 기호로는

$$\frac{\partial f(a, b)}{\partial y}, f_y(a, b), z_y(a, b)$$

등으로 나타낸다.

$f(x, y)$ 에서 편미분은 X 축 또는 Y 축 방향의 미분이라 할 수 있다. $f_x(x, y)$ 는 X 축 방향미분을 의미하고 이때 y 를 상수로 보고 미분하면 된다. 마찬가지로 $f_y(x, y)$ 는 Y 축 방향미분을 의미하고 x 를 상수로 보고 미분하면 된다.



예제1: $f(x, y) = x^3 + x^2y^3 - 2y^2$ 일 때, $f_x(2, 1)$, $f_y(2, 1)$ 을 구하여라.

[풀이] y 를 상수로 간주하고 x 에 관해 미분하면

$$f_x(x, y) = 3x^2 + 2xy^3 \text{이고}$$

$$f_x(2, 1) = 3 \cdot 2^2 + 2 \cdot 2 \cdot 1^3 = 16$$

x 를 상수로 간주하고 y 에 관해 미분하면

$$f_y(x, y) = 3x^2y^2 - 4y \text{이고}$$

$$f_y(2, 1) = 3 \cdot 2^2 \cdot 1^2 - 4 \cdot 1 = 8$$

예제2 : $f(x, y) = x^2 \sin(xy^2)$ 에 대하여 $\frac{\partial f(x, y)}{\partial x}$, $\frac{\partial f(x, y)}{\partial y}$ 을 구하라.

[풀이] $\frac{\partial f(x, y)}{\partial x} = 2x \sin(xy^2) + x^2 \cos(xy^2)y^2 = 2x \sin(xy^2) + x^2y^2 \cos(xy^2)$

$$\frac{\partial f(x, y)}{\partial y} = x^2 \cos(xy^2)2xy = 2x^3y \cos(xy^2)$$



예제3: $f(x, y) = \sin\left(\frac{x}{1+y}\right)$ 일 때 $\frac{\partial f}{\partial x}$ 와 $\frac{\partial f}{\partial y}$ 를 계산하여라.

[풀이]
$$\frac{\partial f}{\partial x} = \cos\left(\frac{x}{1+y}\right) \cdot \frac{\partial}{\partial x}\left(\frac{x}{1+y}\right) = \cos\left(\frac{x}{1+y}\right) \cdot \frac{1}{1+y}$$

$$\frac{\partial f}{\partial y} = \cos\left(\frac{x}{1+y}\right) \cdot \frac{\partial}{\partial y}\left(\frac{x}{1+y}\right) = -\cos\left(\frac{x}{1+y}\right) \cdot \frac{x}{(1+y)^2}$$



12.2-4 이변수 이상의 함수의 편미분

편미분은 셋 또는 그 이상의 변수에 대한 함수에서도 정의된다. 예를 들어 f 가 x, y, z 의 삼변수함수이면 x, y, z 에 대한 편미분은

$$f_x(x, y, z) = \lim_{h \rightarrow 0} \frac{f(x+h, y, z) - f(x, y, z)}{h},$$

$$f_y(x, y, z) = \lim_{h \rightarrow 0} \frac{f(x, y+h, z) - f(x, y, z)}{h},$$

$$f_z(x, y, z) = \lim_{h \rightarrow 0} \frac{f(x, y, z+h) - f(x, y, z)}{h}$$

로 정의된다. $f_x(x, y, z)$ 는 y, z 는 상수로 간주하고 x 만 변수로 생각하고 미분한다.

$f_y(x, y, z)$, $f_z(x, y, z)$ 는 각각 y 와 z 만을 변수로 생각하고 하는 미분이다.



예제4: $f(x, y, z) = e^{xy} \ln z$ 일 때, f_x, f_y, f_z 를 구하여라.

[풀이] y, z 는 상수로 간주하고 x 만 변수로 생각하고 미분하면

$f_x = ye^{xy} \ln z$ 이다. 마찬가지로 $f_y = xe^{xy} \ln z, f_z = \frac{e^{xy}}{z}$ 이다.

편미분이란 곡면을 절단하여 X 축 방향 또는 Y 축 방향과 같이 한 방향 만 변수로 생각하고 미분하는 것이다.

만약 $f : R^3 \rightarrow R$ 이면 곡면을 절단하여 X 축 방향, Y 축 방향, Z 축 방향으로 미분하는 것을 의미한다.



일반적으로 n 변수함수 $f(x_1, x_2, \dots, x_n)$ 에서 i 번째 변수 x_i 에 관한 편미분

$$\frac{\partial f}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{i-1}, x_i + h, x_{i+1}, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h} \dots \textcircled{1}$$

이다.

$f: R^n \rightarrow R$ 인 경우는 $X, Y, Z, \dots$ 방향을 표시하기 위해서 $e_1 = (1, \dots, 0), e_2 = (0, 1, \dots, 0), \dots, e_n = (0, \dots, 0, 1)$ 벡터를 사용하면 $\textcircled{1}$ 식을 간단히 표현 할 수 있다.

$x = (x_1, x_2, \dots, x_n), e_i = (0, \dots, 0, 1, 0, \dots, 0)$ 라 하면

$$\begin{aligned} & (x_1, \dots, x_{i-1}, x_i + h, x_{i+1}, \dots, x_n) \\ &= (x_1, \dots, x_{i-1}, x_i, x_{i+1}, \dots, x_n) + h(0, \dots, 0, 1, 0, \dots, 0) \\ &= x + h e_i \end{aligned}$$

이다. 따라서 $\textcircled{1}$ 식은

$$\frac{\partial f}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x + h e_i) - f(x)}{h}$$

이다.



11.2-5 정의[편미분(partial derivative)]:

$e_1 = (1, \dots, 0), e_2 = (0, 1, \dots, 0), \dots, e_n = (0, \dots, 0, 1)$ 은 R^n 의 표준기저다. 함수 $f : R^n \rightarrow R$ 에 대하여 주어진 점 $x_0 \in R^n$ 의 편미분(방향이 e_i 인 방향미분)은 다음과 같이 정의된다.

$$\frac{\partial f}{\partial x_i}(x_0) = \lim_{h \rightarrow 0} \frac{f(x_0 + h e_i) - f(x_0)}{h}.$$

위의 극한값이 존재할 때, 함수 $f : R^n \rightarrow R$ 는 주어진 점 $x_0 \in R^n$ 에서 편미분 가능이라고 부른다.



11.2-6 기호약속 및 고계 편미분: f_x 을 다시 x 또는 y 로 다시 편미분이 가능하고 이때 기

호로는 $(f_x)_x = f_{xx}$, $(f_x)_y = f_{xy}$ 으로 표시한다.

$$f_x(x, y) = \frac{\partial f(x, y)}{\partial x}, \quad f_y(x, y) = \frac{\partial f(x, y)}{\partial y},$$

$$f_x(x_0, y_0) = \frac{\partial f(x, y)}{\partial x} \Big|_{(x_0, y_0)}, \quad f_y(x_0, y_0) = \frac{\partial f(x, y)}{\partial y} \Big|_{(x_0, y_0)}.$$

$$f_{xx} = \frac{\partial}{\partial x} \left(\frac{\partial f}{\partial x} \right) = \frac{\partial^2 f}{\partial x^2}, \quad f_{yy} = \frac{\partial}{\partial y} \left(\frac{\partial f}{\partial y} \right) = \frac{\partial^2 f}{\partial y^2}$$

$$f_{xy} = (f_x)_y = \frac{\partial}{\partial y} \left(\frac{\partial f}{\partial x} \right) = \frac{\partial^2 f}{\partial y \partial x}, \quad f_{yx} = (f_y)_x = \frac{\partial}{\partial x} \left(\frac{\partial f}{\partial y} \right) = \frac{\partial^2 f}{\partial x \partial y}$$

예제5: $f(x, y) = x^3 + x^2y^3 - 2y^2$ 의 2계 편도함수를 구하여라.

[풀이] $f_x(x, y) = 3x^2 + 2xy^3$, $f_y(x, y) = 3x^2y^2 - 4y$ 이고

$$f_{xx} = \frac{\partial}{\partial x} (3x^2 + 2xy^3) = 6x + 2y^3, \quad f_{xy} = \frac{\partial}{\partial y} (3x^2 + 2xy^3) = 6xy^2$$

$$f_{yx} = \frac{\partial}{\partial x} (3x^2y^2 - 4y) = 6xy^2, \quad f_{yy} = \frac{\partial}{\partial y} (3x^2y^2 - 4y) = 6x^2y - 4$$



편미분은 어떤 점에서 $X, Y, Z, \dots$ 축 방향의 미분 만 생각 하였다. 좀 더 일반적으로 하나의 방향을 정해서 미분을 정의할 수도 있다. 이를 방향미분(directional derivative)이라고 한다.

11.2-8 정의[방향미분]: 함수 $f : R^n \rightarrow R$ 와 $x_0 \in R^n, u \in R^n$ 에 대하여 다음 극한 값이

$$f'(x_0, u) = \lim_{t \rightarrow 0} \frac{f(x_0 + t \cdot u) - f(x_0)}{t}$$

이 존재할 때 $f'(x_0, u)$ 을 x_0 에서의 u 방향으로의 미분 값 이라고 한다.

예제7: 함수 $f(x, y) = x^2 + y^2$ 의 한 점 $(1, 1)$ 에서 방향이 $u = (1, 1)$ 인 방향 미분값을 구하라.

[풀이] $f'((1, 1), (1, 1)) = \lim_{t \rightarrow 0} \frac{f((1, 1) + t(1, 1)) - f(1, 1)}{t}$

$$= \lim_{t \rightarrow 0} \frac{f(1+t, 1+t) - f(1, 1)}{t}$$

$$= \lim_{t \rightarrow 0} \frac{(1+t)^2 + (1+t)^2 - 2}{t} = 4$$



11.2-9 정의[전미분]: 함수 $f : R^n \rightarrow R^m$ 에 대하여, 주어진 점 $x_0 \in R^n$ 에 대하여 하나의 선형변환 $A : R^n \rightarrow R^m$ 이($A: m \times n$ 행렬) 존재해서 다음 조건을 만족할 때, 함수 $f : R^n \rightarrow R^m$ 는 $x_0 \in R^n$ 에서 전미분(total derivative)가능이라고 한다.

$$\lim_{h \rightarrow 0} \frac{\|f(x_0 + h) - f(x_0) - Ah\|}{\|h\|} = 0, \quad h \in R^n.$$

이때 미분값을 $f'(x_0) = A$ 로 표시한다. 위 극한값 식은 다음과 같이 쓰기도 하는데 아래 식은 어떤 사실을 유도할 때 요긴하게 쓰인다.

$$f(x_0 + h) - f(x_0) = f'(x_0)h + r(h), \quad \lim_{h \rightarrow 0} \frac{\|r(h)\|}{\|h\|} = 0$$



예제8: 함수 $f(x, y) = (x^2 + 3y, 2x - 3y, x + y^2)$ 에서 $x_0 = (1, 2)$ 라 하자. 이때, $f(x_0 + h) - f(x_0) = f'(x_0)h + r(h)$ 의 식을 구해보자.

[풀이] $h = (h_1, h_2)$ 라 놓으면 $f(x_0) = f(1, 2) = (7, -4, 5)$

$$x_0 + h = (1, 2) + (h_1, h_2) = (1 + h_1, 2 + h_2)$$

$$\begin{aligned} f(x_0 + h) &= f(1 + h_1, 2 + h_2) \\ &= ((1 + h_1)^2 + 3(1 + h_2), 2(1 + h_1) - 3(1 + h_2), 1 + h_1 + (1 + h_2)^2) \end{aligned}$$

$$\begin{aligned} f(x_0 + h) - f(x_0) &= (2h_1 + h_1^2 + 3h_2, 2h_1 - 3h_2, h_1 + 4h_2 + h_2^2)^\top \\ &= (2h_1 + 3h_2, 2h_1 - 3h_2, h_1 + 4h_2)^\top + (h_1^2, 0, h_2^2)^\top \\ &= \begin{pmatrix} 2 & 3 \\ 2 & -3 \\ 1 & 4 \end{pmatrix} \begin{pmatrix} h_1 \\ h_2 \end{pmatrix} + (h_1^2, 0, h_2^2)^\top \\ &= f'(x_0)h + r(h) \end{aligned}$$

위 식에서 $f'(x_0) = f'(1, 2) = \begin{pmatrix} 2 & 3 \\ 2 & -3 \\ 1 & 4 \end{pmatrix}$, $r(h) = (h_1^2, 0, h_2^2)^\top$ 이고

$$\lim_{h \rightarrow 0} \frac{\|r(h)\|}{\|h\|} = \lim_{(h_1, h_2) \rightarrow (0, 0)} \frac{\sqrt{h_1^4 + h_2^4}}{\sqrt{h_1^2 + h_2^2}} = 0 \text{ 이다.}$$



예제9: 함수 $f(x, y) = (x^2 + 3y, 2x - 3y, x + y^2)$ 에서 $x_0 = (x, y)$ 라 하자. 이때, $f(x_0 + h) - f(x_0) = f'(x_0)h + r(h)$ 의식을 구해보자. 즉, 임의의 점 (x, y) 에서 $f'(x, y)$ 을 구해보자.

[풀이] $x_0 + h = (x, y) + (h_1, h_2) = (x + h_1, y + h_2)$

$$f(x_0) = f(x, y) = (x^2 + 3y, 2x - 3y, x + y^2),$$

$$\begin{aligned} f(x_0 + h) &= f(x + h_1, y + h_2) \\ &= ((x + h_1)^2 + 3(y + h_2), 2(x + h_1) - 3(y + h_2), x + h_1 + (y + h_2)^2) \end{aligned}$$

$$\begin{aligned} f(x_0 + h) - f(x_0) &= (2xh_1 + h_1^2 + 3h_2, 2h_1 - 3h_2, h_1 + 2yh_2 + h_2^2)^\top \\ &= (2xh_1 + 3h_2, 2h_1 - 3h_2, h_1 + 2yh_2)^\top + (h_1^2, 0, h_2^2)^\top \\ &= \begin{pmatrix} 2x & 3 \\ 2 & -3 \\ 1 & 2y \end{pmatrix} \begin{pmatrix} h_1 \\ h_2 \end{pmatrix} + (h_1^2, 0, h_2^2)^\top \end{aligned}$$

따라서 $f'(x, y) = \begin{pmatrix} 2x & 3 \\ 2 & -3 \\ 1 & 2y \end{pmatrix}$ 이다.



$f(x, y) = (x^2 + 3y, 2x - 3y, x + y^2)$ 에서

$f_1(x, y) = x^2 + 3y, f_2(x, y) = 2x - 3y, f_3(x, y) = x + y^2$ 이라 하자. $f'(x, y) = \begin{pmatrix} 2x & 3 \\ 2 & -3 \\ 1 & 2y \end{pmatrix}$

$$\frac{\partial f_1}{\partial x} = 2x, \quad \frac{\partial f_1}{\partial y} = 3$$

$$\frac{\partial f_2}{\partial x} = 2, \quad \frac{\partial f_2}{\partial y} = -3$$

$$\frac{\partial f_3}{\partial x} = 1, \quad \frac{\partial f_3}{\partial y} = 2y$$

이다. $f'(x, y) = \begin{pmatrix} \frac{\partial f_1}{\partial x} & \frac{\partial f_1}{\partial y} \\ \frac{\partial f_2}{\partial x} & \frac{\partial f_2}{\partial y} \\ \frac{\partial f_3}{\partial x} & \frac{\partial f_3}{\partial y} \end{pmatrix}$ 임을 알 수 있다.



평면의 표준벡터 $e_1 = (1, 0)^\top, e_2 = (0, 1)^\top$ 에 대하여

$$f'(x, y)e_1 = \begin{pmatrix} \frac{\partial f_1}{\partial x} & \frac{\partial f_1}{\partial y} \\ \frac{\partial f_2}{\partial x} & \frac{\partial f_2}{\partial y} \\ \frac{\partial f_3}{\partial x} & \frac{\partial f_3}{\partial y} \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} \frac{\partial f_1}{\partial x} \\ \frac{\partial f_2}{\partial x} \\ \frac{\partial f_3}{\partial x} \end{pmatrix}, \quad f'(x, y)e_2 = \begin{pmatrix} \frac{\partial f_1}{\partial x} & \frac{\partial f_1}{\partial y} \\ \frac{\partial f_2}{\partial x} & \frac{\partial f_2}{\partial y} \\ \frac{\partial f_3}{\partial x} & \frac{\partial f_3}{\partial y} \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{\partial f_1}{\partial y} \\ \frac{\partial f_2}{\partial y} \\ \frac{\partial f_3}{\partial y} \end{pmatrix}$$

임을 알 수 있다. 즉, $f'(x, y)$ 의 각 행은 $f_1(x, y) = x^2 + 3y$, $f_2(x, y) = 2x - 3y$, $f_3(x, y) = x + y^2$ 의 편미분이다. 일반적으로 설명하면 다음과 같다.



함수 $f : R^n \rightarrow R^m$ 에 대하여, 주어진 점 $x_0 \in R^n$ 에 대한 전미분값 $f'(x_0)$ 은 $m \times n$

행렬이다. 벡터공간 R^n 의 표준기저를

$e_1 = (1, \dots, 0)^\top$, $e_2 = (0, 1, \dots, 0)^\top$, $\dots$, $e_n = (0, \dots, 0, 1)^\top$ 라 하고 벡터공간 R^m 의 표

준기저를 $u_1 = (1, \dots, 0)^\top$, $u_2 = (0, 1, \dots, 0)^\top$, $\dots$, $u_m = (0, \dots, 0, 1)^\top$ 이라 하자.

그러면 $f'(x_0)e_j$ 은 행렬 $f'(x_0)$ 의 j 번째 열벡터 값이다. 다음 정리에서는

$$\begin{aligned} f'(x_0)e_j &= \left(\frac{\partial f_1(x_0)}{\partial x_j}, \frac{\partial f_2(x_0)}{\partial x_j}, \dots, \frac{\partial f_m(x_0)}{\partial x_j} \right)^\top \\ &= \sum_{i=1}^m \frac{\partial f_i(x_0)}{\partial x_j} u_i \end{aligned}$$

임을 보일 것이다. 따라서 $f'(x_0)$ 는 아래와 같다.

$$f'(x_0) = \begin{pmatrix} \frac{\partial f_1(x_0)}{\partial x_1} & \frac{\partial f_1(x_0)}{\partial x_2} & \dots & \frac{\partial f_1(x_0)}{\partial x_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial f_m(x_0)}{\partial x_1} & \frac{\partial f_m(x_0)}{\partial x_2} & \dots & \frac{\partial f_m(x_0)}{\partial x_n} \end{pmatrix}$$

위 행렬을 **Jacobian 행렬**이라고도 많이 부른다. 이 경우 $f'(x_0) = J(x_0)$ 로 표기하기도 한다.



지금까지는 특정 점을 강조하기 위해서 x_0 을 사용했지만 지금부터는 단순히 x 로 사용하기로 하자.

$f : R^n \rightarrow R$ 인 경우 $f'(x) = \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right)$ 대신

$\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right)$ 로 많이 쓴다.

11.2-11 기호정의: $\nabla f(x) = \left(\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right)$ 을 x 에서의 기울기 벡터 (gradient vector)라 한다.



예제10: 다음 함수들의 전미분값을 구하라.

(1) $f(x, y) = x^3 - 3xy + 3y^2$

(2) $f(x, y, z) = x \sin yz$

(3) $f(x, y) = (x^2 - y^2, 2xy)$

(4) $f(x, y, z) = (x^2 - y^2, z^2 - 3xy)$

(5) $f(x, y) = (x^2y, y^2, 3x - 5y)$

(6) $c(t) = (t^2, t^3, t^4)$

[풀이] (1) $f'(x, y) = \nabla f(x, y) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) = (f_x, f_y) = (3x^2 - 3y, -3x + 6y)$

(2) $f'(x, y, z) = \nabla f(x, y, z) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z} \right) = (f_x, f_y, f_z)$
 $= (\sin yz, xz \cos yz, xy \cos yz)$

(3) $f(x, y) = (x^2 - y^2, 2xy)$ 에서 $f_1(x, y) = x^2 - y^2$, $f_2(x, y) = 2xy$ 라 하면

$$f'(x, y) = \begin{pmatrix} \frac{\partial f_1(x, y)}{\partial x} & \frac{\partial f_1(x, y)}{\partial y} \\ \frac{\partial f_2(x, y)}{\partial x} & \frac{\partial f_2(x, y)}{\partial y} \end{pmatrix} = \begin{pmatrix} 2x & -2y \\ 2y & 2x \end{pmatrix}$$



(4) $f(x, y, z) = (x^2 - y^2, z^2 - 2xy)$ 에서 $f_1(x, y, z) = x^2 - y^2$, $f_2(x, y, z) = z^2 - 3xy$ 라
하면

$$f'(x, y, z) = \begin{pmatrix} \frac{\partial f_1(x, y, z)}{\partial x} & \frac{\partial f_1(x, y, z)}{\partial y} & \frac{\partial f_1(x, y, z)}{\partial z} \\ \frac{\partial f_2(x, y, z)}{\partial x} & \frac{\partial f_2(x, y, z)}{\partial y} & \frac{\partial f_2(x, y, z)}{\partial z} \end{pmatrix}$$

$$= \begin{pmatrix} 2x & -2y & 0 \\ -3y & -3x & 2z \end{pmatrix}$$

(5) $f(x, y) = (x^2y, y^2, 3x - 5y)$ 에서 $f_1(x, y) = x^2y$, $f_2(x, y) = y^2$,
 $f_3(x, y) = 3x - 5y$ 라 하면

$$f(x, y) = \begin{pmatrix} \nabla f_1(\mathbf{x}) \\ \nabla f_2(\mathbf{x}) \\ \nabla f_3(\mathbf{x}) \end{pmatrix} = \begin{pmatrix} 2xy & x^2 \\ 0 & 2y \\ 3 & -5 \end{pmatrix}$$



(6) $c(t) = (t^2, t^3, t^4)$ 에서 $c'(t) = \begin{pmatrix} 2t \\ 3t^2 \\ 4t^3 \end{pmatrix}$ 이다. 하지만 보통

$c'(t) = (2t, 3t^2, 4t^3)$ 으로도 많이 표시한다. 분이기에 따라서 열벡터 또는 행벡터를 이용한다.



예제11: (1) $a = (a_1, a_2, \dots, a_n)$, $x = (x_1, x_2, \dots, x_n)$ 에 대하여 $f(x) = a \cdot x^\top$ 라 하면 $f'(x) = \nabla f(x) = a$ 이다.

(2) $A \in M_{m \times n}$ 이고 $f(x) = Ax$ 라 하면, 임의의 점 $x \in R^n$ 에 대하여 $f'(x) = A$ 이다.

(3) $A \in M_{n \times n}$ 이고 $f(x) = x^\top Ax$ 이면 $f'(x) = A^\top x + Ax$

(4) $A \in M_{n \times n}$ 인 대칭행렬이다. $f(x) = x^\top Ax$ 이면, $f'(x) = 2Ax$ 이다.

[풀이] (1) $f(x) = a \cdot x^\top = a_1x_1 + a_2x_2 + \dots + a_nx_n$ 이고 $\frac{\partial f(x)}{\partial x_i} = a_i$ 이므로

$f'(x) = \nabla f(x) = a$ 이다.



(2) $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$, $A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$ 이라 하면

$$f(\mathbf{x}) = A\mathbf{x} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \end{pmatrix}$$

이다. $f_i(\mathbf{x}) = a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n$ 이라 하면 $\nabla f_i(\mathbf{x}) = (a_{i1} \ a_{i2} \ \cdots \ a_{in})$ 이다.

따라서 $f'(\mathbf{x}) = \begin{pmatrix} \nabla f_1(\mathbf{x}) \\ \nabla f_2(\mathbf{x}) \\ \vdots \\ \nabla f_m(\mathbf{x}) \end{pmatrix} = A$



(3) A 가 3×3 행렬인 경우 직접 미분 해보자.

$$A = \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & k \end{pmatrix} \text{라 하자.}$$

$$\begin{aligned} f(x, y, z) &= (x, y, z) \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & k \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} \\ &= x(ax + by + cz) + y(dx + ey + fz) + z(gx + hy + kz) \\ &= (ax^2 + bxy + cxz) + (dxy + ey^2 + fyz) + (gxz + hyz + kz^2) \end{aligned}$$

$\nabla f(\mathbf{x}) = \left(\frac{\partial f(\mathbf{x})}{\partial x} \quad \frac{\partial f(\mathbf{x})}{\partial y} \quad \frac{\partial f(\mathbf{x})}{\partial z} \right)^\top$ 이다. 보통 $\nabla f(\mathbf{x})$ 는 행벡터 형태로 표시하나 열벡터로 계산해도 문제는 없다.



직접 $\frac{\partial f(\mathbf{x})}{\partial x}$, $\frac{\partial f(\mathbf{x})}{\partial y}$, $\frac{\partial f(\mathbf{x})}{\partial z}$ 을 구해보자.

$$\frac{\partial f(\mathbf{x})}{\partial x} = (a \ d \ g)(x \ y \ z)^\top + (a \ b \ c)(x \ y \ z)^\top,$$

$$\frac{\partial f(\mathbf{x})}{\partial y} = (b \ e \ h)(x \ y \ z)^\top + (d \ e \ f)(x \ y \ z)^\top,$$

$$\frac{\partial f(\mathbf{x})}{\partial z} = (c \ f \ k)(x \ y \ z)^\top + (g \ h \ k)(x \ y \ z)^\top.$$

$$\begin{aligned} \text{따라서 } \nabla f(\mathbf{x}) &= \left(\frac{\partial f(\mathbf{x})}{\partial x} \quad \frac{\partial f(\mathbf{x})}{\partial y} \quad \frac{\partial f(\mathbf{x})}{\partial z} \right)^\top \\ &= \begin{pmatrix} a & d & g \\ b & e & h \\ c & f & k \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} + \begin{pmatrix} a & b & c \\ d & e & f \\ g & h & k \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} = A^\top \mathbf{x} + A \mathbf{x} \end{aligned}$$



11.2-12 정리[합성함수 미분]: 함수 $f : R^n \rightarrow R^m$ 가 $x_0 \in R^n$ 에서 미분가능하고, 함수 $g : R^m \rightarrow R^k$ 가 $f(x_0) \in R^m$ 에서 미분가능이라고 하면, 합성함수 $g \circ f : R^n \rightarrow R^k : (g \circ f)(x) = g(f(x))$ 는 $x_0 \in R^n$ 에서 미분가능하고 다음 식을 만족한다.

$$(g \circ f)'(x_0) = g'(f(x_0))f'(x_0).$$

여기서 $f'(x_0)$ 은 $m \times n$ 행렬이고, $g'(f(x_0))$ 은 $k \times m$ 행렬이다.



보기12: $f(t) = (t, t^2, t^3)$, $g(x, y, z) = xy + \sin z$ 이다. 이때 합성함수는

$h(t) = g(f(t)) = g(t, t^2, t^3) = t^3 + \sin t^3$ 이다. 미분을 해보면

$h'(t) = 3t^2 + 3t^2 \cos t^3$ 이다. 한편,

$h'(t) = g'(f(t))f'(t)$ 이다.

$$f'(t) = \begin{pmatrix} 1 \\ 2t \\ 3t^2 \end{pmatrix}, \quad \nabla g(x, y, z) = (y, x, \cos z), \quad \nabla g(f(t)) = (t^2, t, \cos t^3)$$

$$\text{따라서 } g'(f(t))f'(t) = (t^2, t, \cos t^3) \begin{pmatrix} 1 \\ 2t \\ 3t^2 \end{pmatrix} = t^2 + 2t^2 + 3t^2 \cos t^3 = 3t^2 + 3t^2 \cos t^3$$



보기13: $\alpha : R \rightarrow R^n$, $f : R^n \rightarrow R$ 이면 합성함수 $g(t) = f(\alpha(t))$ 의 미분은 $g'(t) = f'(\alpha(t)) \cdot \alpha'(t)$ 이다.

11.2-13 방향미분과 전미분: 함수 $f : R^n \rightarrow R$ 가 $x_0 \in R^n$ 에서 전미분 가능이면 $u \in R^n$ 에 대한 방향 미분값은 다음과 같다.

$$f'(x_0, u) = \lim_{t \rightarrow 0} \frac{f(x_0 + t \cdot u) - f(x_0)}{t} = \nabla f(x_0) \cdot u$$

[증명] $\alpha : R \rightarrow R^n : \alpha(t) = x_0 + tu$ 라 하자. $g(t) = f(\alpha(t))$ 라 하면

$$f'(x_0, u) = g'(0) = f'(\alpha(0))\alpha'(0) \text{이다.}$$

$$\alpha(0) = x_0, \alpha'(t) = u \text{이므로 } f'(\alpha(0)) = \alpha'(0) = \nabla f(x_0) \cdot u$$

3. 테일러 급수(Taylor Series)



11.3.1 $f : R^n \rightarrow R$ 의 테일러 급수(Taylor Series)

11.3-1 테일러급수 표시방법: 일반적인 테일러급수의 2차 까지 표현방법은 아래와 같다.

$$f(x+h) = f(x) + \nabla f(x)h^\top + \frac{1}{2}hHf(x)h^\top + O(\|h\|^3)$$

또는

$$f(x+h) = f(x) + \nabla f(x)h^\top + \frac{1}{2}hHf(x_0)h^\top, \quad x_0 \in (x, x+h)$$

일반적으로 h 가 x 와 아주 가까운 점이면 다음식이 성립한다.

$$f(x+h) \approx f(x) + \nabla f(x)h^\top + \frac{1}{2}hHf(x)h^\top.$$



예제3: $f : R^2 \rightarrow R$, $x = (x, y)$, $h = (h_1, h_2)$ 라 하면

$f(x + h) = f(x + h_1, y + h_2)$ 을 2차까지 테일러급수로 표시하면

$$\begin{aligned} f(x + h) = f(x + h_1, y + h_2) = & f(x, y) + \left(\frac{\partial f(x, y)}{\partial x} \quad \frac{\partial f(x, y)}{\partial y} \right) \begin{pmatrix} h_1 \\ h_2 \end{pmatrix} \\ & + (h_1 \quad h_2) \begin{pmatrix} \frac{\partial^2 f(x, y)}{\partial x^2} & \frac{\partial^2 f(x, y)}{\partial x \partial y} \\ \frac{\partial^2 f(x, y)}{\partial x \partial y} & \frac{\partial^2 f(x, y)}{\partial y^2} \end{pmatrix} \begin{pmatrix} h_1 \\ h_2 \end{pmatrix} + O(\|h\|^3) \end{aligned}$$



예제5: 함수 $f(x, y) = \ln(x^2 + y^2)$ 에서 $f(x+h)$ 의 값을 테일러급수의 2차 까지 구하여 표현하라.

[풀이] $x = (x, y)$, $h = (h_1, h_2)$ 라 하자.

$$f_x = \frac{2x}{x^2 + y^2}, \quad f_y = \frac{2y}{x^2 + y^2},$$

$$f_{xx} = \frac{2(y^2 - x^2)}{(x^2 + y^2)^2}, \quad f_{yy} = \frac{2(x^2 - y^2)}{(x^2 + y^2)^2}, \quad f_{xy} = \frac{-4xy}{(x^2 + y^2)^2}$$

따라서

$$\nabla f(x) = (f_x \ f_y) = \left(\frac{2x}{x^2 + y^2} \quad \frac{2y}{x^2 + y^2} \right)$$

$$Hf(x) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{xy} & f_{yy} \end{pmatrix} = \begin{pmatrix} \frac{2(y^2 - x^2)}{(x^2 + y^2)^2} & \frac{-4xy}{(x^2 + y^2)^2} \\ \frac{-4xy}{(x^2 + y^2)^2} & \frac{2(x^2 - y^2)}{(x^2 + y^2)^2} \end{pmatrix}$$



$$f(\mathbf{x} + \mathbf{h}) = f(\mathbf{x}) + \nabla f(\mathbf{x})\mathbf{h}^\top + \frac{1}{2}\mathbf{h}Hf(\mathbf{x})\mathbf{h}^\top + O(\|\mathbf{h}\|^3) \text{에서}$$

$$\begin{aligned} f(x + h_1, y + h_2) &= \ln(x^2 + y^2) + \begin{pmatrix} \frac{2x}{x^2 + y^2} & \frac{2y}{x^2 + y^2} \end{pmatrix} \begin{pmatrix} h_1 \\ h_2 \end{pmatrix} \\ &\quad + (h_1 \ h_2) \begin{pmatrix} \frac{2(y^2 - x^2)}{(x^2 + y^2)^2} & \frac{-4xy}{(x^2 + y^2)^2} \\ \frac{-4xy}{(x^2 + y^2)^2} & \frac{2(x^2 - y^2)}{(x^2 + y^2)^2} \end{pmatrix} \begin{pmatrix} h_1 \\ h_2 \end{pmatrix} + O(\|\mathbf{h}\|^3) \\ &= \ln(x^2 + y^2) + \frac{2x}{x^2 + y^2}h_1 + \frac{2y}{x^2 + y^2}h_2 \\ &\quad + \frac{2(y^2 - x^2)}{(x^2 + y^2)^2}h_1^2 - \frac{8xy}{(x^2 + y^2)^2}h_1h_2 + \frac{2(x^2 - y^2)}{(x^2 + y^2)^2}h_2^2 + O(\|\mathbf{h}\|^3) \end{aligned}$$



2.3-8. 정의: $\nabla f(x_0) = 0$ 을 만족하는 점 x_0 을 **임계점(critical point)** 또는 **정지점(stationary point)**라 부른다.

11.3-10. 정리: 점 x_0 을 임계점(critical point)이라 하자. 헤세행렬 $Hf(x_0)$ 에 대하여

- (1) $Hf(x_0)$ 이 양의 정부호(positive definite) 행렬이면 x_0 는 국소 최소자이다.
- (2) $Hf(x_0)$ 이 음의 정부호(negative definite) 행렬이면 x_0 는 국소 최대자이다.
- (3) $Hf(x_0)$ 의 부호가 변하면 이 점 x_0 을 안장점(saddle point)이라 한다.

함수 f 가 이변수 함수이면 위 세 조건을 다음과 같이 바꾸어 쓸 수 있다.

$$Hf(x_0) = \begin{pmatrix} f_{xx}(x_0) & f_{xy}(x_0) \\ f_{xy}(x_0) & f_{yy}(x_0) \end{pmatrix} \text{라 하자.}$$

- (i) $f_{xx}(x_0) > 0, f_{xx}(x_0)f_{yy}(x_0) - (f_{xy}(x_0))^2 > 0$: x_0 는 국소 최소자
- (ii) $f_{xx}(x_0) < 0, f_{xx}(x_0)f_{yy}(x_0) - (f_{xy}(x_0))^2 > 0$: x_0 는 국소 최대자
- (iii) $f_{xx}(x_0)f_{yy}(x_0) - (f_{xy}(x_0))^2 < 0$: x_0 는 안장점

4. 컨벡스 함수(Convex function)



4.1-1 기본개념[최소자(Minimizer)]: D 을 R^n 의 부분집합이라고 하자. 즉, $D \subset R^n$ 일 때, $f : D \rightarrow R$ 에 대하여 몇 가지 기본 개념을 정의하자.

(1) $x^* \in D$ 을 다음 조건을 만족하면 **전역최소자(global minimizer)**이라 부른다.

모든 $x \in D$ 에 대하여 $f(x^*) \leq f(x)$ 이다.

이때, $f(x^*)$ 을 **전역최솟값(global minimum)**이라 한다.

(2) $x^* \in D$ 을 다음 조건을 만족하면 **강 전역최소자(strict global minimizer)**이라 부른다.

모든 $x \in D$ 에 대하여 $f(x^*) < f(x)$ 이다. 단 $x \neq x^*$



(3) $x^* \in D$ 을 다음 조건을 만족하면 국소 최소자(local minimizer)이라 부른다.

$B(x^*; r) \subset D$ 을 만족하는

하나의 오픈볼 $B(x^*; r) = \{y \mid \|y - x^*\| < r\}$, $r > 0$ 이 존재하여

모든 $x \in B(x^*; r)$ 에 대하여 $f(x^*) \leq f(x)$ 이다.

이때, $f(x^*)$ 을 국소 최솟값(local minimum)이라 한다.

(4) $x^* \in D$ 을 다음 조건을 만족하면 강 국소 최소자(strict local minimizer)이라 부른다.

$B(x^*; r) \subset D$ 을 만족하는 하나의 오픈볼 $B(x^*; r) = \{y \mid \|y - x^*\| < r\}$,

$r > 0$ 이 존재하여

모든 $x \in B(x^*; r)$ 에 대하여 $f(x^*) < f(x)$ 이다. 단 $x \neq x^*$



4.1-2 정의[컨벡스 집합과 컨벡스 함수(Convex Set and Convex Function)]:

(1) $x, y \in R^n$ 인 두 점 x, y 을 잇는 선분 집합을 $[x, y]$ 로 표시하고 정의는 다음과 같다.


$$[x, y] = \{z \mid z = (1 - \lambda)x + \lambda y, \lambda \in [0, 1]\}.$$

$[x, y]$ 을 두 점 x, y 을 포함하는 폐구간(closed interval)이라 부른다. 두 점 x, y 을 포함하지 않는 경우를 개구간(open interval)이라 부른다. 정의는 다음과 같다.


$$(x, y) = \{z \mid z = (1 - \lambda)x + \lambda y, \lambda \in (0, 1)\}.$$

(2) $K \subset R^n$ 인 집합 K 가 다음 조건을 만족하면 컨벡스집합(convex set) 이라고 부른다.

임의의 $x, y \in K$ 에 대하여 $[x, y] \subset K$ 이다.



[컨벡스 집합]



[컨벡스 집합 아님]



(3) K 가 컨벡스 집합이고 함수 $f: K \rightarrow R$ 가 다음 조건을 만족하면 컨벡스 함수 (convex function)이라 부른다.

임의의 $x, y \in K$ 와 $\lambda \in [0, 1]$ 에 대하여 다음 부등식이 만족한다.

$$f((1-\lambda)x + \lambda y) \leq (1-\lambda)f(x) + \lambda f(y) \quad \dots (3.1)$$

식 (3.1)을 바꾸어 쓰면 $\lambda_1 + \lambda_2 = 1$ 을 만족하는 음이 아닌 실수 λ_1, λ_2 에 대하여

$$f(\lambda_1 x + \lambda_2 y) \leq \lambda_1 f(x) + \lambda_2 f(y)$$


이다.

(4) K 가 볼록집합이고 함수 $f: K \rightarrow R$ 에 대하여 $-f$ 가 컨벡스 함수(convex function)이면 함수 f 을 컨케이브 함수(concave function)이라 한다.



임의의 $x, y \in K$ 와 $\lambda \in [0, 1]$ 에 대하여 다음 부등식이 만족한다.

$$f((1-\lambda)x + \lambda y) \leq (1-\lambda)f(x) + \lambda f(y) \quad \dots (3.1)$$



[Convex function]



4.1-11 정리: $f \in C^2$ 이고 K 는 R^n 의 오픈 컨벡스 집합(open convex subset) 이다.

$f: K \rightarrow R$ 가 컨벡스 함수일 필요충분조건은 임의의 $x \in K$ 에 대하여 헤세행렬(Hessian matrix) $Hf(x)$ 는 양의 준정부호(positive semidefinite) 행렬이다.

[증명] Taylor정리에 의해서

$$f(x) = f(x_0) + \nabla f(x_0)(x - x_0) + \frac{1}{2}(x - x_0)^\top Hf(x_0 + \alpha(x - x_0))(x - x_0),$$
$$\alpha \in [0, 1].$$

$$\frac{1}{2}(x - x_0)^\top Hf(x_0 + \alpha(x - x_0))(x - x_0) \geq 0 \text{ 이므로}$$

$$f(x) \geq f(x_0) + \nabla f(x_0)(x - x_0) \text{ 이다.}$$



예제2: $f: \mathbb{R}^2 \rightarrow \mathbb{R}: f(x, y) = x^2 + 4y^2 - 2x + 8y - 1$ 은 컨벡스 함수임을 보여라.

[풀이] $f_x = 2x - 2, f_y = 8y + 8, f_{xx} = 2, f_{yy} = 8, f_{xy} = 0$ 이므로


$Hf(x, y) = \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix}$ 이다.

임의의 $h = (h_1 \ h_2)$ 에 대하여

$$h Hf(x, y) h^T = (h_1 \ h_2) \begin{pmatrix} 2 & 0 \\ 0 & 8 \end{pmatrix} \begin{pmatrix} h_1 \\ h_2 \end{pmatrix} = 2h_1^2 + 8h_2^2$$

따라서 $h \neq 0$ 이면 $h Hf(x, y) h^T > 0$ 이다.

그러므로 주어진 함수는 컨벡스이다.



[$f(x, y) = x^2 + 4y^2 - 2x + 8y - 1$ 의 그래프]

5. 제약 조건이 없는 최적화



5.1 기본개념

사실 지금까지 공부한 편미분 및 전미분은 이절에서는 소개하는 최적화 방법 중 가장 대표적인 **Gradient Descent 방법**을 설명하기 위함이었다. Gradient Descent 방법은 머신러닝 기법 중 선형회기(Linear Regression), 로지스틱 회귀 (Logistic Regression), 신경망 (Neural Networks), Support Vector Machines (SVM) 등에 사용되며 머신러닝뿐만 아니라 다양한 분야에서는 사용하는 최적화 기법 중 하나이다.

어떤 특정한 데이터가 주어졌을 때, 이 데이터를 기반으로 해서 우리가 알고자 하는 변수 값 들을 구해야 하는 경우가 종종 생기게 된다.

주어진 데이터에 적합한 변수 값들을 구하기 위해서는 변수들을 정의역으로 하는 하나의 함수를 구성하게 된다. 이러한 함수 $f : R^n \rightarrow R$ 을 목적함수(objective function) 또는 비용함수(cost function)라 부른다. 그 다음 하는 일은 모든 $x \in R^n$ 에 대하여 $f(x^*) \leq f(x)$ 을 만족하는 x^* 을 찾는 일이다.

이러한 x^* 을 보통 전역 최소자(global minimizer)라 부른다. 이때 찾아진 x^* 는 주어진 데이터에 적합한 변수들의 최적화된 조합이라 할 수 있다.



문제는 보통 우리가 말하는 목적 함수 $f : R^n \rightarrow R$ 의 분석이 그리 쉽지 않다는 것이다. 즉, 구성된 목적함수가 유일한 전역 최소자를 갖는 함수인지 또는 많은 국소 최소자들을 갖는 경우인지 파악하기가 쉽지 않다는 뜻이다. 물론 몇몇 경우는 제외 하고는 사실 현재까지 알려진 수학적 이론들을 가지고는 복잡하게 만들어진 목적함수에서 전역 최소자가 있는지 판별하기란 그리 쉬운 일이 아니다.

최소자를 찾는 방법으로 가장 많이 사용하는 방법은 처음 시점 x_0 을 정하고 그 다음 스텝에서 $f(x_1) \leq f(x_0)$ 인 x_1 을 찾아 나가는 방법들이다. 현재 있는 점에서 하강방향을 결정하고 어느 정도 내려갈지를 선택해서 그 다음 점을 결정한다. 다시 같은 반복적인 방법(iterative method)으로 우리가 원하는 조건에 맞는 최소자를 구할 때 까지 일을 수행하게 된다.

이러한 방법은 주어진 목적함수의 구조를 모르고 시행하는 방법임으로 국소 최소자를 찾는 방법이라고 해야 한다. 즉, 적당한 범위에서의 $f(x^*) \leq f(x) \ (x \in D \subset R^n)$ 을 만족하는 x^* 을 구하게 되는 방법이다.



5.1-1: 초깃값 x_0 의 중요성

반복적인 방법을 동원하여 최소자(minimizer)를 구하는 경우 초깃값의 설정은 매우 중요한 의미를 가진다. 만약 초깃값 x_0 가 최소자 x^* 의 근처에서 시작했다면 반복횟수를 많이 줄일 수 있고 우리가 원하는 최소자에 수렴가능성이 크다고 할 수 있다. 또는 목적함수가 컨벡스 함수라면 최소자 x^* 로 부터 먼 곳에서 초깃값 x_0 을 시작해도 최소자로 수렴 가능성이 있으나, 목적함수의 모양이 어떠한지 모르는 경우에서 엉뚱한 최소자를 얻게 돼서 문제를 발생시키기도 한다. 다행히도 초깃값을 잘 구해서 시작하는 경우도 있지만 아닌 경우는 여러 개의 초깃값을 시작으로 하여 최소자를 찾기도 한다.



지금까지 설명한 내용을 간단히 아래와 같이 표현 한다.

5.1-2: [Optimization problem] Given $f : R^n \rightarrow R$,

$$\text{Find } x^* = \operatorname{argmin}_{x \in R^n} f(x)$$

$f : R^n \rightarrow R$ 을 목적함수(objective function) 또는 비용함수(cost function)라 부른다.

여기서 x^* 을 최소화자(minimizer)라 부른다. 위 영어식 표현은 책마다 약간씩 다를 수 있으나 내용은 거의 같다. 이 방법의 핵심은 먼저 하강 방향을 결정하고 결정된 하강 방향만큼 얼마나 내려가나 인데, 내려가는 크기를 보통 보폭크기(step size)라 한다.



5.1-3: 하강방향(descent direction)

x 에서 시작해서 그 다음은 $f(x + \alpha h) < f(x)$ 을 만족하는 $x + \alpha h$ 을 찾는 것이다. 테일러 전개 식에서

$$f(x + \alpha h) = f(x) + \alpha \nabla f(x) h^T + O(\alpha^2), \alpha > 0$$

이고, 적당히 작은 α 에 대하여 $f(x + \alpha h)$ 값은

$$f(x + \alpha h) \approx f(x) + \alpha \nabla f(x) h^T$$

와 같이 근사화 된다. 만약 $\nabla f(x) h^T < 0$ 이면 $f(x + \alpha h) < f(x)$ 인 식을 만족한다. 이때 h 을 하강방향(descent direction)이라 부른다.



예제1: $f(x, y) = \frac{10xy}{e^{x^2+y^2}}$ 에 대하여 $f(x + \alpha h) \approx f(x) + \alpha \nabla f(x) h^\top$ 인 관계를 알아보자.

$$f_x = \frac{10y - 20x^2y}{e^{x^2+y^2}}, \quad f_y = \frac{10x - 20xy^2}{e^{x^2+y^2}}$$

$$x = (1, 1), \quad h = (1, 7), \quad \nabla f(1, 1) = \left(\frac{-10}{e^2}, \frac{-10}{e^2} \right) \text{이면,}$$

(1) α 가 작아질수록 $f(x + \alpha h) \approx f(x) + \alpha \nabla f(x) h^\top$ 임을 알 수 있다.

(2) $\nabla f(1, 1) \cdot h^\top = \left(\frac{-10}{e^2}, \frac{-10}{e^2} \right) \cdot (1, 7)^\top = -\frac{80}{e^2} < 0$ 이므로 $h = (1, 7)$ 은 하강방향임을 알 수 있다.

α	$f(x + \alpha h)$	$f(x) + \alpha \nabla f(x) h^\top$
$\alpha = 5$	0	-52.7808
$\alpha = 1$	0	-9.4735
$\alpha = 0.5$	0	-4.0600
$\alpha = 0.1$	0.3099	0.2706
$\alpha = 0.05$	0.7606	0.8120
$\alpha = 0.01$	1.2401	1.2450
$\alpha = 0.005$	1.2978	1.2992
$\alpha = 0.001$	1.3424	1.3425
$\alpha = 0$	1.3533	1.3533



5.1 정의: (1) 벡터 h 가 $\nabla f(x)h^T < 0$ 만족하면 벡터 h 을 x 에서의 하강방향(descent direction)이라 부른다.

(2) 하강방향 h 가 결정되면 양의 상수 α 을 이용하여 αh 을 결정하는데. 양의 상수 α 를 보폭 크기(step size)라 한다.

5.1-6 종료조건(Stopping criteria) 반복을 종료하기 위해서 아래 종료조건 중 몇 개를 선택해서 사용한다.

(1) $\|x_{k+1} - x_k\| \leq \epsilon_1$

(2) $f(x_k) - f(x_{k+1}) \leq \epsilon_2$

(3) $\|\nabla f(x_k)\|_\infty \leq \epsilon_3$ ($\|x\|_\infty = \max_{i=1,2,\dots,n} |x_i|$)

(4) $f(x) \rightarrow 0$ 이면 $|f(x)| < \epsilon_4$

(5) $k > k_{\max}$ ($k_{\max}$: 최대 반복 횟수)



5.2 하강방향 찾기 [Gradient Descent 탐색방법]

미분 가능한 함수 $f : R^n \rightarrow R$ 가 x_0 에서부터 시작하여

$$f(x_0) > f(x_1) > f(x_2) > \dots$$

를 만족하는 $x_1, x_2, \dots$ 을 순차적으로 찾아간다고 생각해보자.

최종 목적은 유한 번 반복해서 아래 관계를 만족하는 x^* 을 찾아내는 것이다.

$$f(x_0) > f(x_1) > f(x_2) > \dots > f(x^*)$$

최소자 x^* 을 초깃값 x_0 부터 시작해서 순차적으로 $x_1, x_2, \dots$ 찾아내는 방법 중 하나를 Gradient descent method이라 한다.



u 를 단위 벡터라 하자, 즉, $\|u\| = 1$.

$\alpha_0(t) = x_0 + tu$ 라 하면, $\alpha_0(t)$ 는 R^n 에서 x_0 를 지나고 방향이 u 인 직선을 의미한다.

보기13: $\alpha : R \rightarrow R^n$, $f : R^n \rightarrow R$ 이면 합성함수 $g(t) = f(\alpha(t))$ 의 미분은 $g'(t) = f'(\alpha(t)) \cdot \alpha'(t)$ 이다.

$$\phi_0(t) = f(\alpha_0(t)) = f(x_0 + tu)$$

라 하면 $\phi_0 : R \rightarrow R$ 인 함수가 된다. ϕ_0 의 정의역은 $R = \{x_0 + tu \mid t \in R\} \subset R^n$ 이라 할 수 있다. 만약 직선 $x_0 + tu$ 의 점 중에서 $x_1 = x_0 + t_0 u$ 가

$f(x_0) > f(x_1)$ 을 만족한다면, $\phi_0(t)$ 함수는 $t = 0$ 인 점에서 감소 함수임에 틀림없다. 따라서 $\phi_0'(0) < 0$ 이어야 한다. 우리는 $\phi_0'(0) < 0$ 를 만족하는 단위 방향벡터 u 를 찾아야 한다.

$$\phi_0'(0) = \nabla f(x_0) \cdot u = \|\nabla f(x_0)\| \cos \theta$$



각 θ 는 $\nabla f(x_0)$ 와 u 사이의 각이다.

$u = -\frac{\nabla f(x_0)}{\|\nabla f(x_0)\|}$ 로 하면 $\phi_0'(0) < 0$ 를 만족하는 최소 방향벡터 이다.

따라서 x_1 의 값은 $x_0 - t\nabla f(x_0)$, $t > 0$ 중에서 $f(x_0 - t\nabla f(x_0))$ 의 값이 최소가 되는 t_0 를 구하면 된다.

만약 t_0 를 발견했다면 $x_1 = x_0 - t_0 \nabla f(x_0)$ 으로 하면 된다.

같은 방식으로 x_1 에서 $x_1 - t\nabla f(x_1)$ 에서 $f(x_1 - t\nabla f(x_1))$ 의 값이 최소가 되는 t_1 를 구하면 된다. 이 방법을 Gradient Descent 탐색 방법이라 한다.



5.2-1 알고리즘[Gradient Descent 탐색 방법]

$f : R^n \rightarrow R$ 에서

초깃값 x_0 부터 시작하여 순차적으로 $\{x_k\}$ 값을 구한다.

$$x_{k+1} = x_k - t_k \nabla f(x_k), \quad k = 0, 1, 2, \dots$$

단, $t_k > 0$ 이고 t_k 값은 아래 함수값을 최소로 하는 값이다.

$$\phi_k(t) = f(x_k - t_k \nabla f(x_k))$$



예제2: $f(x, y) = 4x^2 - 4xy + 2y^2$ 라 하자. $f(x, y)$ 는 컨벡스 함수이고 전역 최소자는 $x^* = (0, 0)$ 이다. 초깃값이 $x_0 = (2, 3)$ 라 하고 Gradient Descent 탐색 방법을 이용해서 전역 최소자를 찾아가는 방법을 생각해 보자.

[풀이] $\nabla f(x, y) = (8x - 4y, 4y - 4x)$ 에서

$$\nabla f(x_0) = \nabla f(2, 3) = (4, 4)$$

$$\phi(t) = f((2, 3) - t(4, 4)) = f(2 - 4t, 3 - 4t)$$

$$\begin{aligned}\phi'(t) &= -\nabla f(2 - 4t, 3 - 4t) \cdot (4, 4) \\ &= -(8(2 - 4t) - 4(3 - 4t), 4(3 - 4t) - 4(2 - 4t)) \cdot (4, 4) \\ &= -(-16t + 4, 4) \cdot (4, 4) \\ &= 64t - 32\end{aligned}$$

$\phi''(t) = 64 > 0$ 이므로 $\phi(t)$ 는 컨벡스 함수이다.

따라서 $\phi'(t) = 64t - 32 = 0$ 에서 $t = \frac{1}{2}$ 일 때 최솟값을 갖는다.

$$x_1 = x_0 - \frac{1}{2} \nabla f(x_0) = (2, 3) - \frac{1}{2}(4, 4) = (0, 1)$$



한 번 더 해보면, $\nabla f(x_1) = \nabla f(0, 1) = (-4, 4)$

$$\phi(t) = f((0, 1) - t(-4, 4)) = f(4t, 1 - 4t)$$

$$\phi'(t) = -\nabla f(4t, 1 - 4t) \cdot (-4, 4)$$

$$= -(8(4t) - 4(1 - 4t), 4(1 - 4t) - 4(4t)) \cdot (-4, 4)$$

$$= -(48t - 4, -32t + 4) \cdot (-4, 4) = 320t - 32$$

$\phi''(t) = 320 > 0$ 이므로 $\phi(t)$ 는 컨벡스 함수이다.

$\phi'(t) = 320t - 32 = 0$ 에서 $t = \frac{1}{10}$ 일 때 최솟값을 갖는다.

$$x_2 = x_1 - \frac{1}{10} \nabla f(x_1) = (0, 1) - \frac{1}{10}(-4, 4) = \left(\frac{2}{5}, \frac{3}{5}\right)$$

$$x_3 = \left(0, \frac{1}{5}\right)$$

$\vdots$

$$f(x_0) = f(2, 3) = 10$$

$$f(x_1) = f(0, 1) = 2$$

$$f(x_2) = f\left(\frac{2}{5}, \frac{3}{5}\right) = \frac{2}{5}$$

$$f(x_3) = f\left(0, \frac{1}{5}\right) = \frac{2}{25}$$



5.3 정리: $f : R^n \rightarrow R$ 이 2차 편미분 가능한 함수이다. $x_1 = x_0 - \alpha \nabla f(x_0)$, $\alpha > 0$ 인 식에서 보폭 α 는 다음과 같이 결정할 수 있다.

$$\alpha = \frac{\nabla f(x_0) \nabla f(x_0)^\top}{\nabla f(x_0) H f(x_0) \nabla f(x_0)^\top}$$



예제6: $f(x, y) = 4x^2 - 4xy + 2y^2$ 이고 초깃값이 $x_0 = (2, 3)$ 라 하자. 이때 보폭 α 값을 위 정리를 이용해서 구해보자.

[풀이] $f(2, 3) = 4 \times 2^2 - 4 \times 2 \times 3 + 2 \times 3^2 = 10$

$$\nabla f(x, y) = (f_x, f_y) = (8x - 4y, 4y - 4x) \text{ 에서}$$

$$\nabla f(x_0) = \nabla f(2, 3) = (4, 4)$$

$$f_{xx} = 8, f_{xy} = -4, f_{yy} = 4 \text{ 이므로}$$

$$Hf(x, y) = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{xy} & f_{yy} \end{pmatrix} = \begin{pmatrix} 8 & -4 \\ -4 & 4 \end{pmatrix} \text{ 이다.}$$

여기서 $Hf(x, y)$ 는 양 확정행렬이다.

$$\alpha = \frac{(4, 4)(4, 4)^\top}{(4, 4) \begin{pmatrix} 8 & -4 \\ -4 & 4 \end{pmatrix} (4, 4)^\top} = \frac{1}{2}$$

$x_1 = (0, 1)$ 로 시작하면

$$\nabla f(x_1) = \nabla f(0, 1) = (4, -4)$$

$$\alpha = \frac{(-4, 4)(-4, 4)^\top}{(-4, 4) \begin{pmatrix} 8 & -4 \\ -4 & 4 \end{pmatrix} (-4, 4)^\top} = \frac{1}{10}$$

6. 라그랑주 승수법



$$\text{Minimize } f(x) \text{ Subject to } g(x) = 0$$

라그랑주 승수법(Lagrange multiplier method)은 제약조건이 있는 최적화 문제를 푸는 방법이다. 이탈리아 태생으로 활동은 주로 프랑스에서 활약한 수학자 조세프루이 라그랑주 (Joseph-Louis Lagrange: 1736.1.25 - 1813.4.10)가 고안해낸 방법이다. 라그랑주 승수법엔 어떤 아이디어가 숨어있지는 하나의 예제 문제를 가지고 시작해 보자.

예제1: $xy = 3$ 을 만족하는 값 중 $x^2 + y^2$ 의 최솟값을 구하는 문제를 생각해보자.



예제1: $xy = 3$ 을 만족하는 값 중 $x^2 + y^2$ 의 최솟값을 구하는 문제를 생각해보자.

$xy = 3$ 이라는 조건을 그림으로 그리면 $y = \frac{3}{x}$ 인 유리함수의 그래프이다. 이 그래프 위에

점 중 $x^2 + y^2$ 이 최소인 점을 구하는 문제이다. $x^2 + y^2 = r^2$ 이라 하면

최소인 점은 $x^2 + y^2 = r^2$ 과 $y = \frac{3}{x}$ 의 그래프가 접할 때 이다. 즉, 최소인 점에서

$x^2 + y^2 = r^2$ 과 $y = \frac{3}{x}$ 이 같은 접선을 가질 때


이다. 이를 수식적으로 표현해 보자.

$f(x, y) = x^2 + y^2$, $g(x, y) = xy - 3$ 이라 하면

두 벡터 $\nabla f(x, y)$, $\nabla g(x, y)$ 가 평행이 될 때

이다.

$$\nabla f(x, y) = \lambda \nabla g(x, y) \quad \dots (6.1)$$



$[x^2 + y^2 = r^2$ 과 $y = \frac{3}{x}$ 의 그래프가

접할 때 $x^2 + y^2$ 은 최솟값을 갖는다.]



(6.1)식의 Lagrange방식은 제한영역을 나타내는 함수 $g(x,y)$ 와 $f(x,y)$ 을 하나의 식으로 묶을 수 있다. 즉,

$$L(x,y,\lambda) = f(x,y) + \lambda g(x,y) = x^2 + y^2 + \lambda(xy - 3) \quad \dots (6.2)$$

$L(x,y,\lambda)$ 을 Lagrange 함수라고 부른다. $L(x,y,\lambda)$ 의 최소자를 구해보자.

$L(x,y,\lambda)$ 는 미분 가능이므로 최소자를 가지려면 당연히 $\nabla L(x,y,\lambda) = 0$ 이다.

$$\frac{\partial L}{\partial x} = \frac{\partial f}{\partial x} + \lambda \frac{\partial g}{\partial x} = 0 \Rightarrow 2x + \lambda y = 0 \quad \dots \textcircled{1}$$

$$\frac{\partial L}{\partial y} = \frac{\partial f}{\partial y} + \lambda \frac{\partial g}{\partial y} = 0 \Rightarrow 2y + \lambda x = 0 \quad \dots \textcircled{2}$$

$$\frac{\partial L}{\partial \lambda} = g(x,y) = 0 \Rightarrow xy - 3 = 0 \quad \dots \textcircled{3}$$

주위 있게 관찰하면 $\nabla L(x,y,\lambda) = 0$ 식은 $\nabla f(x,y) + \lambda \nabla g(x,y) = 0$ 이므로 (6.1)식을 포함하고 있다. 또한 ③식에 제한조건 $g(x,y) = 0$ 가 들어가 있다.



① - ②을 하면 $(x - y)(2 - \lambda) = 0$ 이고 $\lambda = 2$ 이면 ①, ②식에서 $2x + 2y = 0$ 이고 $x = -y$ 이다. ③식에 대입하면 $x^2 + 3 = 0$ 이므로 만족하는 실수는 존재하지 않는다. 따라서 $x = y$ 이고 ③식에서 $x = y = \pm \sqrt{3}$ 이다. 여기서는 $x = y = \sqrt{3}$ 또는 $x = y = -\sqrt{3}$ 일 때 $x^2 + y^2 = (\sqrt{3})^2 + (\sqrt{3})^2 = 6$ 인 최솟값을 갖는다. 이때 $\lambda = -2$ 이다. $\lambda = -2$ 일 때, Lagrange 함수는

$$L(x, y, -2) = x^2 + y^2 - 2(xy - 3) = (x - y)^2 + 6$$

이다.



$$L_x(x, y, -2) = 2(x - y), \quad L_y(x, y, -2) = -2(x - y)$$

$$L_{xx}(x, y, -2) = 2, \quad L_{yy}(x, y, -2) = 2, \quad L_{xy}(x, y, -2) = L_{yx}(x, y, -2) = -2$$

따라서 헤세 행렬은 $HL(x, y, -2) = \begin{pmatrix} 2 & -2 \\ -2 & 2 \end{pmatrix}$ 이다.

$$(x \ y) \begin{pmatrix} 2 & -2 \\ -2 & 2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = 2(x - y)^2 \text{ 이므로 } HL(x, y, -2) \text{는 양의 정부호행렬이다.}$$

따라서 $L(x, y, -2) = x^2 + y^2 - 2(xy - 3) = (x - y)^2 + 6$ 는 컨벡스 함수다.

따라서 $(x^*, y^*) = (-\sqrt{3}, -\sqrt{3}), (\sqrt{3}, \sqrt{3})$ 은 $L(x, y, -2)$ 의 전역최소자다.

위 내용을 요약하면 $\lambda = -2$ 이고 $(x^*, y^*) = (-\sqrt{3}, -\sqrt{3}), (\sqrt{3}, \sqrt{3})$ 는 $g(x^*, y^*) = 0$ 을 만족하면서 $L(x, y, -2)$ 의 전역최소자이다.



6.1 라그랑주 승수법(Lagrange multiplier method)

-등호 제약조건이 있는 경우-

Minimize $f(x)$ **on** D

subject to $g_i(x) = 0$ **for** $i = 1, \dots, m$

$$D = \{x \in R^n \mid g_i(x) = 0, \forall i = 1, \dots, m\}$$

위 조건은 제약함수가 m 개 있는 일반적인 상황을 설명하고 있다.

6.1 정리 [Lagrange multiplier method]:

$f : R^n \rightarrow R, g_1, g_2, \dots, g_m : R^n \rightarrow R$ 에 대하여

$D = \{x \in R^n \mid g_i(x) = 0, \forall i = 1, \dots, m\}$ 이라 하자.

$\lambda_1, \dots, \lambda_m$ 에 대하여 $\lambda = (\lambda_1, \lambda_2, \dots, \lambda_m)$ 이라 하자.

$x^* \in D$ 가 함수

$$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i g_i(x) \quad \dots (5.3)$$

의 최소자라고 하면, x^* 는 집합 D 상에서 함수 f 의 최소자이다. $\lambda = (\lambda_1, \dots, \lambda_m)$ 을

Lagrange 계수 (Lagrange Multiplier)라고 한다.



6.2 정의: $\lambda = (\lambda_1, \dots, \lambda_m)$ 을 Lagrange 계수 (Lagrange Multiplier),

$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i g_i(x)$ 을 Lagrange 함수라고 한다.



6.3 정리 [Lagrange multiplier method]:

$L(x, \lambda) = f(x) + \sum_{i=1}^m \lambda_i g_i(x)$ 가 미분가능이라고 하면, 6.1-1정리 조건에 의해서 x^* 가 국

소 최소해일 필요충분조건은 $\lambda^* = (\lambda_1^*, \dots, \lambda_m^*)$ 가 존재하여 다음 조건을 만족한다.

$$(1) \quad \nabla L(x^*, \lambda^*) = 0 \Rightarrow \nabla_x L(x^*, \lambda^*) = 0, \quad \nabla_\lambda L(x^*, \lambda^*) = 0$$

$$(2) \quad a^t H L(x^*, \lambda^*) a \geq 0$$

(3) $a^t H L(x, \lambda^*) a \geq 0$ 이면 $L(x, \lambda^*)$ 가 컨벡스함수 이므로 x^* 는
전역최소자 이다.



예제2: Find $\min_{(x,y) \in \mathbb{R}^2} f(x,y)$ subject to $g(x,y) = 0$
where

$$f(x,y) = x + y \text{ and } g(x,y) = x^2 + y^2 - 2$$

[풀이] $L(x,y,\lambda) = f(x,y) + \lambda g(x,y) = x + y + \lambda(x^2 + y^2 - 2)$ 라 놓자.

$\nabla L(x,y,\lambda) = 0$ 을 계산하자.

$$\frac{\partial L}{\partial x} = 1 + 2\lambda x = 0 \dots \textcircled{1}$$

$$\frac{\partial L}{\partial y} = 1 + 2\lambda y = 0 \dots \textcircled{2}$$

$$\frac{\partial L}{\partial \lambda} = x^2 + y^2 - 2 = 0 \dots \textcircled{3}$$

① - ② 하면 $\lambda(x - y) = 0$ 이고 $\lambda = 0$ 이면 ①, ② 식이 성립하지 않는다.

따라서 $\lambda \neq 0$ 이고 $x = y$ 이다. ③식에 대입하면 $2x^2 = 2$

따라서 $x = y = 1$ 또는 $x = y = -1$ 이다.

$$\text{여기서 } HL = \begin{pmatrix} L_{xx} & L_{xy} \\ L_{xy} & L_{yy} \end{pmatrix} = \begin{pmatrix} 2\lambda & 0 \\ 0 & 2\lambda \end{pmatrix}$$

(1) $x = y = 1$ 이면 $\lambda = -\frac{1}{2}$ 이때 $HL = \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix}$ 이므로

$(x,y) = (1,1)$ 은 국소 최대자 이다.

(2) $x = y = -1$ 이면 $\lambda = \frac{1}{2}$ 이때 $HL = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ 이므로

$(x,y) = (-1,-1)$ 은 전역 최소자 이다.



예제3[중요]: 스펙트럴 크러스팅 과 주성분분석(PCA) 이론에 사용

$x \in R^n$ 이고 행렬 A 는 $n \times n$ 인 대칭행렬($A^T = A$)이다.

[문제] $\operatorname{argmin}_x x^T A x$ s.t. $x^T x = 1, A^T = A$

[풀이] $L(x, \lambda) = x^T A x - \lambda(x^T x - 1)$

$$0 = \frac{\partial}{\partial x} L(x, \lambda) = \frac{\partial}{\partial x} [x^T A x - \lambda(x^T x - 1)]$$

$$= \frac{\partial}{\partial x} [x^T A x - \lambda x^T x + \lambda] = 2Ax - 2\lambda x$$

따라서 $Ax = \lambda x$ 즉, x 는 고유벡터가 된다.

$x^T A x = x^T \lambda x = \lambda x^T x = \lambda$ 에서

고유값이 작은 고유벡터가 위 조건식을 만족한다.

참고: A 가 positive definite 행렬이면 모든 고유치 값은 0보다 크다.

예제11: (1) $a = (a_1, a_2, \dots, a_n)$, $x = (x_1, x_2, \dots, x_n)$ 에 대하여 $f(x) = a \cdot x^T$ 라 하면 $f'(x) = \nabla f(x) = a$ 이다.

(2) $A \in M_{m \times n}$ 이고 $f(x) = Ax$ 라 하면, 임의의 점 $x \in R^n$ 에 대하여 $f'(x) = A$ 이다.

(3) $A \in M_{n \times n}$ 이고 $f(x) = x^T A x$ 이면 $f'(x) = A^T x + Ax$

(4) $A \in M_{n \times n}$ 인 대칭행렬이다. $f(x) = x^T A x$ 이면, $f'(x) = 2Ax$ 이다.