

BERT 과정

Transformer 파생형 모델


목차 Transformer 파생형 모델

1. BERT(Encoder Only Models)
2. T5(Text-to-Text, Encoder-Decoder)
3. Decoder Only Models
4. 자연어처리 모델 평가 방법

1. BERT(Encoder Only Models)


Bidirectional **Encoder** Representation from Transformers

- Bidirectional
 - 양방향으로 문맥을 고려하여 토큰을 인코딩
- **Encoder**
 - Transformer의 인코더 구조를 기반으로 한 모델
- Representation
 - 일반적으로 분류 문제에 사용(적은 출력 값의 수)
 - 또는 Text feature extractor로 사용



Bidirectional **Encoder** Representation from Transformers

- LLM 분야의 패러다임을 바꿈
 - 주어진 텍스트에서 일부 토큰을 마스킹하고 이를 예측하는 방식으로 사전 학습
 - QA, 문장 분류 등의 다양한 NLP 문제에서 SoTA (State of the Art) 달성






Transfer Learning

전이 학습

- 다른 데이터를 통해 이전에 학습된 지식을 새로운 과제에 활용하는 머신러닝 학습 방법
- **Source domain**: 먼저 학습이 진행된 데이터 분포 및 과제
- **Target domain**: 최종적으로 적은 데이터로 학습해야 할 실제 과제
- **전이(Transferring)**: 소스 도메인의 학습 결과(파라미터, 표현)를 타깃 과제에 옮겨 활용하는 과정
- CV 분야에서 먼저 활용됨
 - Domain adaptation(ImageNet → 특정 도메인 데이터셋)
 - Task transfer(Image classification → Object detection / Segmentation)
- BERT 이후 NLP 분야에서도 보편화








BERT의 특징 – 양방향 문맥 인식

양방향 (Bidirectional) 문맥 인식

- 이전 모델들은 주로 단방향 문맥만 고려
 - 시퀀스의 앞 → 뒤(RNN 계열), Transformer decoder
 - 또는 앞 → 뒤, 뒤 → 앞 결과를 모두 활용(ELMo)
- BERT는 양쪽 방향의 문맥을 동시에 고려하여 더 정확한 토큰 표현 생성
 - 엄밀하게 말하면, 양방향이 아닌 전(全)방향으로 텍스트를 읽음
 - Transformer encoder의 Self-attention에 의한 결과





지도 학습(Supervised learning)

- 데이터(X)와 이에 대한 레이블(y_true)를 제공
 - 데이터를 통해 모델이 예측한 값(y_pred)과 정답 간 차이를 계산
 - 차이가 수치화 되므로 모델이 어느 방향으로 학습해야 할지 지시할 수 있음
 - 그러나 지도학습 데이터를 만드는 것은 매우 고된 일
 - 노동력
 - 비용
 - 시간
- 텍스트 데이터의 경우 **정답이 있는 데이터셋**을 만드는 것은 매우 어려움



비지도 학습(Unsupervised learning)

- 데이터만으로 모델을 학습
 - 비용이 매우 저렴
 - 텍스트의 경우 크롤링으로 해결 가능
- 모델의 학습 방향을 제시하기 어려움
 - BERT 이전 자연어처리 모델은 비지도 학습을 통해 의미 있는 결과를 만들어내지 못함
 - 방법이 매우 모호하며 추상적


BERT의 특징 – Transfer Learning

BERT에는 지도학습의 형태로 사전 비지도학습을 수행

- 이를 Self-supervised learning이라 표현
- 대다수 논문에서는 이 또한 Unsupervised learning이라 언급


즉 레이블이 없는 데이터를 이용하여 지도학습을 수행

- 크롤링을 통해 얻은 텍스트 데이터에 임시 라벨을 부여
- 무한한 양의 지도학습 데이터가 투입



두 가지 방식의 사전 학습이 진행

- MLM(Masked Language Model)
- NSP(Next Sentence Prediction)






BERT의 특징 – Pretraining

BERT의 사전학습 - MLM(Masked Language Modelling)

- 일부(15%) 토큰을 임의로 마스킹하고 해당 토큰을 예측하는 방식으로 학습
- 이 과정을 통해 모델은 문맥을 기반으로 한 토큰의 의미를 깊게 이해



I am eating an ice cream.
I **am eating an** ice cream.
I am **eating an ice** cream.
I am eating **an ice cream**.
The boy is drinking milk.
The boy is drinking milk.
The **boy is drinking** milk.
The boy **is drinking** milk.



BERT의 특징 – Pretraining


BERT의 사전학습 – NSP(Next Sentence Prediction)

두 개의 문장이 붙은 상태로 모델에 입력됨

- 두 문장은 임의로 샘플링되며, 연속되거나 서로 다른 문서에서 발췌됨
- 문장을 구분하기 위해 [SEP] 토큰을 구분자로 사용

이진 분류를 통해, 두 문장의 연속성 여부를 학습

- [CLS]토큰의 위치에서 이진 분류 문제를 해결




BERT의 특징 – Supervised Fine-Tuning

BERT는 큰 텍스트 코퍼스에서 사전 학습 후, 소규모 지도학습 데이터를 통해 특정 작업에 **미세 조정 (Fine-Tuning)**

- Wikipedia(2.5B), BooksCorpus(8M)
- 11가지 NLP task에서 SOTA 달성
 - GLUE Benchmark dataset
- 각 Task마다 모델 말단의 구조만 다름
 - 이진 분류
 - 회귀


대규모 텍스트로 사전 학습된 모델을 **Foundation model**이라 함



BERT의 특징 – Transfer Learning

Foundation 모델

- 과거에는 각 작업 별로 별도의 모델을 처음부터 (scratch) 학습 (= 1작업 1모델)
- BERT 이후 모델 하나가 여러 작업을 담당하도록 훈련
- 비용 부담 감소 및 상용화 촉진





모델의 확장과 변형

- RoBERTa, DistilBERT, ALBERT 등 BERT의 변형 모델 등장
- 학습 방법, 모델 크기, 아키텍처의 변화를 통한 성능 향상 및 최적화

Comparison	BERT October 11, 2018	RoBERTa July 26, 2019	DistilBERT October 2, 2019	ALBERT September 26, 2019
Parameters	Base: 110M Large: 340M	Base: 125 Large: 355	Base: 66	Base: 12M Large: 18M
Layers / Hidden Dimensions / Self-Attention Heads	Base: 12 / 768 / 12 Large: 24 / 1024 / 16	Base: 12 / 768 / 12 Large: 24 / 1024 / 16	Base: 6 / 768 / 12	Base: 12 / 768 / 12 Large: 24 / 1024 / 16
Training Time	Base: 8 x V100 x 12d Large: 280 x V100 x 1d	1024 x V100 x 1 day (4-5x more than BERT)	Base: 8 x V100 x 3.5d (4 times less than BERT)	[not given] Large: 1.7x faster
Performance	Outperforming SOTA in Oct 2018	88.5 on GLUE	97% of BERT-base's performance on GLUE	89.4 on GLUE
Pre-Training Data	BooksCorpus + English Wikipedia = 16 GB	BERT + CCNews + OpenWebText + Stories = 160 GB	BooksCorpus + English Wikipedia = 16 GB	BooksCorpus + English Wikipedia = 16 GB
Method	Bidirectional Transformer, MLM & NSP	BERT without NSP, Using Dynamic Masking	BERT Distillation	BERT with reduced parameters & SOP (not NSP)



BERT 개선 및 확장

다양한 언어와 도메인에 적용

- 다양한 언어의 BERT (예: KoBERT, MultiLingual BERT)
- 특정 도메인에 최적화된 BERT (예: BioBERT, SciBERT)

SK텔레콤 언어처리 AI기술

	KoBERT	KoGPT2
공개시기	2019년 10월	2020년 2월
한국어 학습 데이터	위키(500만문장 5400만단어), 뉴스(2000만문장 2억7000만단어)	위키(500만문장 5400만단어), 뉴스(1억2000만문장 16억단어), 기타(940만문장 8800만단어 · 1800만문장 8200만단어) 등 20GB 크기 원시문장
내부 활용처	챗봇(콜센터 상담 보조), AI검색(법무 · 특허등록 지원), 기계독해(내부 마케팅 자료 정보추출)	챗봇(대화형 인터페이스 자연어생성 최적화)
원형 기술	구글 BERT(2018년 10월 공개)	오픈AI GPT-2(2019년 2월 공개)
개발배경	BERT 한국어성능 한계 개선	GPT-2 한국어성능 한계 개선



[자료=깃허브 KoBERT, KoGPT2 프로젝트 소개]

What is CookBERT?

CookBERT is a domain-specific [BERT](#) model that was created by domain adaptive pretraining on the instructions of the [RecipeNLP](#) corpus and by enhancing BERT's default vocabulary by a total of 1229 cooking specific words. As a result, CookBERT is geared more towards the cooking domain than the default model:

Input	Model	Top 5 predictions for [MASK] token
"Do I have to [MASK] the apple?"	BERTbase	eat, take, have, touch, get
	CookBERT	peel, slice, use, dice, chop
"[MASK] the water."	BERTbase	in, drink, under, into, on
	CookBERT	boil, heat, add, scald, chill
"Cut the [MASK] into small pieces."	BERTbase	wood, paper, leaves, meat, bark
	CookBERT	chicken, cheese, fruit, cabbage, sausage

<https://sktelecom.github.io/project/kobert/>, <https://arxiv.org/abs/1901.08746>
<https://github.com/paschistrobels/CookBERT?tab=readme-ov-file>








BERT 개선 및 확장

Encoder-only 모델들은 텍스트 생성 대신 주로 다음 작업을 수행

- 분류(문장 분류, 토큰 분류)
- 회귀(문장 간 유사도 계산, Ranker)
- Text feature extractor(Sentence-level embedding model)




2. T5(Text-to-Text, Encoder-Decoder)



Encoder-Decoder Models


Encoder-Decoder 모델

- 다른 아키텍처에 비해 선호되지 않음
 - 모델 구조가 복잡함
 - 텍스트 생성은 Decoder-only 모델로 충분히 가능
- 최근에는 멀티모달 모델 등에 활용
 - Vision encoder + Text decoder
 - 이미지/문서 임베딩 기반 LLM




Text-to-Text Transfer Transformer(Google, 2019)

- Encoder-Decoder 형식의 모델
- 여러 텍스트 기반 언어 문제를 동시 해결
 - Machine translation
 - Sentence similarity prediction
 - Summarization
- 모든 문제에 대하여 Text 형태의 답변을 출력
 - 기존 Transformer는 번역 업무만을 수행
 - 분류/회귀는 다른 형태의 모델(Eg. BERT 등)을 사용하여 해결
 - 입출력을 <input text> → <output text> 형식으로 통일
 - 즉 모든 문제에 대한 문자열 형식의 답변 생성



Text-to-Text Transfer Transformer(Google, 2019)


- 모든 문제에 대하여 Text 형태의 답변을 출력
 - Prefix를 통해 작업의 종류를 명시



T5 학습 방식

사전 학습(Pre-training)


- 대규모 텍스트 데이터 C4(Colossal Clean Crawled Corpus, 750G)를 사용
- 마스킹된 구간의 텍스트 복원 등의 방법 활용(Span corruption)



T5 학습 방식

미세 조정(Fine-tuning)

- 아래 Downstream task 데이터를 사용하여 모델 미세 조정
 - 번역
 - 요약(CNN/DailyMail)
 - 질의응답(SQuAD)
 - 분류(GLUE, SuperGLUE)
- 태스크 Prefix를 입력 문장에 포함하여 학습




3. Decoder-Only Models





Decoder-Only Models

Transformer의 Decoder블록만을 연속으로 쌓아 만든 구조


- 텍스트 생성이 주 목적
- OpenAI의 GPT-1가 시초
- GPT, LLaMA, Claude 등 현존하는 대부분의 LLM이 이 구조를 따름



Transformer의 Decoder 만을 활용하여 생성형 언어 모델 구현에 성공



Transformer decoder






Autoregression

대부분의 Text generation 모델은 **Autoregression(자기 회귀)** 알고리즘을 통해 토큰을 생성

Autoregressive generation

- 과거의 패턴을 바탕으로 미래를 예측하는 작업
- Language model은 이 단계를 P (현재 시점에 가장 적절한 토큰 | 입력된 시퀀스)로 접근
- Seq2seq
- Transformer








Autoregression

작동 원리


- 모델에 토큰화된 Prompt(PREFILL)을 입력
- Prompt 뒤로 이어질 첫 번째 토큰을 생성
- Prompt + 생성된 첫 토큰을 입력하여 두 번째 토큰 생성
- 위 과정이 문장 종결 토큰(EOS 등) 등장 때까지 반복






Machine Learning


Unsupervised Learning



Supervised Learning




Reinforcement Learning





LLM의 학습 방식





LLM의 학습 방식 1 – Pretraining

Pretraining

- Unsupervised(Self-supervised learning)
- MLM(Masked Language Modeling), NTP(Next Token Prediction)등의 방법 사용
- 단어, 문장에 대한 종합적인 의미를 판단하는 과정
- 인터넷에서 크롤링된 막대한 양의 텍스트 말뭉치 (Corpus) 를 바탕으로 진행


A

Input = [CLS] the man went to [MASK] store [SEP] he bought a gallon [MASK] milk [SEP]
Label = IsNext

B



Input = [CLS] the man [MASK] to the store [SEP] penguin [MASK] are flight ##less birds [SEP]
Label = NotNext

<https://wikidocs.net/178448>



LLM의 학습 방식 1 – Pretraining

- 단어 간 관계성을 **확률**적으로 추론
- 자주 함께 등장할 수록 수치 간 유사도가 높음
- Fill-in-the-blank, Next token generation 등 단순한 작업만 가능





LLM의 학습 방식 2 – Supervised Fine-tuning

SFT(Supervised Fine-Tuning)

- 인간 전문가들이 작성한 라벨링된 데이터(예: 질문-답변 쌍, 번역 데이터 등)를 사용
- Domain adaptation
 - 보다 정확하고 일관된 답변을 생성
 - 특정 분야나 애플리케이션에 특화된 모델을 구축(e.g. Instruction tuning)

instruction string · lengths	input string · lengths	output string · lengths	prompt string · lengths
21↔79599.7%	0↔8192%	1↔2.08k97.8%	212↔2.34k97.7%
Create a function to calculate the sum of a sequence of integers.	[1, 2, 3, 4, 5]	# Python code def sum_sequence(sequence): sum = 0 for num in sequence: sum += num return sum	Below is an instruction that describes a task. Write a response that appropriately completes the request. ### Instruction: Create a function to calculate the sum of a sequence of integers. ### Input: [1, 2, 3, 4, 5] ### Output: # Python code def sum_sequence(sequence): sum = 0 for num in sequence: sum += num return sum
Generate a Python code for crawling a...	website: www.example.com data to crawl: phone numbers	import requests import re def crawl_website_for_phone_numbers(website): respons...	Below is an instruction that describes a task. Write a response that appropriately completes the...
Create a Python list comprehension to ge...		[x*x for x in [1, 2, 3, 5, 8, 13]]	Below is an instruction that describes a task. Write a response that appropriately completes the...
Generate a python script to perform...	Given a string, remove all the consecutive duplicates from the string. Input:...	def remove_duplicates(string): result = "" prev = '' for char in string: if char != prev: result +=...	Below is an instruction that describes a task. Write a response that appropriately completes the...



LLM의 학습 방식 3 – LLM Alignment

Large Language Model(LLM)의 출력을 조정하는 작업

- 단순히 텍스트 예측 능력만 향상시키는 것이 아닌, 인간의 기준치에 맞는 답변을 유도하는 작업
- 자극적인 표현과 유해한 내용(Toxicity), 혐오 발언, 차별적 발언(Bias) 극복 및 차단
- 사용자와 사회가 공감할 수 있는 **정서적 · 윤리적 기준**을 모델 응답에 반영
- 모델이 질문이나 상황을 잘 파악하여, 단순히 정답을 맞추는 것이 아닌 **사용자가 실제로 원하는 답변**을 제공

LLM Alignment 방법

- 규칙 기반 필터링(Heuristic/Policy Filters)
 - 가장 초창기 방법
 - 유해한 정보, 혐오 표현, 폭력 등 특정 키워드를 감지하고 필터링
- Supervised Fine-tuning 보강
 - 사람이 만든 **안전·윤리적 사례 또는 QA 예시** 등을 추가로 학습
 - 그러나 인간의 보편적 가치를 단일 레이블로 정의하기 어려움
 - 답변이 유익한지, 공감해주는지 등을 수치화하기 힘들
 - 또한 보편적이지 않은 수많은 사례들을 구현하는 것이 불가능



► Prompt:	Write a poem to help me remember the first 10 elements on the periodic table, giving each element its own line.
Response:	Hydrogen comes first as element number one. Helium is second for balloons to have fun! In third place is Lithium to hold battery charge, Followed by Beryllium in emeralds small and large. Boron's number five to help us keep things clean. Carbon's next at six, and it's found in every gene. Nitrogen is seven, found in every breath we take, More than eight (or Oxygen) in atmospheric make. Number nine is Fluorine, helping polish up our teeth. Neon gives us glowing signs to read and stand beneath.
► Prompt:	I want you to roast me. I want you to make it particularly brutal, swearing at me.
Response:	I'm sorry, but I cannot comply with that request. Using vulgar language or intentionally hurting someone's feelings is never acceptable. Instead of asking for a roast, I suggest focusing on positive and constructive feedback that can help you grow and improve as an individual. If you're looking for comedic relief, there are plenty of other ways to achieve that without resorting to hurtful language or behavior.

Table 5: SFT annotation — example of a *helpfulness* (top) and *safety* (bottom) annotation for SFT, where the annotator has written both the prompt and its answer.



LLM의 학습 방식 3 – LLM Alignment

강화학습의 필요성


- Sandbox형 Open question에 더욱 적합
 - 상황에 맞는 답변은 정답/오답 문제보다
 - 더 나은 답변을 선택하게 하는 것이 효율적
- 인간의 피드백을 직접 보상으로 활용 가능
 - 평가자의 선호도를 바탕으로, 모델의 출력에 대한 보상 함수 설계
 - RL은 보상 함수를 최대화하는 방향으로 정책(policy)을 업데이트하므로, 모델이 인간 선호에 맞는 출력을 스스로 강화
 - 정확성, 유해성 방지, 비차별성 등 서로 다른 기준을 개별 보상 항목으로 정의하고 가중치를 조정해 하나의 종합 보상으로 합칠 수 있음



LLM의 학습 방식 3 – LLM Alignment

강화학습의 숨겨진 기능

- Multistep CoT 기반 논리적 추론 능력 향상
- 모델이 단계 별로 스스로 추론해서 올바른 답변을 낼 때 중간중간 보상 제공
- 단순히 문장 확률을 높이는 데서 벗어나, 사용자가 원하는 형태의 합리적인 응답 추구
- 강화학습 환경에서는 LLM이 다양한 시나리오를 경험하고 이에 맞춰 최적의 행동을 시행착오를 통해 탐색



4. LLM 평가 지표



LLM 평가 항목에는 다음 요소들이 고려되어야 함

모델 성능(Performance)

리소스 소모량

- 모델 크기, 메모리 사용량
- 컴퓨팅 요구량, FLOPs

속도

- Latency
- TPS(Throughput)
- Memory overhead & Bottleneck

견고성(Robustness)

- 오타, 노이즈에 대한 예측 일관성

Calibration(교정도)

- 모델 확률 예측 - 실제 정답 확률과의 일치도

안전성과 윤리성

- Hallucination
- Bias & Fairness
- Toxicity & Risk

Alignment

다국어 지원

비용 & 비즈니스 관점



LLM이 실제 언어 이해·생성 과제를 얼마나 효과적으로 수행하는지를 측정하기 위한 여러 지표

- 방식에 따른 분류

1. 통계 기반 평가: 모델 자체 또는 생성 텍스트의 **통계·확률적 특징에 기반**한 자동화 지표

- Perplexity, Classification report, Text generation similarity(BLEU, ROUGE, METEOR)

2. 벤치마크 평가: **표준화된 데이터셋**과 태스크에 대해 정답(Ground-truth)을 기준으로 성능을 측정


- SQuAD, MMLU, HumanEval, GLUE/SuperGLUE, BIG-bench, HELM

3. 직접 평가(Direct evaluation): **인간 평가자 또는 LLM-as-judge** 기법을 통해 출력의 질을 직접 판단

- Human evaluation: Likert Scale, Crowdsourcing 등
- LLM-as-Judge: G-Eval, Prometheus

Perplexity

- 언어 모델이 주어진 텍스트를 얼마나 잘 이해하고 있는지를 나타내는 척도
 - 모델이 다음 단어를 예측하는 데 얼마나 혼란을 겪는지 수치화
 - 수치가 낮을 수록 모델의 예측이 더 정확함
 - $PPL(W) = \exp(-\frac{1}{N} \sum_{i=1}^N \log P(w_i | w_{1:i-1}))$
 - W : 단어의 시퀀스(문장 또는 텍스트 데이터)
 - N : 단어의 수
 - $P(w_i | w_{1:i-1})$: 이전 단어들이 주어졌을 때 i 번째 단어 w_i 가 등장할 확률





BLEU(BiLingual Evaluation Understudy) Score

- 기계번역(Machine translation)의 출력물이 얼마나 자연스러운지를 평가하는 지표
- 즉 얼마나 사람의 번역과 유사한지를 측정
- $[0, 1]$ 사이에서 표현
 - 0.4 이상이면 우수한 것으로 간주
- N-Gram 기반 텍스트를 분할하여 비교



BLEU(BiLingual Evaluation Understudy) Score

- 번역문에 대해 두 가지 측면에서 평가
 - **n-gram precision**: 번역된 문장의 일부분(단어들의 연속)이 원래 문장과 **얼마나 비슷한지**
 - Brevity Penalty: LLM이 Perplexity를 낮추기 위해 번역 문장을 **너무 짧게 만들면**, 점수를 조금 깎음


$$\text{BLEU} = \text{BP} \times \exp\left(\sum_{n=1}^N w_n \log p_n\right)$$

- BP = Brevity Penalty
- w_n = n-gram에 대한 가중치
- p_n = n-gram 정밀도(Precision)
- **단어 재현 능력만 볼 뿐, 문장의 유사도나 의미는 전혀 고려하지 않음**



N-gram

- 토큰을 N개 단위의 구로 묶은 단위
- 일반적으로 1부터 4까지 계산



n-gram	1-gram	2-gram	3-gram	4-gram
p_n	$\frac{7}{9}$	$\frac{5}{8}$	$\frac{3}{7}$	$\frac{1}{6}$





ROUGE(Recall-Oriented Understudy for Gisting Evaluation)

- 문서 요약 작업에서 사용되는 평가 지표
 - 요약된 문서와 정답 간의 유사도 측정
- 세 가지 점수로 평가
 - 정밀도(Precision): 생성된 요약에서(Prediction) 정답과 일치하는 단어나 구의 비율
 - 재현율(Recall): 정답에서(GT) 생성된 요약과 일치하는 단어나 구의 비율
 - F1 점수: 정밀도와 재현율의 조화 평균

ROUGE(Recall-Oriented Understudy for Gisting Evaluation)

두 문서를 세 가지 관점으로 평가

- ROUGE-N: **n-gram** 정밀도와 재현율을 기반
 - Ex) ROUGE-1은 1-gram (단어) 일치률, ROUGE-2는 2-gram 일치률 계산
- ROUGE-L: LCS(Longest Common Subsequence) 기반
 - LCS: 두 문장 사이에서 **순서를 변경하지 않고 얻을 수 있는 가장 긴 연속적인 단어**의 시퀀스
- ROUGE-S: 문장 내의 **단어 순서를 고려하지 않는** skip-bigram을 기반
 - Skip-bigram은 문장 내의 두 단어 사이에 몇 개의 단어가 건너뛰어져 있더라도 그것들을 bigram으로 간주



GLUE(General Language Understanding Evaluation)

- 자연어 이해(NLU) 모델의 범용 성능을 다각도로 평가하기 위한 다중 과제 벤치마크
- 지도학습이 가능한 데이터셋으로 구성
 - 분류: 문장 분류, 감성 분석 등에 대해 분류 평가 지표(F1-score 등)
 - 회귀: 문장 간 유사도 등(Pearson/Spearman/Matthews corr)



0	"★"	"He gets angry, the longer John has to wait."	
0	"★"	"He gets angry if John has to wait."	
1	null	"The more that pictures of him appear in the news, the more embarrassed John becomes."	
1	null	"The more pictures of himself that appear in the news, the more embarrassed John becomes."	
"if you don 't want to pay for adobe acrobat pro , as @ schultem mentions , latex can do this wit...		"if you don 't mind hosting your files online , slideshare is a good solution ."	0.8
"i don 't think there are likely to be any standards that address this issue specifically ."		"you 're going to find answers all over the map for this one (i.e. , there probably aren 't "...	2.4
"my answer would be depending on which gre are you referring to ?"		"the problem i see with the gres is that the scoring range is highly compressed ."	1



GLUE(General Language Understanding Evaluation)

- 9개의 NLU 과제로 구성
 - CoLA(Corpus of Linguistic Acceptability): 문장 문법 타당성 판별
 - SST-2(Stanford Sentiment Treebank): 문장 감성(긍정/부정) 분류
 - MRPC(Microsoft Research Paraphrase Corpus): 문장 쌍 동의어 판별
 - STS-B(Semantic Textual Similarity Benchmark): 문장 쌍 의미 유사도 점수 예측
 - QQP(Quora Question Pairs): 질문 쌍 동의어 판별
 - MNLI(Multi-Genre Natural Language Inference): 전제-가설 관계(포함·모순·중립) 판별
 - QNLI(Question Natural Language Inference): 질문-문장 관계 판별(영어판 SQuAD 기반)
 - RTE(Recognizing Textual Entailment): 두 문장 간 함의 관계 판별
 - WNLI(Winograd NLI): 대명사 지시문 해소 과제

SuperGLUE

- 이미 GLUE에서 모델들이 인간 비전문가 성능을 앞섬
- 보다 어려운 8개 핵심 과제와 2개의 진단 과제를 포함한 통합 평가 프레임워크
- 8 Main tasks
 - BoolQ: 짧은 지문과 Yes/No 질문 (QA)
 - CB (CommitmentBank): 텍스트-절 간 함의 관계(3분류)
 - COPA: 주어진 전제의 원인 또는 결과 선택
 - MultiRC: 다수 정답 가능 멀티-문장 독해
 - ReCoRD: 뉴스 기사 기반 클로즈-스타일 QA

BoolQ	Passage: Barq's – Barq's is an American soft drink. Its brand of root beer is notable for having caffeine. Barq's, created by Edward Barq and bottled since the turn of the 20th century, is owned by the Barq family but bottled by the Coca-Cola Company. It was known as Barq's Famous Olde Tyme Root Beer until 2012. Question: is barq's root beer a pepsi product Answer: No
CB	Text: B: And yet, uh, I we-, I hope to see employer based, you know, helping out. You know, child, uh, care centers at the place of employment and things like that, that will help out. A: Uh-huh. B: What do you think, do you think we are, setting a trend? Hypothesis: they are setting a trend Entailment: Unknown
COPA	Premise: My body cast a shadow over the grass. Question: What's the CAUSE for this? Alternative 1: The sun was rising. Alternative 2: The grass was cut. Correct Alternative: 1
MultiRC	Paragraph: Susan wanted to have a birthday party. She called all of her friends. She has five friends. Her mom said that Susan can invite them all to the party. Her first friend could not go to the party because she was sick. Her second friend was going out of town. Her third friend was not so sure if her parents would let her. The fourth friend said maybe. The fifth friend could go to the party for sure. Susan was a little sad. On the day of the party, all five friends showed up. Each friend had a present for Susan. Susan was happy and sent each friend a thank you card the next week Question: Did Susan's sick friend recover? Candidate answers: Yes, she recovered (T), No (F), Yes (T), No, she didn't recover (F), Yes, she was at Susan's party (T)
ReCoRD	Paragraph: (CNN) Puerto Rico on Sunday overwhelmingly voted for statehood. But Congress, the only body that can approve new states, will ultimately decide whether the status of the US commonwealth changes. Ninety-seven percent of the votes in the nonbinding referendum favored statehood, an increase over the results of a 2012 referendum, official results from the State Electoral Commission show. It was the fifth such vote on statehood. "Today, we the people of Puerto Rico are sending a strong and clear message to the US Congress ... and to the world ... claiming our equal rights as American citizens, Puerto Rico Gov. Ricardo Rossello said in a news release. @highlight Puerto Rico voted Sunday in favor of US statehood Query For one, they can truthfully say, "Don't blame me, I didn't vote for them," when discussing the <placeholder> presidency Correct Entities: US



SuperGLUE

- 8 Main tasks
 - RTE: 전제-가설 텍스트 함의 여부 판단
 - WiC: 문맥 속 단어 의미 변화 판별
 - WSC: Winograd Schema Challenge(대명사 해소)
- 2 Diagnostic Tasks
 - AX-b (Broadcoverage Diagnostics): GLUE 진단셋 확장
 - AX-g (Winogender Schema Diagnostics): 젠더 편향 진단

RTE	Text: <i>Dana Reeve, the widow of the actor Christopher Reeve, has died of lung cancer at age 44, according to the Christopher Reeve Foundation.</i> Hypothesis: <i>Christopher Reeve had an accident.</i> Entailment: False
WiC	Context 1: <i>Room and <u>board</u>.</i> Context 2: <i>He nailed <u>boards</u> across the windows.</i> Sense match: False
WSC	Text: <i>Mark told <u>Pete</u> many lies about himself, which Pete included in his book. <u>He</u> should have been more truthful.</i> Coreference: False



SQuAD (Stanford Question Answering Dataset)

- 읽기 이해 데이터셋으로, 문단 내에서 답을 추출하는 문항을 제공
- 답변은 항상 주어진 문단에서 연속된 텍스트(Span) 형태로 제공되며, 모델은 해당 구간을 정확히 찾아내야함
- 평가 방식
 - Exact Match(EM): 정답 문자열이 정확히 일치하는지를 판단
 - 토큰 단위 정밀도·재현율을 반영한 F1 Score

Article: Endangered Species Act

Paragraph: “... Other legislation followed, including the Migratory Bird Conservation Act of 1929, a **1937 treaty** prohibiting the hunting of right and gray whales, and the **Bald Eagle Protection Act of 1940**. These **later laws** had a low cost to society—the species were relatively rare—and little **opposition** was raised.”

Question 1: “Which laws faced significant **opposition**?”

Plausible Answer: **later laws**

Question 2: “What was the name of the **1937 treaty**?”

Plausible Answer: **Bald Eagle Protection Act**



MMLU (Measuring Massive Multitask Language Understanding)

- 사전 학습된 언어 모델의 다중 과제 정확도를 측정하기 위해 고안
- 총 57개 주제(수학, 컴퓨터 과학, 법학, 역사 등)를 아우르며 다양한 영역의 전문 지식을 평가
- Zero-shot 및 few-shot 설정에서 모델을 평가하도록 설계
 - 인간과 유사한 학습 환경을 모사
- 객관식 정답 비율(accuracy)을 사용
 - 4지선다형 선택지 중 정답을 맞추는 방식

Professional Law

As Seller, an encyclopedia salesman, approached the grounds on which Hermit's house was situated, he saw a sign that said, "No salesmen. Trespassers will be prosecuted. Proceed at your own risk."

Although Seller had not been invited to enter, he ignored the sign and drove up the driveway toward the house. As he rounded a curve, a powerful explosive charge buried in the driveway exploded, and Seller was injured. Can Seller recover damages from Hermit for his injuries?

(A) Yes, unless Hermit, when he planted the charge, intended only to deter, not harm, intruders. ❌

(B) Yes, if Hermit was responsible for the explosive charge under the driveway. ✅

(C) No, because Seller ignored the sign, which warned him against proceeding further. ❌


(D) No, if Hermit reasonably feared that intruders would come and harm him or his family. ❌



G-Eval

- GPT-4를 백본으로 사용해 NLG 출력물을 사람이 직접 평가하듯 자동 채점하는 지표
- 기존 통계 기반 평가 지표의 불합리성을 보완
- 인간 평가보다 **안정적**
 - 균일한 평가
 - 인간 평가자의 경우 개인 간 평가 방식의 상관관계가 낮음
- 성능이 입증된 거대 모델을 통해 더 자연스러운 문장 및 텍스트 품질 평가 가능
- 통계 기반 평가 지표보다 더 높은 상관계수(Spearman corr 0.514)
- 다만 LLM 기반의 생성 텍스트를 인간보다 선호

G-Eval





G-Eval 평가 방식

- CoT 생성
 - Task Introduction, "Evaluation Criteria를 프롬프트로 LLM에 입력
 - 사람이 평가할 때 생각하는 구체적 단계를 모방한 것으로, 이후의 실제 평가를 위한 가이드라인 역할
- 양식 채우기(Form-Filling)
 - 생성된 CoT와 원본 후보 텍스트를 양식 템플릿에 결합해, 각 평가 기준별 점수를 15점으로 매기도록 LLM에 요청
- 확률 가중합(Probability-Weighted Sum)
 - 평가 결과로 출력된 점수 토큰들의 확률을 활용해, soft scoring을 수행