



딥러닝을 이용한 자연어 처리

02 감정 분석 서비스



목차

- 01. 감정 분석 서비스
- 02. 나이브 베이즈
- 03. 나이브 베이즈 기반 감정 예측
- 04. scikit-learn을 통한 나이브 베이즈 구현
- 05. 기타 감정 분석 기법


01

감정 분석 서비스





헤드라인 뉴스와 각 기사묶음 타이틀은 기사 내용을 기반으로 자동 추출됩니다.



[영상] 제네시스 첫 전기차 G80 공개...상하이 모터쇼 출격

44

‘정청래 저격수’ 김용태 “조국 일가 ‘내로남불’에 국민이 치를 ...

42

공시가 뛰자 증여 광풍...인천 역대 최대, 강남 6배·세종 2배 폭증

23

먹던 국물이 다시 욕수통으로? '국물 재사용' 논란 휩싸인 부산...

57

8년만에 불매 직면...세종시, 남양유업에 영업정지 통보

69

뉴스, 백과 사전 같은 텍스트는 객관적인 정보를 제공

✔ 텍스트 데이터의 종류

문장	감정
영상미가 뛰어나고 너무너무 재미있었어요...	기쁨
배우들의 뛰어난 연기...	기쁨
허무한 결말...	분노

리뷰, 소설 같은 텍스트는 저자의 주관적인 평가나 감정을 표현

✓ 감정 분석이란

문장	감정
영상미가 뛰어나고 너무너무 재미있었어요...	기쁨
배우들의 뛰어난 연기...	기쁨
허무한 결말...	분노

대량의 텍스트가 있는 경우, **일일이** 데이터를 하나씩 살펴보고 판단하기 어려움

✓ 감정 분석이란

문장	감정
영상미가 뛰어나고 너무너무 재미있었어요...	기쁨
배우들의 뛰어난 연기...	기쁨
너무 흥미진진한 구성...	기쁨


비슷한 감정을 표현하는 문서는 유사한 단어 구성 및 언어적 특징을 보일 것을 가정

✓ 감정 분석이란



감정 분석(Sentiment analysis)은 텍스트 내에 표현되는
감정 및 평가를 식별하는 자연어 처리의 한 분야

✓ 감정 분석이란



텍스트 내 감정을 분류하거나 긍정/부정의 정도를 점수화


✓ 감정 분석 서비스

문장	감정
영상미가 뛰어나고 너무너무 재미있었어요...	기쁨
허무한 결말...	분노
배우들의 뛰어난 연기...	기쁨

•
•
•

머신러닝 기반 감정 분석 서비스의 경우, 데이터를 통한 **모델 학습**부터 시작

✓ 감정 분석 서비스



학습된 머신러닝 모델을 통해 **신규 텍스트의 감정**을 예측

02

나이프 베이스



✓ 나이브 베이즈의 원리

[텍스트 1] : 영상미가 | 뛰어나고 | 너무너무 | 재미있었어요



$$P(\text{감정} \mid \text{텍스트}) = ?$$

나이브 베이즈 기반 감정 분석은 주어진 텍스트가 특정 감정을 나타낼 확률을 예측하는 문제로 정의

✓ 나이브 베이즈의 원리

$$P(\text{감정} \mid \text{텍스트}) = \frac{P(\text{텍스트} \mid \text{감정}) \times P(\text{감정})}{P(\text{텍스트})}$$

베이즈 정리를 사용하여 텍스트의 감정 발생 확률을 추정

✓ 나이브 베이즈의 원리

[텍스트 1] : 영상미가 | 뛰어나고 | 너무너무 | 재미있었어요



[텍스트 1의 감정] : 해당 감정 내 단어들이 발생할 가능성 $\times$ 감정의 발생 확률

감정의 발생 확률과 텍스트를 구성하는
단어들의 가능도(likelihood)로 텍스트의 감정을 예측

✓ 단어의 가능도

$$\hat{P}(\text{단어} \mid \text{감정}) = \frac{(\text{감정 내 단어의 빈도수})}{(\text{감정 내 모든 단어의 빈도수})}$$

$$\hat{P}(\text{"재미있었어요"} \mid \text{기쁨}) = \frac{(\text{기쁨을 표현하는 문서 내 "재미있었어요"의 빈도수})}{(\text{기쁨을 표현하는 문서 내 모든 단어의 빈도수})}$$

텍스트 데이터에서는 가능도는 단어의 빈도수로 추정

✓ 감정의 발생 확률


$$P(\text{감정}) = \frac{(\text{해당 감정을 표현하는 문서의 수})}{(\text{데이터 내 모든 문서의 수})}$$

$$P(\text{기쁨}) = \frac{(\text{기쁨을 표현하는 리뷰의 수})}{(\text{전체 리뷰의 수})}$$

감정의 발생 확률은 주어진 텍스트 데이터 내 해당 감정을 표현하는 **문서의 비율**로 추정

✓ 텍스트의 감정

[텍스트 1] : 영상미가 | 뛰어나고 | 너무너무 | 재미있었어요



[텍스트 1이 기쁨을 나타낼 확률] : $\hat{P}(\text{"영상미가"} | \text{기쁨}) \times \dots \times \hat{P}(\text{"재미있었어요"} | \text{기쁨}) \times P(\text{기쁨})$

[텍스트 1이 분노를 나타낼 확률] : $\hat{P}(\text{"영상미가"} | \text{분노}) \times \dots \times \hat{P}(\text{"재미있었어요"} | \text{분노}) \times P(\text{분노})$

텍스트의 감정별 확률값 중 **최대 확률값**을 나타내는 감정을 해당 문서의 감정으로 예측

03

나이프 베이스 기반 감정 예측



✓ 스무딩 (smoothing)

학습 데이터 내 재미있었어요의 빈도 = 0

$$\hat{P}(\text{"재미있었어요"} | \text{기쁨}) = \frac{(\text{기쁨을 표현하는 문서 내 "재미있었어요"의 빈도수})}{(\text{기쁨을 표현하는 문서 내 모든 단어의 빈도수})} = 0$$

학습 데이터 내 존재하지 않은 단어가 포함된 문장의 감정 발생 확률은 0

✓ 스무딩 (smoothing)


학습 데이터 내 재미있었어요의 빈도 = 0

$$\hat{P}(\text{"재미있었어요"} | \text{기쁨}) = \frac{(\text{기쁨을 표현하는 문서 내 재미있었어요의 빈도수}) + 1}{(\text{기쁨을 표현하는 문서 내 모든 단어의 빈도수}) + 1}$$

스무딩(smoothing)을 통해 학습 데이터 내 존재하지 않은 단어의 빈도수를 보정

✓ 소수

[텍스트 1] : 영상미가 | 뛰어나고 | 너무너무 | 재미있었어요



[텍스트 1이 기쁨을 나타낼 확률] : $0.52 \times \dots \times 0.75 \times 0.22$

[텍스트 1이 분노를 나타낼 확률] : $0.1 \times \dots \times 0.001 \times 0.35$

단어의 감정별 가능도와 감정의 발생 확률은 모두 소수로 표현

✓ 소수

$$0.1 \times 0.1 = 0.01$$

$$0.1 \times 0.1 \times 0.1 = 0.001$$

$$0.1 \times 0.1 \times 0.1 \times 0.1 = 0.0001$$


$$0.1 \times 0.1 \times 0.1 \times 0.1 \times 0.1 = 0.00001$$

•
•
•

연속적으로 소수를 곱하면 결괏값은 끊임없이 감소

 소수

[텍스트 1] : 동해물과 | 백두산이 | 마르고 | 닳도록 ...

[illegible]

단어의 수가 많아질수록 텍스트의 확률값은 컴퓨터가 처리할 수 있는
소수점의 범위보다 작아질 수 있음

✓ 로그

$$\log_{10}(0.1 \times 0.1) = \log_{10}(0.1) + \log_{10}(0.1) = -2$$

$$\log_{10}(0.1 \times 0.1 \times 0.1) = \log_{10}(0.1) + \log_{10}(0.1) + \log_{10}(0.1) = -3$$


$$\log_{10}(0.1 \times 0.1 \times 0.1 \times 0.1) = \log_{10}(0.1) + \log_{10}(0.1) + \log_{10}(0.1) + \log_{10}(0.1) = -4$$

•
•
•

로그를 사용하면 끊임없이 숫자가 작아지는 것을 방지

✓ 최종 나이브 베이즈

[텍스트 1] : 영상미가 | 뛰어나고 | 너무너무 | 재미있었어요



[텍스트 1이 기쁨을 나타낼 확률] : $\log(\hat{P}(\text{"영상미가"} | \text{기쁨})) + \dots + \log(\hat{P}(\text{"재미있었어요"} | \text{기쁨})) + \log(P(\text{기쁨}))$

로그 확률값의 합으로 텍스트의 감정을 예측

04

scikit-learn을 통한 나이브 베이즈 구현



✓ scikit-learn



scikit-learn은 각종 데이터 전처리 및 머신 러닝 모델을
간편한 형태로 제공하는 파이썬 라이브러리

✓ scikit-learn

Example

```
from sklearn.feature_extraction.text import CountVectorizer

doc = ["i am very happy", "this product is really great"]
emotion = ["happy", "excited"]

cv = CountVectorizer()
csr_doc_matrix = cv.fit_transform(X_train)

# 각 단어 및 문장별 고유 ID 부여 및 단어의 빈도수를 계산
print(csr_doc_matrix) # (0, 0)      1, (0, 7)      1
```

✓ scikit-learn

Example

```
from sklearn.naive_bayes import MultinomialNB

doc = ["i am very happy", "this product is really great"]
emotion = ["happy", "excited"]

clf = MultinomialNB()

# CountVectorizer로 변환된 텍스트 데이터를 사용
clf.fit(csr_doc_matrix, emotion)
```

✓ scikit-learn

Example

```
from sklearn.naive_bayes import MultinomialNB

test_doc = ["i am really great"]

# 학습된 CountVectorizer 형태로 변환
transformed_test = cv.transform(test_doc)
pred = clf.predict(doc_vector)


print(pred) # array(['excited'], dtype='<U7')
```

05

기타 감정 분석 방법



✓ 감정 분석



감정 분석은 지도 학습(supervised learning) 기반의 분류 및 예측의 문제

✓ 감정 분석 + 머신러닝

문장	감정
영상미가 뛰어나고 너무너무 재미있었어요...	기쁨
허무한 결말...	분노
인생 최고의 영화...	감동

학습 데이터에 감정만 존재하면 머신러닝 알고리즘 학습이 가능


✓ 감정 분석 + 머신러닝

엘리스		[0.23, 0.401, 0.482, 0.42, 0.99 ...]
자연어		[0.03, 0.101, 2.682, 0.62, 0.08 ...]
처리	➡	[1.03, 0.222, 0.382, 0.32, 1.28 ...]
.		.
.		.
.		.

임베딩 벡터를 사용하여, 머신러닝 알고리즘 적용이 가능

✓ 예시: 평균 임베딩 벡터

[텍스트 1] : 영상미가 | 뛰어나고 | 너무너무 | 재미있었어요 | ...



영상미 : [0.12, 0.24, 0.913 ...]


+

뛰어나다 : [0.87, 0.53, 0.03 ...]

+


가장 간단한 방법으로 **단어 임베딩 벡터의 평균**을 사용

✓ 예시: CNN




단어 임베딩 벡터에 필터를 적용하여 CNN 기반으로 감정 분류

✓ 예시: CNN




문자 임베딩 벡터에 필터를 적용하여 CNN 기반으로 감정 분류

✓ 예시: RNN



LSTM, GRU를 활용하여 RNN 기반으로 분류 및 예측

✓ 예시: RNN



문자 단위로 단어를 분리하여 RNN 기반으로 분류 및 예측

크레딧

/* elice */

코스 매니저

이재성

콘텐츠 제작자

김한결

강사

김한결

감수자

김한결

디자이너

강혜정

연락처

TEL

070-4633-2015

WEB

<https://elice.io>

E-MAIL

contact@elice.io

