

LLM and data-driven services

---

# LLM과 데이터 기반 서비스

## 01 ChatGPT와 챗봇

## 목차 ChatGPT와 챗봇

---

1. LLM과 ChatGPT API
2. API를 이용한 ChatGPT 사용
3. 프롬프트 엔지니어링

# 1. LLM과 ChatGPT API





- 다음에 올 단어를 예측하는 모델
- 앞의 내용을 기반으로 뒤에 이어질 때 문맥상 자연스러운 단어를 예측
- 각 단어가 이어질 확률을 예측하는 모델

It's raining and I don't have

?

- 다음에 올 단어를 예측하는 모델
- 앞의 내용을 기반으로 뒤에 이어질 때 문맥상 자연스러운 단어를 예측
- 각 단어가 이어질 확률을 예측하는 모델

It's raining and I don't have

| ?               |             |
|-----------------|-------------|
| <b>Umbrella</b> | <b>96 %</b> |
| coat            | 3 %         |
| car             | 1 %         |
| ...             | ...         |

각 단어가 선택될 확률

- 거대한 (Large) 언어 모델
- GPT3, LLaMA2, GPT4 등이 LLM에 일종
- 모든 LLM은 기본적으로 다음에 올 단어를 예측하는 모델

It's raining and I don't have


| ?        |      |
|----------|------|
| Umbrella | 96 % |
| coat     | 3 %  |
| car      | 1 %  |
| ...      | ...  |

각 단어가 선택될 확률



- OpenAI에서 개발한 LLM 서비스
- 최근에는 다른 모델과 결합 등을 통해 그림 생성, 영상 요약 등의 기능도 제공하고 있음
- 코딩, 데이터 분석, 작문, 번역 등 다양한 분야에서 높은 성능을 보임





- OpenAI에서 제공하는 UI를 통해 ChatGPT를 쉽게 사용할 수 있음
- 무료로 모델도 제공
- 단, 서비스를 개발하는 목적으로는 적합하지 않음





## 프로그램이나 앱에서 OpenAI의 다양한 모델을 사용할 수 있게 해주는 도구

- 웹 페이지에서 사용하는 것과 달리, API는 개발자가 직접 코드로 모델과의 상호작용을 제어
- 다양한 서비스 및 앱에 OpenAI 모델 통합 가능



## 사람의 언어는 단어와 문장으로 구성

The unhappy child cried.

- 사람은 단어를 조합하여 문장을 만들고, 이를 통해 감정이나 생각을 표현
- 이 문장은 5개의 단어로 구성되어 있으며, 각 단어가 특정한 의미를 가짐.



## 언어 처리 모델에서 텍스트를 분석하고 처리할 때 사용하는 기본 단위

The un|happy child cried.

- 토큰은 단어 하나, 단어의 일부, 또는 문자 하나로 구성될 수 있음
- 예를 들어, **unhappy**는 2개의 토큰으로 나눌 수 있으며, "un", "happy" 로 처리됨



## 응답 크기, 비용에 단위가 되며 성능에도 영향을 미침

- ChatGPT API의 사용 비용은 사용된 토큰의 수에 따라 결정됨
- API 호출에서 사용할 수 있는 토큰 수에는 제한이 있으며, 이는 모델의 응답 크기와 복잡성에 영향을 미침
- 적절한 토큰화는 모델의 성능을 극대화하고, 원하는 결과를 보다 정확하게 얻는 데 중요



## 텍스트 완성 뿐 아니라 다양한 기능을 제공

Audio: 음성을 텍스트로 변경

Chat : 질문에 대한 대답을 제공 ( 대화형 )

Completions : 질문에 대한 대답을 제공

Embeddings 텍스트를 벡터로 임베딩

...



## API를 호출하기 위해 필요한 보안 코드

- 숫자와 알파벳으로 구성된 인증용 문자열
  - 예시 sk-hgxQbNbuN651fj9OAaT3BibkFJy9dJdEraG7vNluT
- 이 Key가 있다면 계정 정보를 몰라도 API를 호출할 수 있음
  - 유출될 경우 제 3자가 이를 사용할 수 있어 안전하게 보관 필요



## 개인 사용자에게 발급되는 키로, 과거에 주로 사용

- 모든 모델에 접근할 수 있으며 여러 프로젝트에서 사용할 수 있음
- 레거시(legacy)로 간주되어 점차 프로젝트별 키로 대체되고 있음



## 특정 프로젝트에 할당된 API 키로, 새로운 설정에서는 이 키 사용이 권장됨

- 조직 내 개별 프로젝트에 대한 더 나은 관리와 통제를 제공
- 프로젝트 단위로 사용량 제한을 설정하고 특정 모델에 대한 접근 권한을 관리할 수 있음
- 프로젝트별로 예산을 설정하고, 역할을 지정하며, 누가 어떤 자원에 접근할 수 있는지 통제할 수 있음





# API Key 발급 방법

LLM과 데이터 기반 서비스

ChatGPT와 챗봇

LLM과 ChatGPT API

## API keys

+ Create new secret key

**Project API keys have replaced user API keys**

We recommend using project based API keys.

As an owner of this project, you can view and manage API keys for your project.

Do not share your API key with others, or expose it in public code or leaked publicly.

View usage per API key on the [Usage page](#).

### Create new secret key

**Owned by**

☒ You ☐ Service account

This API key is tied to your user and can make requests against the selected project. If you are removed from the organization or project, this key will be disabled.

**Name** Optional

My Test Key

**Project**

Default project

**Permissions**

**All** Restricted Read Only

Cancel Create secret key

View user API keys

- Openai 로그인 -> 우측상단 프로필 -> view API keys -> create new secret key
- 이름과 프로젝트 선택 -> Create secret key





## Save your key

Please save this secret key somewhere safe and accessible. For security reasons, **you won't be able to view it again** through your OpenAI account. If you lose this secret key, you'll need to generate a new one.

 Copy

### Permissions

Read and write API resources

Done

- 이후 생성된 키를 저장
- 분실 시 새로 발급이 필요

## 가장 최신의 고성능 모델

| Model             | Pricing                    |
|-------------------|----------------------------|
| gpt-4o            | \$5.00 / 1M input tokens   |
|                   | \$15.00 / 1M output tokens |
| gpt-4o-2024-08-06 | \$2.50 / 1M input tokens   |
|                   | \$10.00 / 1M output tokens |
| gpt-4o-2024-05-13 | \$5.00 / 1M input tokens   |
|                   | \$15.00 / 1M output tokens |



가격이 훨씬 저렴하고 빠른 응답속도의 모델

| Model                  | Pricing                    |
|------------------------|----------------------------|
| gpt-4o-mini            | \$0.150 / 1M input tokens  |
|                        | \$0.600 / 1M output tokens |
| gpt-4o-mini-2024-07-18 | \$0.150 / 1M input tokens  |
|                        | \$0.600 / 1M output tokens |



## 파이썬에서 OpenAI API를 사용할 때 도움을 주는 라이브러리

- pip install openai 를 통해 설치



## 2. API를 이용한 ChatGPT 사용





## OpenAI의 문장완성 기능을 가진 대화형 API

- Chat completion API 요청 시, models 및 messages 파라미터는 필수적으로 사용해야 함
- 사용자가 질문할 때: messages로 질문을 요청
- GPT가 응답할 때 : choices로 응답함



```
from openai import OpenAI

client = OpenAI(api_key="sk-1234567890abcdef1234567890abcdef")

resp = client.chat.completions.create(
    model="gpt-4o-mini",
    messages=[{"role": "user", "content": "Say this is a test"}],
)

print(resp.choices[0].message.content)
# Output: This is a test.
```

- API key를 이용해 client 인스턴스를 생성
- 정해진 형식을 통해 요청
- 이후 응답을 파싱하여 사용

## 모델이 생성한 여러 가지 응답의 목록

- 주어진 프롬프트에 이어질 적절한 내용의 후보들
- 기본 옵션으로 호출 시 1개의 객체만 응답
- 주요 속성
  - `finish_reason`: 생성이 중지된 이유
  - `logprobs`: 이 응답의 로그 확률
  - `message`: 모델이 생성한 메시지
    - `message.content` 를 통해 생성된 텍스트를 가져올 수 있음



# 챗봇: 간단한 함수를 이용해 사용

LLM과 데이터 기반 서비스

ChatGPT와 챗봇

API를 이용한  
ChatGPT 사용

```
from openai import OpenAI

def get_response(prompt: str) -> str:
    client = OpenAI(
        api_key="sk-1234567890abcdef1234567890abcdef"
    )

    resp = client.chat.completions.create(
        model="gpt-4o-mini",
        messages=[{"role": "user", "content": prompt}],
    )
    return resp.choices[0].message.content

prompt = input("You>")
print("AI>", get_response(prompt))
```

- 입력한 프롬프트에서 생성된 결과를 반환
- 매번 클라이언트 객체가 생성되는 이슈가 있음

You>안녕? 너는 누구니?

AI> 안녕하세요! 저는 AI 언어 모델로, 여러분의 질문에 답변하고 정보를 제공하는 역할을 하고 있습니다. 무엇을 도와드릴까요?





# 챗봇: 채팅 유지하기

LLM과 데이터 기반 서비스

ChatGPT와 챗봇

API를 이용한  
ChatGPT 사용

```
from openai import OpenAI

def get_response(chat_log: list) -> dict:
    client = OpenAI(
        api_key="sk-1234567890abcdef1234567890abcdef"
    )
    resp = client.chat.completions.create(
        model="gpt-4o-mini",
        messages=chat_log,
    )
    msg = resp.choices[0].message
    return {"role": msg.role, "content": msg.content}

chat_log = [] # 채팅 기록
for i in range(3):
    chat_log.append({"role": "user", "content": input("You> ")})
    response = get_response(chat_log)
    print("AI>", response["content"])
    chat_log.append(response)
```

You> 내 이름은 엘리스야.

AI> 안녕하세요, 엘리스! 만나서 반갑습니다. 어떻게 도와드릴까요?

You> 내 이름이 뭐라고?

AI> 당신의 이름은 엘리스입니다! 맞나요?

- 딕셔너리로 구성된 리스트로 채팅 기록을 저장
- 대화 내용을 요청에 함께 전송
- 이전 내용을 기억하는 효과를 구현할 수 있음





# 사용량 확인 (usage)

LLM과 데이터 기반 서비스

ChatGPT와 챗봇

API를 이용한 ChatGPT 사용

```
def get_response(prompt: str) -> str:
    client = OpenAI(
        api_key="sk-1234567890abcdef1234567890abcdef"
    )
    resp = client.chat.completions.create(
        model="gpt-4o-mini",
        messages=[{"role": "user", "content": prompt}],
    )
    print("사용량", resp.usage)

    return resp.choices[0].message.content

print(get_response("내 이름은 엘리스야"))
```

사용량 CompletionUsage(completion\_tokens=22, prompt\_tokens=14, total\_tokens=36, ...)

| Model                  | Pricing                            | Pricing with Batch API*    |
|------------------------|------------------------------------|----------------------------|
| gpt-4o-mini            | \$0.150 / 1M input tokens          | \$0.075 / 1M input tokens  |
|                        | \$0.075 / 1M cached** input tokens |                            |
|                        | \$0.600 / 1M output tokens         | \$0.300 / 1M output tokens |
| gpt-4o-mini-2024-07-18 | \$0.150 / 1M input tokens          | \$0.075 / 1M input tokens  |
|                        | \$0.075 / 1M cached** input tokens |                            |
|                        | \$0.600 / 1M output tokens         | \$0.300 / 1M output tokens |

- API의 사용량을 확인
- 모델마다 설정된 토큰당 가격을 확인하여 청구될 가격을 예측할 수 있음



## 자연스러운 거짓 정보를 생성할 수 있음

- 자연스러운 문장을 생성하도록 학습된 인공지능 모델
- 학습하지 않은 정보에 대해서도 그럴듯하게 생성할 가능성이 높음





# ChatGPT 단점: 할루시네이션의 예시

LLM과 데이터 기반 서비스

ChatGPT와 챗봇

API를 이용한  
ChatGPT 사용



카이사르의 Gallic War에 마늘(garlic)을 무기로 사용한 예시가 있다고 들었어. 어떻게 마늘을 사용해 갈리아를 정복했는지 알려줘



카이사르의 "The Gallic War"에서 마늘이 어떻게 사용되었는지에 대한 기록이 있습니다. 카이사르는 이 책에서 갈리아 전쟁에 대한 기록을 남겼는데, 그는 마늘을 이용해 갈리아 지역을 정복했습니다.



카이사르는 갈리아를 침공할 때 갈리아의 부족들이 자신들의 요리에 마늘을 사용하는 것을 알아냈습니다. 그리고 그는 이를 이용해 부족들을 교란시켰습니다. 카이사르는 병사들에게 마늘을 배급하고, 그들이 갈리아의 마을로 접근할 때 마늘 냄새를 내면서 적들의 집중력을 약화시키고 방어를 무너뜨리는 전술을 사용했습니다. 이를 통해 로마군은 갈리아 부족들을 쉽게 이길 수 있었습니다.

또한, 카이사르는 마늘을 사용하는 것이 로마 병사들의 건강에도 도움이 된다는 것을 알고 있었습니다. 마늘은 혈액순환과 면역력을 향상시켜주는 효과가 있기 때문입니다. 그래서 카이사르는 자신의 병사들에게 마늘을 배급하면서 건강한 상태를 유지하도록 했습니다.

결국, 마늘은 갈리아 전쟁에서 로마군이 승리하는 데 큰 역할을 했습니다. 이를 통해 카이사르는 자신의 지도력을 입증하고 로마 제국을 확장시키는데 큰 기여를 했습니다.

🔄 Regenerate response



## 정확한 정보를 미리 전달하고 모르는 부분은 생성하지 않도록 설정

- 사용자의 질문 앞에 관련 정보를 배치하여 이를 기반으로 응답하도록 설정
  - 환불 정책
  - 상품들의 정보





```
products = [
    {"name": "사과", "price": 1000, "memo": "환불 불가"},
    {"name": "바나나", "price": 2000, "memo": "눈떨림이 있는 사람에게 추천"},
]
SYSTEM_PROMPT = (
    """"You are a customer support chatbot for an online shopping mall.\n""
    + str(products)
)

chat_log = [] # 채팅 기록
chat_log.append({"role": "system", "content": SYSTEM_PROMPT})

for i in range(3):
    ...
```

You> 요즘 눈이 떨리는데 추천상품 있어?

AI> 눈이 떨리는 증상에 추천드리는 상품은 '바나나'입니다. 가격은 2000원이며, 눈 떨림이 있는 사람에게 추천되는 제품입니다. 도움이 필요하시거나 추가 질문이 있으시면 말씀해 주세요!

You> 사과가 맛이 없어서 환불받고 싶어

AI> 죄송하지만, '사과'는 환불이 불가한 제품입니다. 다른 문의 사항이나 도움이 필요하시면 언제든지 말씀해 주세요!

- 정보를 앞에 넣어두고 사용자의 질문을 전달
- 주어진 데이터 기반 응답이 가능



### 3. 프롬프트 엔지니어링



## 모델에서 올바른 출력을 얻기 위해 프롬프트를 만드는 과정

- 모델에 정확한 지침, 예시, 필요한 정보를 제공하여 품질과 정확도를 개선할 수 있음
- API에서는 웹 UI보다 상세한 설정이 가능



## 이 메시지를 해석하는 방식을 설정

1. User: 최종 사용자가 입력하는 메시지
  - 챗봇과 대화하는 고객 등이 입력한 메시지
2. System: 최상위 수준의 지침 역할
  - 일반적으로 모델이 해야 하는 작업, 응답 방법 등을 설정
3. Assistant: 모델이 생성한 것으로 해석
  - 대화 기록을 저장할 때 모델이 응답했던 내용을 의미



## 모델의 최상위 수준 지침 역할

- 보통 가장 처음에 위치하여 모델의 전체적인 지침을 담당
- 일반적으로 아래 내용들을 설정
  - 모델을 무엇을 해야 하는지
  - 어떻게 답변해야 하는지
  - 어떻게 동작하고 응답해야 하는지





## 응답에 필요한 정보를 미리 전달

```
products = [  
    {"name": "사과", "price": 1000, "memo": "환불 불가"},  
    {"name": "바나나", "price": 2000, "memo": "눈떨림이 있는 사람에게 추천"},  
]  
SYSTEM_PROMPT = (  
    """"You are a customer support chatbot for an online shopping mall.\n"""  
    + str(products)  
)  
  
chat_log = [] # 채팅 기록  
chat_log.append({"role": "system", "content": SYSTEM_PROMPT})
```

You> 요즘 눈이 떨리는데 추천상품 있어?

AI> 눈이 떨리는 증상에 추천드리는 상품은 '바나나'입니다. 가격은 2000원이며, 눈 떨림이 있는 사람에게 추천되는 제품입니다. 도움이 필요하시거나 추가 질문이 있으시면 말씀해 주세요!

You> 사과가 맛이 없어서 환불받고 싶어

AI> 죄송하지만, '사과'는 환불이 불가한 제품입니다. 다른 문의 사항이나 도움이 필요하시면 언제든지 말씀해 주세요!



## 모델이 해야 하는 작업, 응답 방법, 형식 등을 설정

```
SYSTEM_PROMPT = """너는 일본어와 한국어를 번역하는 통역가 챗봇이야.  
user가 입력한 문장을 일본어로 번역해서 출력하면 되고 번역문 앞뒤의 설명은 생략하고 바로 번역문을 응답해야 해.  
"""
```

```
chat_log.append({"role": "system", "content": SYSTEM_PROMPT})
```

You> 안녕하세요

AI> こんにちは

You> 프롬프트 엔지니어링은 정말 어렵군요

AI> プロンプトエンジニアリングは本当に難しいですね。



## 설명하는 대상을 설정하여 대상에게 맞는 어투로 설명

“너는 초등학생들을 가르치는 코딩 교사야. 모든 답변은 초등학생들이 이해할 수 있도록 쉽게 설명해야 해.”

You> 변수가 무엇인가요?

AI> 변수는 컴퓨터 프로그래밍에서 정보를 담는 그릇 같은 거예요. 우리가 변수를 사용하면 어떤 값을 저장해두고 필요할 때 꺼내서 쓸 수 있죠.

예를 들어, 만약 우리가 “사과의 개수”를 저장하고 싶다면, “사과”라는 변수를 만들고 거기에 숫자를 넣는 거예요.

```
사과 = 5
```

이렇게 하면 “사과”라는 변수가 5라는 값을 가지고 있게 돼요. 나중에 “사과”가 몇 개인지 알고 싶을 때는 언제든지 꺼내서 사용할 수 있죠!

변수의 이름은 우리가 원하는 대로 지을 수 있는데, 너무 긴 이름이나 특이한 문자는 피하는 게 좋아요. 예를 들면, “apple\_count” 같은 이름이 적당하죠.

그래서 변수를 사용하면 컴퓨터와 대화할 때 쉽게 정보를 관리할 수 있어요!

“너는 성인들을 가르치는 코딩 교사야. 답변이 너무 유치하거나 성인에게 어울리지 않는다면 안돼.”

You> 변수가 무엇인가요?

AI> 변수는 프로그래밍에서 데이터를 저장하고 관리하는 기본 단위입니다. 쉽게 말해, 변수를 사용하면 특정 데이터를 기억하고 필요할 때 불러와 사용할 수 있습니다. 변수를 정의할 때는 보통 선언 구문을 사용하며, 변수에 할당된 값은 나중에 변경하거나 참조할 수 있습니다.

다음은 변수가 갖는 주요 특성입니다:

1. 이름: 변수를 식별하는 데 사용되는 고유한 이름입니다. 알파벳, 숫자, 언더스코어(\_)로 구성할 수 있으며, 숫자로 시작할 수는 없습니다.
2. 값: 변수에 저장된 데이터로, 정수, 실수, 문자열 등 다양한 형태를 가질 수 있습니다.
3. 유형: 프로그래밍 언어에 따라 변수는 특정 데이터 유형(예: int, float, string 등)을 가집니다. 이는 변수가 무엇을 저장할 수 있는지를 정의합니다.

예를 들어 파이썬에서는 다음과 같이 변수를 사용할 수 있습니다:

```
age = 30          # 정수형 변수
name = "Alice"    # 문자열 변수
height = 5.5      # 실수형 변수
```

이렇게 변수를 사용하면 프로그래밍 로직을 더 깔끔하고 유연하게 구성할 수 있습니다.





## 금지된 답변 등을 설정

### SYSTEM 프롬프트

너는 쇼핑몰의 고객센터 챗봇이야. 아래와 같은 답변은 절대 금지되어 있다:

- 개인정보를 요구하는 답변
- 상품의 가격을 알려주는 답변
- 손님을 비방하는 답변

이런 답변들은 절대 금지되어 있으며, 죄송하지만 이런 질문에 대한 답변은 드릴 수 없다고 안내해야 해.

You> 저 치마의 가격은 얼마야?

AI> 죄송하지만 해당 상품의 가격에 대한 정보는 제공해 드릴 수 없습니다. 추가적인 도움이 필요하시면 다른 질문을 해 주시면 감사하겠습니다.

### 금지해야 하는 내용들의 예시

- 유저에게 위험한 답변들
- 손님에게 부정확한 정보를 줄 수 있는 내용
- 직접 응대가 필요한 내용
- 정답을 직접 알려달라는 학생의 질문





## 모델이 생성한 내용으로 취급됨

- 가장 일반적인 상황은 이전에 모델이 생성한 응답을 표시함
- 대화 내역을 기록할 때 모델의 답변과 유저의 입력을 구분할 때 사용
- 모델에게 요청에 어떻게 응답해야 하는지에 대한 예시를 제공할 수도 있음
  - 예시를 제공하는 기법을 few-shot learning이라고 함



## 모델이 생성한 응답을 기록을 추적하는 용도

You> 안녕하세요.  
AI> 안녕하세요! 어떻게 도와드릴까요?  
You> 저의 이름은 엘리스입니다.  
AI> 안녕하세요, 엘리스님! 반갑습니다. 어떤 이야기를 나누고 싶으신가요?  
You> 저의 이름이 뭐였죠?  
AI> 당신의 이름은 엘리스입니다! 어떻게 더 도와드릴까요?

```
[
  {
    "content": "안녕하세요.",
    "role": "user"
  },
  {
    "content": "안녕하세요! 어떻게 도와드릴까요?",
    "role": "assistant"
  },
  {
    "content": "저의 이름은 엘리스입니다.",
    "role": "user"
  },
  {
    "content": "안녕하세요, 엘리스님! 반갑습니다. 어떤 이야기를 나누고 싶으신가요?",
    "role": "assistant"
  },
  {
    "content": "저의 이름이 뭐였죠?",
    "role": "user"
  }
]
```



## 대화 내역을 저장하고 불러와서 대화를 이어갈 수 있음

You> 안녕하세요.  
AI> 안녕하세요! 어떻게 도와드릴까요?  
You> 저의 이름은 엘리스입니다.  
AI> 안녕하세요, 엘리스님! 반갑습니다. 어떤 이야기를 나누고 싶으신가요?

3일전 대화 내용 (파일로 저장)

You> 저의 이름이 뭐였죠?  
AI> 당신의 이름은 엘리스입니다! 어떻게 더 도와드릴까요?

오늘 대화 내용

```
[
  {
    "content": "안녕하세요.",
    "role": "user"
  },
  {
    "content": "안녕하세요! 어떻게 도와드릴까요?",
    "role": "assistant"
  },
  {
    "content": "저의 이름은 엘리스입니다.",
    "role": "user"
  },
  {
    "content": "안녕하세요, 엘리스님! 반갑습니다. 어떤 이야기를 나누고 싶으신가요?",
    "role": "assistant"
  },
  {
    "content": "저의 이름이 뭐였죠?",
    "role": "user"
  }
]
```



## 가상의 내역을 만들어 대화의 예시로 전달하여 원하는 방식에 가깝도록 출력 (few-shot learning)

```
chat_log = [  
    {"content": "너는 끝말잇기 챗봇이야.\n", "role": "system"},  
    {"content": "라면", "role": "user"},  
    {"content": "면사포", "role": "assistant"},  
]
```

You> 빨대  
AI> 대나무

- 실제로는 하지 않은 대화 내역을 추가
- 이를 기반으로 원하는 응답을 하도록 유도



| MODEL                               | DESCRIPTION                                                                                                                                                                                                       | CONTEXT WINDOW | MAX OUTPUT TOKENS | TRAINING DATA  |
|-------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------|-------------------|----------------|
| <code>gpt-4o-mini</code>            | <b>GPT-4o-mini:</b> Our affordable and intelligent small model for fast, lightweight tasks. GPT-4o mini is cheaper and more capable than GPT-3.5 Turbo. Currently points to <code>gpt-4o-mini-2024-07-18</code> . | 128,000 tokens | 16,384 tokens     | Up to Oct 2023 |
| <code>gpt-4o-mini-2024-07-18</code> | <code>gpt-4o-mini</code> currently points to this version.                                                                                                                                                        | 128,000 tokens | 16,384 tokens     | Up to Oct 2023 |

- Context window: 한번의 요청으로 사용할 수 있는 총 토큰 수
  - 입력 토큰과 모델의 출력 토큰을 모두 더한 수
  - GPT-4o mini의 경우 128,000개로 제한 (24년 10월 기준)
- Max output tokens: 모델이 한번에 생성할 수 있는 토큰의 수