

LangChain 데이터 분석

02 다양한 데이터 수집 및 분석

목차 02 다양한 데이터 수집 및 분석

1. PDF, Word, PPT 문서 데이터 수집 및 분석
2. 웹 데이터 수집 및 분석
3. 데이터 임베딩 및 저장

1. PDF, Word, PPT 문서 데이터 수집 및 분석



형식에 따라 처리 방식이 다름

- 다양한 문서 형식에서 텍스트 추출 필요
- 각 형식별 전용 라이브러리 사용
- LangChain과 연동하여 임베딩, 질의응답 구현 가능





데이터 형식에 따라 Document Loader 사용

	설명
PyPDFLoader	PDF 문서 내 텍스트 추출
Unstructured WordDocumentLoader	Word 파일 텍스트 추출
Unstructured PowerPointLoader	PPT 파일 텍스트 추출

- LangChain Document Loaders는 문서별 특화된 텍스트 추출 기능 제공
- `load()` 메서드는 문서 내용이 포함된 리스트를 반환
- 반환된 각 요소는 LangChain 문서 객체
- 텍스트 접근은 `page_content` 프로퍼티 사용



PyPDFLoader

	설명
PyPDFLoader	PDF 문서 내 텍스트 추출
Unstructured WordDocumentLoader	Word 파일 텍스트 추출
Unstructured PowerPointLoader	PPT 파일 텍스트 추출

- 페이지 단위로 텍스트를 분리해 로드
- 표, 단락 등 레이아웃을 비교적 잘 유지
- PDF에서 내용 기반 검색, 요약, 질의응답 등에 적합

```
from langchain_community.document_loaders import PyPDFLoader

loader = PyPDFLoader("sample.pdf")
documents = loader.load()

for doc in documents:
    print(doc.page_content)
```



UnstructuredWordDocumentLoader

	설명
PyPDFLoader	PDF 문서 내 텍스트 추출
UnstructuredWordDocumentLoader	Word 파일 텍스트 추출
UnstructuredPowerPointLoader	PPT 파일 텍스트 추출

- 문서 내 모든 문단 텍스트를 추출
- 서식, 이미지 등은 제외하고 순수 텍스트 중심
- 보고서, 문서 기반 자연어 처리, 분석에 활용

```
from langchain_community.document_loaders import UnstructuredWordDocumentLoader

loader = UnstructuredWordDocumentLoader("sample.docx")

documents = loader.load()

for doc in documents:
    print(doc.page_content)
```



UnstructuredWordDocumentLoader

	설명
PyPDFLoader	PDF 문서 내 텍스트 추출
UnstructuredWordDocumentLoader	Word 파일 텍스트 추출
UnstructuredPowerPointLoader	PPT 파일 텍스트 추출

- 각 슬라이드 내 텍스트 박스, 도형 텍스트 추출
- 이미지, 애니메이션, 비디오 등 비텍스트 요소는 제외
- 발표자료 분석, 요약, 슬라이드 내용 검색 등에 적합

```
from langchain_community.document_loaders import UnstructuredPowerPointLoader

loader = UnstructuredPowerPointLoader("sample.pptx")
documents = loader.load()

for doc in documents:
    print(doc.page_content)
```

2. 웹 데이터 수집 및 분석




웹 데이터: 방대한 정보의 원천과 수집 방법

- 웹은 전 세계 수많은 웹사이트에서 생성되는 방대한 양의 텍스트, 이미지, 영상 등의 데이터가 존재하는 정보의 보고

• 데이터 수집 기법

- 크롤링(Crawling) : 인터넷에 존재하는 웹 페이지를 자동으로 방문하며 데이터를 수집
- 스크래핑(Scraping) : 방문한 웹 페이지에서 원하는 특정 데이터만 추출

→ LangChain은 Agent와 Tool 구조를 통해 크롤링과 스크래핑 작업을 자동화하고, 수집된 데이터를 자연어 처리 워크플로우와 연결하는 기능을 제공





UnstructuredURLLoader

- urls : 스크래핑할 웹 페이지 주소 (리스트)
 - 다수의 URL 사용 가능
- load() : 페이지 내용을 크롤링 및 텍스트 추출
- documents : 문서 리스트
 - page_content 프로퍼티로 텍스트에 접근 가능

```
from langchain.document_loaders import UnstructuredURLLoader

urls = ["https://example.com"]

loader = UnstructuredURLLoader(urls=urls)

documents = loader.load()

for doc in documents:
    print(doc.page_content)
```



Agent와 Tool로 실시간 웹 데이터 활용하기

• Agent 역할

- 사용자의 자연어 질문을 이해
- 필요한 정보를 얻기 위해 적절한 웹 검색이나 API 호출 도구를 선택해 실행

• Tool 역할

- 웹 검색, API 요청, 데이터 처리 등 실제 작업 수행

• 활용 사례

- 최신 뉴스 헤드라인 자동 검색 및 요약
- 주가, 날씨, 환율 등의 실시간 정보 제공

→ 복잡한 다단계 작업도 자동화 가능


→ 최신 데이터를 실시간 반영할 수 있음



3. 데이터 임베딩 및 저장

임베딩(Embedding)이란

- 자연어 문장을 컴퓨터가 이해할 수 있도록 고차원 수치 벡터로 변환하는 과정
- 의미가 유사한 문장일수록 임베딩 벡터 간의 **거리(유사도)**가 가까워짐
- LangChain에서는 임베딩 벡터를 벡터 DB에 저장해 검색 기반 질의응답에 활용



유사한 임베딩 벡터

사과를 구매한 고객



사과를 산 사람



LangChain으로 임베딩 벡터 생성하기

```
# OpenAI Embeddings 사용 예시
from langchain_openai import OpenAIEmbeddings

embeddings = OpenAIEmbeddings(
    model="text-embedding-3-large")

input_text = "The meaning of life is 42"
vector = embeddings.embed_query("hello")
print(vector[:3])
```

result :

```
[-0.024603435769677162, -0.007543657906353474, 0.0039630369283258915]
```

- LangChain은 다양한 임베딩 모델을 지원 (OpenAI, HuggingFace 등)
- `OpenAIEmbeddings`로 OpenAI API 기반 임베딩 모델을 불러옴
- `vector`
 - "hello"라는 짧은 문장을 임베딩 벡터로 변환
 - 보통 1000~1500차원 정도의 실수 리스트
 - 텍스트의 의미를 수치화한 표현
- 벡터의 앞 3개 원소만 출력
 - "hello"의 의미를 벡터 공간에서 나타내는 좌표 값 일부



FAISS를 활용한 벡터 검색 준비

```
from langchain_community.vectorstores import FAISS
```

```
vectorstore = FAISS.from_texts(texts, embedding=embeddings)
```

```
vectorstore.save_local("faiss_index") # 저장
```

```
# 나중에 다시 불러올 때
```

```
# FAISS.load_local("faiss_index", embeddings)
```

- 생성된 벡터를 **FAISS** 같은 벡터 DB에 저장하면,
나중에 유사한 질문에 대해 빠르게 관련 데이터를 검색 가능
- LangChain은 벡터 DB 연결도 모듈화되어 있음

