

LLM and data-driven services

LLM과 데이터 기반 서비스

02 데이터 기반 서비스

목차 데이터 기반 서비스

1. 데이터 기반 서비스
2. Pandas를 이용한 데이터 추출
3. SQL을 통한 데이터 추출
4. 웹 크롤링

1. 데이터 기반 서비스



“이 내용을 요약해줘”와 같은 프롬프트로 간단히 구현 가능

지난 7일

이 대화 요약 요청

HTML URL 추출 방법

웹 크롤링 스크립트 작성

웹페이지 헤더 분석

<ChatGPT의 대화 내역 한 줄 요약>

- 길게 주어진 글에서 핵심 내용을 추출하는 챗봇은 쉽게 제작할 수 있음
- 간단한 프롬프트를 통해서도 구현 가능

세상의 모든 데이터를 학습할 수는 없음

우리 매장에서 취급하는 과일은 어떤 종류가 있어?

저는 취급하는 과일에 종류에 대한 정보를 가지고 있지 않아서 종류를 알 수 없어요.

- 서비스에 맞는 정보를 제공하기 위해서는 별도의 데이터를 제공해야 함



모델이 학습한 데이터는 최신 데이터가 아님

MODEL	DESCRIPTION	CONTEXT WINDOW	MAX OUTPUT TOKENS	TRAINING DATA
gpt-4o	GPT-4o: Our high-intelligence flagship model for complex, multi-step tasks. GPT-4o is cheaper and faster than GPT-4 Turbo. Currently points to gpt-4o-2024-08-06.	128,000 tokens	16,384 tokens	Up to Oct 2023
gpt-4o-2024-08-06	Latest snapshot that supports Structured Outputs . gpt-4o currently points to this version.	128,000 tokens	16,384 tokens	Up to Oct 2023
gpt-4o-2024-05-13	Original gpt-4o snapshot from May 13, 2024.	128,000 tokens	4,096 tokens	Up to Oct 2023
chatgpt-4o-latest	Dynamic model continuously updated to the current version of GPT-4o in ChatGPT. Intended for research and evaluation [1].	128,000 tokens	16,384 tokens	Up to Oct 2023

→ 이후의 내용은 입력되지 않음

- 이후의 최신 내용에 대해서는 응답하지 않거나 잘못된 정보를 생성할 수 있음



관련된 데이터를 기반으로 동작하는 서비스

매장에서 취급하는 상품 목록:

○○○

□□□

우리 매장에서 취급하는 과일은 어떤 종류가 있어?

매장에서 취급하는 과일은 ○○○와 □□□가 있어요.

- 서비스에 맞는 정보를 제공하기 위해서는 별도의 데이터가 필요



직접 데이터를 입력하여 전달

```
products = [
    {"name": "사과", "price": 1000, "memo": "환불 불가"},
    {"name": "바나나", "price": 2000, "memo": "눈떨림이 있는 사람에게 추천"},
]
SYSTEM_PROMPT = (
    """You are a customer support chatbot for an online shopping mall.\n"""
    + str(products)
)

chat_log = [] # 채팅 기록
chat_log.append({"role": "system", "content": SYSTEM_PROMPT})

for i in range(3):
    ...
```




실제로 서비스 하려면 데이터로부터 해당 프롬프트를 생성

```
products = [  
    {"name": "사과", "price": 1000, "memo": "환불 불가"},  
    {"name": "바나나", "price": 2000, "memo": "눈떨림이 있는 사람에게 추천"},  
]  
SYSTEM_PROMPT = (  
    ""You are a customer support chatbot for an online shopping mall.\n""  
    + str(products)  
)  
  
chat_log = [] # 채팅 기록  
chat_log.append({"role": "system", "content": SYSTEM_PROMPT})  
  
for i in range(3):  
    ...
```

매장취급목록.csv

실제 데이터 파일

	A	B	C
1	name	price	memo
2	사과	1000	환불 불가
3	바나나	2000	눈떨림이 있는 사람에게 추천
4	귤	6000	겨울에만 판매

데이터 조작 및 분석을 위한 파이썬 라이브러리



- 파이썬 코드를 통해 데이터를 전처리하고 분석함
- 다양한 분석 관련 기능을 사용할 수 있음



간단한 데이터는 파일을 읽어 프롬프트에 전달

```
import pandas as pd
```

```
df = pd.read_csv("취급목록.csv")  
data = df.to_records(index=False)  
print(data)
```

```
# [('사과', 1000, '환불 불가')  
#  ('바나나', 2000, '눈떨림이 있는 사람에게 추천')  
#  ('귤', 6000, '겨울에만 판매')]
```

```
products = [  
    {"name": "사과", "price": 1000, "memo": "환불 불가"},  
    {"name": "바나나", "price": 2000, "memo": "눈떨림이 있는 사람에게 추천"},  
]  
  
SYSTEM_PROMPT = (  
    """You are a customer support chatbot for an online shopping mall.\n"""  
    + str(products)  
)  
  
chat_log = [] # 채팅 기록  
chat_log.append({"role": "system", "content": SYSTEM_PROMPT})  
  
for i in range(3):  
    ...
```




상품 목록 예시

LLM과 데이터 기반 서비스

데이터 기반 서비스

데이터 기반 서비스

name	stock	price	description	allergy	notice
다이어트 샐러드A	10	7000	완제품 샐러드, 다이어트 식품	아몬드가 포함되어 견과류 알러지 주의	
다이어트 샐러드B	5	9000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 연어를 추가		
다이어트 샐러드C	0	8000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 닭가슴살을 추가		
우유	20	1500	신선한 우유, 1리터	유당 불내증 주의	
커피우유	15	2500	커피와 우유의 조화, 1리터	유당 불내증 주의	
아몬드 밀크	12	3000	아몬드로 만든 대체 우유, 1리터	견과류 알러지 주의	
오트 밀크	10	3200	귀리로 만든 대체 우유, 1리터		
엘리스 콜라	25	1200	탄산음료, 355ml		
엘리스 콜라 제로	30	1300	제로 칼로리 탄산음료, 355ml, 제로 음료		당분 함유 없음
라떼	10	4500	커피와 우유를 섞은 음료, 500ml	유당 불내증 주의	
카푸치노	8	5000	커피와 스팀 밀크, 500ml	유당 불내증 주의	
녹차 라떼	6	4800	녹차와 우유를 섞은 음료, 500ml	유당 불내증 주의	
초코 프로틴바	15	3500	고단백 초콜릿 바, 50g, 다이어트 식품	견과류 알러지 주의	단백질 보충 간식
바나나 프로틴쉐이크	10	5500	바나나 맛 단백질 쉐이크, 350ml, 다이어트 식품	유당 불내증 주의	단백질 보충 음료
닭가슴살 스낵	20	4000	고단백 저지방 닭가슴살 스낵, 50g, 다이어트 식품		다이어트 간식
매운맛 김부각	30	2500	매콤한 김부각 스낵, 50g		
프로바이오틱 요거트	18	2000	프로바이오틱스 함유 요거트, 150ml	유당 불내증 주의	장 건강 도움
크랜베리 아몬드 그래놀라	12	6000	크랜베리와 아몬드가 들어간 그래놀라, 300g	견과류 알러지 주의	아침 식사 대용

product_list.csv

- 31개 제품의 정보들이 기록된 csv파일
- 이 파일의 내용을 기반으로 답변하는 챗봇을 제작



파일을 읽어 텍스트 형태로 프롬프트에 첨부

```
# 상품 정보를 읽어옵니다.
df_product_list = pd.read_csv("product_list.csv")

chat_log = [
    {
        "role": "system",
        "content": "너는 제품에 대한 정보를 제공하는 챗봇이야. "
        + "다음 제품목록을 기반으로 정보를 제공해줘. "
        + "알러지 주의사항이 있는 제품은 반드시 안내해야 해. "
        + "\n제품목록:\n"
        + str(df_product_list.to_records(index=False)),
    }
]

prompt = input("You> ")
chat_log.append({"role": "user", "content": prompt})

response = get_response(chat_log)
print("AI>", response.content)
```

You> 다이어트 하고 있는데, 식사 대체할 제품들 3개만 추천해줘.

AI> 다이어트를 하신다면 다음의 제품을 추천합니다:

1. ****다이어트 샐러드A****

- 가격: 7,000원
- 설명: 완제품 샐러드, 다이어트 식품
- 알러지 주의: 아몬드가 포함되어 견과류 알러지 주의

2. ****바나나 프로틴쉐이크****

- 가격: 5,500원
- 설명: 바나나 맛 단백질 쉐이크, 350ml, 다이어트 식품
- 알러지 주의: 유당 불내증 주의

3. ****코코아 프로틴 쉐이크****

- 가격: 6,000원
- 설명: 코코아 맛 단백질 쉐이크, 350ml, 다이어트 식품
- 알러지 주의: 유당 불내증 주의

이 제품들은 다이어트를 도와주며 맛도 좋으니 고려해보세요!



실시간으로 데이터 파일을 업데이트할 수 있음

name	stock	price	description	allergy
다이어트 샐러드A	10	7000	완제품 샐러드, 다이어트 식품	아몬드가 포함되어 견과류 알러지 주의
다이어트 샐러드B	5	9000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 연어를 추가	
다이어트 샐러드C	0	8000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 닭가슴살을 추가	
우유	20	1500	신선한 우유, 1리터	유당 불내증 주의
커피우유	15	2500	커피와 우유의 조화, 1리터	유당 불내증 주의
아몬드 밀크	12	3000	아몬드로 만든 대체 우유, 1리터	견과류 알러지 주의
오트 밀크	10	3200	귀리로 만든 대체 우유, 1리터	

- 데이터를 수정하면 챗봇의 응답도 다르게 할 수 있음
- 새로운 제품을 추가할 수 있음
- 비전공자도 사용할 수 있는 파일 편집을 통해 업데이트 가능



지나치게 커지는 프롬프트로 인한 비용 발생

"너는 제품에 대한 정보를 제공하는 챗봇이야. 다음 제품목록을 기반으로 정보를 제공해줘. 알러지 주의사항이 있는 제품은 반드시 안내해야 해. \n제품목록:\n\n('다이어트 샐러드A', 10, 7000, '완제품 샐러드, 다이어트 식품', '아몬드'가 포함되어 견과류 알러지 주의', nan)\n('다이어트 샐러드B', 5, 9000, '완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 연어를 추가', nan, nan)\n('다이어트 샐러드C', 0, 8000, '완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 닭가슴살을 추가', nan, nan)\n('우유', 20, 1500, '신선한 우유, 1리터', '유당 불내증 주의', nan)\n('커피우유', 15, 2500, '커피와 우유의 조화, 1리터', '유당 불내증 주의', nan)\n('아몬드 밀크', 12, 3000, '아몬드로 만든 대체 우유, 1리터', '견과류 알러지 주의', nan)\n('오트 밀크', 10, 3200, '귀리로 만든 대체 우유, 1리터', nan, nan)\n('엘리스 콜라', 25, 1200, '탄산음료, 355ml', nan, nan)\n('엘리스 콜라 제로', 30, 1300, '제로 칼로리 탄산음료, 355ml, 제로 음료', nan, '당분 함유 없음')\n('라떼', 10, 4500, '커피와 우유를 섞은 음료, 500ml', '유당 불내증 주의', nan)\n('카푸치노', 8, 5000, '커피와 스팀 밀크, 500ml', '유당 불내증 주의', nan)\n('녹차 라떼', 6, 4800, '녹차와 우유를 섞은 음료, 500ml', '유당 불내증 주의', nan)\n('초코 프로틴바', 15, 3500, '고단백 초콜릿 바, 50g, 다이어트 식품', '견과류 알러지 주의', '단백질 보충 간식')\n('바나나 프로틴쉐이크', 10, 5500, '바나나 맛 단백질 셰이크, 350ml, 다이어트 식품', '유당 불내증 주의', '단백질 보충 음료')\n('닭가슴살 스낵', 20, 4000, '고단백 저지방 닭가슴살 스낵, 50g, 다이어트 식품', nan, '다이어트 간식')\n('매운맛 김부각', 30, 2500, '매콤한 김부각 스낵, 50g', nan, nan)\n('프로바이오틱 요거트', 18, 2000, '프로바이오틱스 함유 요거트, 150ml', '유당 불내증 주의', '장 건강 도움')\n('크랜베리 아몬드 그레놀라', 12, 6000, '크랜베리와 아몬드가 들어간 그레놀라, 300g', '견과류 알러지 주의', '아침 식사 대용')\n('매콤한 비건 버거', 8, 7800, '채식주의자를 위한 매콤한 비건 버거, 다이어트 식품', '견과류 알러지 주의', '비건 제품')\n('말차 쿠키', 15, 4000, '말차 맛 쿠키, 150g', '글루텐 알러지 주의', nan)\n('코코넛 워터', 20, 3000, '천연 코코넛 워터, 330ml', nan, '수분 보충 음료')\n('아보카도 샐러드', 7, 8500, '아보카도와 다양한 채소가 포함된 샐러드, 다이어트 식품', '견과류 알러지 주의', '단백질 보충 간식')\n('아보카도 우유', 10, 2200, '아보카도와 우유를 섞은 음료, 500ml', '유당 불내증 주의', nan)

시스템 프롬프트
(약 2200문자, 1446 토큰)

코로나 감염병과 관련된 데이터

	Country/Region	Confirmed	Deaths	Recovered	Active	New cases	New deaths	New recovered	Deaths / 100 Cases	Recovered / 100 Cases	Deaths / 100 Recovered	Confirmed last week	1 week change	1 week % increase
0	Afghanistan	36263	1269	25198	9796	106	10	18	3.50	69.49	5.04	35526	737	2.07
1	Albania	4880	144	2745	1991	117	6	63	2.95	56.25	5.25	4171	709	17.00
2	Algeria	27973	1163	18837	7973	616	8	749	4.16	67.34	6.17	23691	4282	18.07
3	Andorra	907	52	803	52	10	0	0	5.73	88.53	6.48	884	23	2.60
4	Angola	950	41	242	667	18	1	0	4.32	25.47	16.94	749	201	26.84
5	Antigua and Barbuda	86	3	65	18	4	0	5	3.49	75.58	4.62	76	10	13.16
6	Argentina	167416	3059	72575	91782	4890	120	2057	1.83	43.35	4.21	130774	36642	28.02
7	Armenia	37390	711	26665	10014	73	6	187	1.90	71.32	2.67	34981	2409	6.89
8	Australia	15303	167	9311	5825	368	6	137	1.09	60.84	1.79	12428	2875	23.13
9	Austria	20558	713	18246	1599	86	1	37	3.47	88.75	3.91	19743	815	4.13
10	Azerbaijan	30446	423	23242	6781	396	6	558	1.39	76.34	1.82	27890	2556	9.16

- 15개 칼럼, 189줄의 데이터



데이터가 더 큰 경우에는 사용할 수 없음

	Country/Region	Confirmed	Deaths	Recovered	Active	New cases	New deaths	New recovered	Deaths / 100 Cases	Recovered / 100 Cases	Deaths / 100 Recovered	Confirmed last week	1 week change	1 week % increase
0	Afghanistan	36263	1269	25198	9796	106	10	18	3.50	69.49	5.04	35526	737	2.07
1	Albania	4880	144	2745	1991	117	6	63	2.95	56.25	5.25	4171	709	17.00
2	Algeria	27973	1163	18837	7973	616	8	749	4.16	67.34	6.17	23691	4282	18.07
3	Andorra	907	52	803	52	10	0	0	5.73	88.53	6.48	884	23	2.60
4	Angola	950	41	242	667	18	1	0	4.32	25.47	16.94	749	201	26.84
5	Antigua and Barbuda	86	3	65	18	4	0	5	3.49	75.58	4.62	76	10	13.16
6	Argentina	167416	3059	72575	91782	4890	120	2057	1.83	43.35	4.21	130774	36642	28.02
7	Armenia	37390	711	26665	10014	73	6	187	1.90	71.32	2.67	34981	2409	6.89
8	Australia	15303	167	9311	5825	368	6	137	1.09	60.84	1.79	12428	2875	23.13
9	Austria	20558	713	18246	1599	86	1	37	3.47	88.75	3.91	19743	815	4.13
10	Azerbaijan	30446	423	23242	6781	396	6	558	1.39	76.34	1.82	27890	2556	9.16



Country/Region,Confirmed,Deaths,Recovered,Active,New cases,New deaths,New recovered,Deaths / 100 Cases,Recovered / 100 Cases,Deaths / 100 Recovered,Confirmed last week,1 week change,1 week % increase,WHO Region
Afghanistan,36263,1269,25198,9796,106,10,18,3.5,69.49,5.04,35526,737,2.07,Eastern Mediterranean
Albania,4880,144,2745,1991,117,6,63,2.95,56.25,5.25,4171,709,17.0,Europe
Algeria,27973,1163,18837,7973,616,8,749,4.16,67.34,6.17,23691,4282,18.07,Africa
Andorra,907,52,803,52,10,0,0,5.73,88.53,6.48,884,23,2.6,Europe
Angola,950,41,242,667,18,1,0,4.32,25.47,16.94,749,201,26.84,Africa
Antigua and Barbuda,86,3,65,18,4,0,5,3.49,75.58,4.62,76,10,13.16,Americas
Argentina,167416,3059,72575,91782,4890,120,2057,1.83,43.35,4.21,130774,36642,28.02,Americas
Armenia,37390,711,26665,10014,73,6,187,1.9,71.32,2.67,34981,2409,6.89,Europe
Australia,15303,167,9311,5825,368,6,137,1.09,60.84,1.79,12428,2875,23.13,Western Pacific
Austria,20558,713,18246,1599,86,1,37,3.47,88.75,3.91,19743,815,4.13,Europe
Azerbaijan,30446,423,23242,6781,396,6,558,1.39,76.34,1.82,27890,2556,9.16,Europe
Bahamas,382,11,91,280,40,0,0,2.88,23.82,12.09,174,208,119.54,Americas

약 15000 글자

- 모든 데이터를 텍스트로 전달하면 많은 토큰을 차지
- 제한에 걸리거나 많이 비용이 발생할 수 있음



데이터에 길이 제한을 통해 해결?

```
Country/Region,Confirmed,Deaths,Recovered,Active,New cases,New deaths,New recovered,Deaths / 100 Cases,Recovered / 100 Cases,Deaths / 100 Recovered,Confirmed last week,1 week change,1 week % increase,WHO Region
Afghanistan,36263,1269,25198,9796,106,10,18,3.5,69.49,5.04,35526,737,2.07,Eastern Mediterranean
Albania,4880,144,2745,1991,117,6,63,2.95,56.25,5.25,4171,709,17.0,Europe
Algeria,27973,1163,18837,7973,616,8,749,4.16,67.34,6.17,23691,4282,18.07,Africa
Andorra,907,52,803,52,10,0,0,5.73,88.53,6.48,884,23,2.6,Europe
Angola,950,41,242,667,18,1,0,4.32,25.47,16.94,749,201,26.84,Africa
Antigua and Barbuda,86,3,65,18,4,0,5,3.49,75.58,4.62,76,10,13.16,Americas
```

앞에서부터 1000 글자만 사용

- 잘린 데이터에 대해서는 부정확한 응답이 발생

다이어트와 관련된 제품들만 추출하여 프롬프트에 입력

name	stock	price	description	allergy	notice
다이어트 샐러드A	10	7000	완제품 샐러드, 다이어트 식품	아몬드가 포함되어 견과류 알러지 주의	
다이어트 샐러드B	5	9000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 연어를 추가		
다이어트 샐러드C	0	8000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 닭가슴살을 추가		
우유	20	1500	신선한 우유, 1리터	유당 불내증 주의	
커피우유	15	2500	커피와 우유의 조화, 1리터	유당 불내증 주의	
아몬드 밀크	12	3000	아몬드로 만든 대체 우유, 1리터	견과류 알러지 주의	
오트 밀크	10	3200	귀리로 만든 대체 우유, 1리터		
엘리스 콜라	25	1200	탄산음료, 355ml		
엘리스 콜라 제로	30	1300	제로 칼로리 탄산음료, 355ml, 제로 음료		당분 함유 없음
라떼	10	4500	커피와 우유를 섞은 음료, 500ml	유당 불내증 주의	
카푸치노	8	5000	커피와 스팀 밀크, 500ml	유당 불내증 주의	
녹차 라떼	6	4800	녹차와 우유를 섞은 음료, 500ml	유당 불내증 주의	
초코 프로틴바	15	3500	고단백 초콜릿 바, 50g, 다이어트 식품	견과류 알러지 주의	단백질 보충 간식
바나나 프로틴쉐이크	10	5500	바나나 맛 단백질 쉐이크, 350ml, 다이어트 식품	유당 불내증 주의	단백질 보충 음료
닭가슴살 스낵	20	4000	고단백 저지방 닭가슴살 스낵, 50g, 다이어트 식품		다이어트 간식
매운맛 김부각	30	2500	매콤한 김부각 스낵, 50g		
프로바이오틱 요거트	18	2000	프로바이오틱스 함유 요거트, 150ml	유당 불내증 주의	장 건강 도움
크랜베리 아몬드 그래놀라	12	6000	크랜베리와 아몬드가 들어간 그래놀라, 300g	견과류 알러지 주의	아침 식사 대용

설명에 "다이어트"가 들어간 제품들

다이어트와 관련된 제품들만 추출하여 프롬프트에 입력

name	stock	price	description	allergy	notice
다이어트 샐러드A	10	7000	완제품 샐러드, 다이어트 식품	아몬드가 포함되어 견과류 알러지 주의	
다이어트 샐러드B	5	9000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 연어를 추가		
다이어트 샐러드C	0	8000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 닭가슴살을 추가		
초코 프로틴바	15	3500	고단백 초콜릿 바, 50g, 다이어트 식품	견과류 알러지 주의	단백질 보충 간식
바나나 프로틴쉐이크	10	5500	바나나 맛 단백질 쉐이크, 350ml, 다이어트 식품	유당 불내증 주의	단백질 보충 음료
닭가슴살 스낵	20	4000	고단백 저지방 닭가슴살 스낵, 50g, 다이어트 식품		다이어트 간식

- 사용자에게 응답하는데 필요한 정보만 추출하여 입력
- 응답의 정확함을 유지하면서 필요한 토큰을 줄임



1. 만약 사용자의 요청에 “다이어트” 라는 단어가 있다면

You> **다이어트** 하고 있는데, 식사 대체할 제품들 3개만 추천해줘.

사용자의 요청

2. 데이터에서 제품 설명에 “다이어트” 가 포함된 제품만 추출

name	stock	price	description
다이어트 샐러드A	10	7000	완제품 샐러드, 다이어트 식품
다이어트 샐러드B	5	9000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 연어를 추가
다이어트 샐러드C	0	8000	완제품 샐러드, 다이어트 식품, 다이어트 샐러드A에서 아몬드 대신 닭가슴살을 추가
우유	20	1500	신선한 우유, 1리터
커피우유	15	2500	커피와 우유의 조화, 1리터
아몬드 밀크	12	3000	아몬드로 만든 대체 우유, 1리터
오트 밀크	10	3200	귀리로 만든 대체 우유, 1리터

데이터



Pandas를 통해 데이터를 선별하고 프롬프트에 전달

```
chat_log = [
    {"role": "system", "content": "너는 제품에 대한 정보를 제공하는 챗봇이야."}
]

prompt = input("You> ")
chat_log.append({"role": "user", "content": prompt})

if "다이어트" in prompt:
    chat_log.append(
        {
            "role": "system",
            "content": "다이어트 관련 상품은 다음과 같아 이를 기반으로 대답해줘: "
            # description에 다이어트라는 단어가 들어간 제품을 찾아서 출력합니다.
            + str(
                df_product_list[
                    df_product_list["description"].str.contains("다이어트")
                ].to_records(index=False)
            ),
        }
    )
```




같은 키워드도 표현 방식이 다양하게 존재

살 빼려고 하는데...
살 빼고 싶어서...
다이어트 하고 싶어서...
요즘 살찐 것 같아서...

키워드



다이어트



키워드도 다양하게 존재

살 빼려고 하는데...
살 빼고 싶어서...
다이어트 하고 싶어서...
요즘 살찐 것 같아서...

키워드



연어
샐러드
다이어트
비타민
제로음료



챗봇이 필요한 키워드를 추출하고 이 정보를 요청하는 기능

환불 절차 알려줘.



기본 프롬프트만으로 답변

다이어트 하고 있는데, 식사 대체할
제품들 3개만 추천해줘.



“다이어트” 키워드로 상품 검색 후 답변



ChatGPT에게 사용할 수 있는 함수에 대한 설명을 제공

```
def find_products(keywords: list[str]) -> list[dict]:  
    df = pd.read_csv("product_list.csv")  
    result = df[df["description"].str.contains("|".join(keywords))]  
    return result.to_dict(orient="records")
```

함수이름: find_products

상품 설명에 keywords가 들어간 상품들을 검색해서 반환하는 함수

각 키워드는 영어단어 하나

매개변수: keywords: 문자열 리스트

반환형태: 딕셔너리의 리스트



ChatGPT



함수 설명을 기반으로 호출할 함수와 매개변수를 적절하게 반환

살 빼고 싶은데, 식사 대체할
제품들 3개만 추천해줘.

다이어트를 위해서는 이런
제품들을 추천합니다!
상품A: ...



ChatGPT

find_products 함수 호출 요청
`{"keywords":["다이어트", "건강"]}`

함수 실행

```
[{  
  "name": "상품A",  
  "price": 10000,  
  "description": "다이어트용 샐러드. 견과류 있음",  
}, { ... }, { ... }]
```



호출이 필요 없는 요청에는 바로 답변

환불 절차는 어떻게 돼?


정확한 안내는 고객센터를
이용해주세요.
환불 절차는 아래와 같습니다.



ChatGPT




여러 함수를 전달하고 적절한 함수를 선택할 수 있음






다양한 방법으로 정보를 가져와 응답에 사용



데이터 베이스



파일



웹 페이지

- 데이터 베이스: SQL을 통해 DB로부터 정보를 가져옴
- 파일: 파일을 읽어 정보를 가져옴
- 웹 페이지: 웹 페이지의 내용을 크롤링하여 정보를 가져옴

2. Pandas를 이용한 데이터 추출



파이썬 함수와 관련된 용어

함수명: 함수의 이름 = get_order

```
def get_order(order_id):  
    return db.get(order_id)
```

매개변수
반환 값

매개변수: 함수에 전달되는 변수들 = order_id

- 여러가지로 표현
 - arguments
 - parameters

반환 값: 함수가 실행되고 반환하는 값



함수를 사용하는데 필요한 정보들

```
def get_order(order_id):  
    return db.get(order_id)
```

매개변수

반환 값

- order_id의 타입은?
- 이 함수가 반환하는 값의 타입은?
- 이 함수는 무엇을 하는 함수인지?



가독성을 위해 각 타입을 명시적으로 지정

매개변수 타입

```
def get_order(order_id: int) -> dict:  
    return db.get(order_id)
```

반환 타입

- order_id의 타입은?
 - int
- 이 함수가 반환하는 값의 타입은?
 - dict
- 이 함수는 무엇을 하는 함수인지?

주의: 다른 값을 입력해도 오류는 발생하지 않음

모듈, 함수, 클래스 등에 문자열의 형태로 추가하는 일종의 주석

```
def get_order(order_id: int) -> dict:
    """order_id에 해당하는 주문 정보를 반환합니다."""
    return db.get(order_id)
```

함수 설명

- order_id의 타입은?
 - int
- 이 함수가 반환하는 값의 타입은?
 - dict
- 이 함수는 무엇을 하는 함수인지?
 - order_id에 해당하는 주문 정보를 반환합니다.



단순 주석이 아니라 코드를 통해 접근할 수 있음

```
def get_order(order_id: int) -> dict:
    """order_id에 해당하는 주문 정보를 반환합니다."""

    return db.get(order_id)

print(get_order.__annotations__)
# {'order_id': <class 'int'>, 'return': <class 'dict'>}

print(get_order.__doc__)
# order_id에 해당하는 주문 정보를 반환합니다.
```



필요한 함수를 정의

```
def find_products(keywords: list[str]) -> list[dict]:  
    """제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다."""  
  
    df = pd.read_csv("product_list.csv")  
    result = df[df["description"].str.contains("|".join(keywords))]  
    return result.to_dict(orient="records")
```



필요한 함수를 정의

함수의 각종 정보를 기록

```
def find_products(keywords: list[str]) -> list[dict]:  
    """제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다."""  
  
    df = pd.read_csv("product_list.csv")  
    result = df[df["description"].str.contains("|".join(keywords))]  
    return result.to_dict(orient="records")
```

```
{  
    "name": "find_products",  
    "description": "제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다.",  
    "parameters": {  
        "type": "object",  
        "properties": {  
            "keywords": {  
                "type": "array",  
                "items": {"type": "string"},  
            },  
        },  
        "required": ["keywords"],  
        "additionalProperties": False,  
    },  
}
```



필요한 함수를 정의

함수의 이름

함수의 각종 정보를 기록

```
def find_products(keywords: list[str]) -> list[dict]:  
    """제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다."""  
  
    df = pd.read_csv("product_list.csv")  
    result = df[df["description"].str.contains("|".join(keywords))]  
    return result.to_dict(orient="records")
```

```
{  
    "name": "find_products",  
    "description": "제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다.",  
    "parameters": {  
        "type": "object",  
        "properties": {  
            "keywords": {  
                "type": "array",  
                "items": {"type": "string"},  
            },  
        },  
        "required": ["keywords"],  
        "additionalProperties": False,  
    },  
}
```

함수의 이름

- 문자열로 그대로 전달
- 함수를 직접 호출하는 것은 아니라 값을 필요는 없음
- 가독성을 위해 가급적 동일하게 설정



필요한 함수를 정의

함수의 각종 정보를 기록

```
def find_products(keywords: list[str]) -> list[dict]:  
    """제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다."""  
  
    df = pd.read_csv("product_list.csv")  
    result = df[df["description"].str.contains("|".join(keywords))]  
    return result.to_dict(orient="records")
```

함수 설명

함수 설명

- 이 함수의 용도
- 언제 이 함수를 호출해야 하는지

```
{  
    "name": "find_products",  
    "description": "제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다.",  
    "parameters": {  
        "type": "object",  
        "properties": {  
            "keywords": {  
                "type": "array",  
                "items": {"type": "string"},  
            },  
        },  
        "required": ["keywords"],  
        "additionalProperties": False,  
    },  
}
```



필요한 함수를 정의

함수의 각종 정보를 기록

```
def find_products(keywords: list[str]) -> list[dict]:  
    """제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다."""  
  
    df = pd.read_csv("product_list.csv")  
    result = df[df["description"].str.contains("|".join(keywords))]  
    return result.to_dict(orient="records")
```

매개변수

json 스키마 형식으로 전달

매개변수 목록

```
{  
  "name": "find_products",  
  "description": "제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다.",  
  "parameters": {  
    "type": "object",  
    "properties": {  
      "keywords": {  
        "type": "array",  
        "items": {"type": "string"},  
      },  
    },  
    "required": ["keywords"],  
    "additionalProperties": False,  
  },  
}
```



```
find_products_info = {
    "name": "find_products",
    "description": "제품 설명에 keywords가 포함된 제품을 찾아서 반환합니다.",
    "parameters": {
        "type": "object",
        "properties": {
            "keywords": {
                "type": "array",
                "items": {"type": "string"},
                "description": "검색할 키워드 리스트.",
            },
        },
        "required": ["keywords"],
        "additionalProperties": False,
    },
}

tools = [
    {
        "type": "function",
        "function": find_products_info,
    }
]
```

tools에 사용할 함수들 정보를 전달



create 함수에 tools를 추가로 전달하고 프롬프트를 입력

tools를 추가로 전달

```
def get_response(chat_log: list, tools: dict = None) -> ChatCompletionMessage:
    response = client.chat.completions.create(
        model="gpt-4o-mini", messages=chat_log, tools=tools
    )
    print(response.choices[0])
    return response.choices[0].message
```

[system] You are a helpful customer support assistant. Use the supplied tools to assist the user.

[user] 나 살빼려고 하는데 샐러드 추천해줘



```
print(response.choices[0])
```

```
Choice(
  finish_reason="tool_calls",
  index=0,
  logprobs=None,
  message=ChatCompletionMessage(
    content=None,
    refusal=None,
    role="assistant",
    function_call=None,
    tool_calls=[
      ChatCompletionMessageToolCall(
        id="call_vBwjNig2xfd3WChEaKe8dVPR",
        function=Function(
          arguments='{"keywords":["샐러드", "다이어트", "건강식"]}',
          name="find_products",
        ),
        type="function",
      )
    ],
  ),
)
```

호출할 tool 목록



```
response.choices[0].message.tool_calls
```

함수의 각종 정보를 기록

```
tool_calls = [  
    ChatCompletionMessageToolCall(  
        id="call_vBwjNig2xfd3WChEaKe8dVPR", 이 호출의 ID  
        function=Function( 호출에 필요한 정보들  
            arguments='{"keywords":["샐러드", "다이어트", "건강식"]}',  
            name="find_products",  
        ),  
        type="function",  
    )  
]
```

```
if response.choices[0].message.tool_calls:  
    tool_call_results = []  
    for tool_call in response.choices[0].message.tool_calls:  
        call_id = tool_call.id  
  
        if tool_call.function.name == "find_products":  
            keywords = json.loads(tool_call.function.arguments)["keywords"]  
            products = find_products(keywords)
```

받은 요청을 그대로 실행



실행 결과를 모델에 전달할 메시지 구성

```
call_result_message = {  
    "tool_call_id": call_id, 호출 ID (call_id = tool_call.id)  
    "role": "tool", 함수의 실행결과는 tool이라는 role 사용  
    "content": json.dumps(  
        {"keywords": keywords, "products": products}  
    ),  
}  
tool_call_results.append(call_result_message)
```

호출 결과

호출된 함수들의 결과를 저장할 리스트



함수들의 호출 결과를 포함하여 다시 요청

처음에 입력했던 기록

첫 응답(함수 호출을 요구한 응답)

함수들의 호출 결과

```
messages = chat_log + [response.choices[0].message] + tool_call_results
response = client.chat.completions.create(
    model="gpt-4o-mini",
    messages=messages,
    tools=tools,
)
```




스스로 키워드를 추출하여 검색하고 그 결과를 기반으로 답변

고객> 나 살빼려고 하는데 샐러드 추천해줘.

AI> 다이어트를 원하신다면 다음 샐러드를 추천드립니다:

1. ****다이어트 샐러드A****

- ****가격****: 7,000원
- ****설명****: 완제품 샐러드, 다이어트 식품
- ****알레르기****: 아몬드가 포함되어 있어 견과류 알러지 주의

2. ****다이어트 샐러드B****

- ****가격****: 9,000원
- ****설명****: 완제품 샐러드로, 다이어트 샐러드A에서 아몬드 대신 연어를 추가한 제품
- ****알레르기****: 별도 언급 없음

3. ****아보카도 샐러드****

- ****가격****: 8,500원
- ****설명****: 아보카도와 다양한 채소가 포함된 샐러드, 다이어트 식품
- ****알레르기****: 견과류 알러지 주의

이 샐러드들로 건강한 다이어트를 시작해 보세요!



함수 호출이 필요 없는 경우에는 생략

호출이 필요 없다면 None

안녕?

안녕하세요! 어떻게 도와드릴까요?

```
print(response.choices[0].message.tool_calls)
# None
```

```
if response.choices[0].message.tool_calls: ...
    # 호출 관련 처리
    response = client.chat.completions.create( ... )
```

```
return response.choices[0].message
```

첫 응답을 바로 반환

3. SQL을 통한 데이터 추출




SQL: 관계형 데이터베이스의 정보를 저장하고 처리하기 위한 프로그래밍 언어

(표로 만든 데이터)

```
SELECT * FROM tbl_users
```

SQL



관계형 데이터베이스

ID	이름
1	홍길동
2	엘리스

데이터

- DB에 데이터를 넣거나 가져올 때 사용하는 언어



데이터가 담긴 하나의 표를 테이블(Table)이라고 함

id	이름
1	홍길동
2	엘리스

고객 이름 테이블

id	이름
1	비누
2	모니터

상품 이름 테이블

id	사용자 id	상품 id	상태	날짜
1	1	2	1	24.10.21
2	1	2	2	24.10.22

주문 기록 테이블

- 테이블마다 권한을 다르게 할 수 있음



데이터가 담긴 하나의 표를 테이블(Table)이라고 함

id	이름
1	홍길동
2	엘리스

고객 이름 테이블

id	이름
1	비누
2	모니터

상품 이름 테이블

id	사용자 id	상품 id	상태	날짜
1	1	2	1	24.10.21
2	1	2	2	24.10.22

주문 기록 테이블

홍길동 이 모니터 를 주문한 기록

- 여러 테이블 간의 관계를 통해 정보를 표현
- 하나의 정보를 해석하기 위해서는 여러가지 표에서 정보를 가져와야 할 수 있음




전통적인 DB 사용 방법

LLM과 데이터 기반 서비스

데이터 기반 서비스


SQL을 통한 데이터 추출



- 필요한 정보에 맞는 SQL 쿼리를 작성
- 이 쿼리를 통해 필요한 데이터를 가져와 가공하여 전달



API를 통한 DB 접근



- 작성해둔 쿼리에 주문번호만 채워서 보내는 함수 제작




챗봇을 통해 입력되는 요청

LLM과 데이터 기반 서비스


데이터 기반 서비스

SQL을 통한 데이터 추출




- 실제 요청은 자연어로 된 문장으로 접수됨
- 앞에서 ChatGPT를 통해 적절한 함수를 자동으로 호출하도록 제작

다양한 유형의 요청이 있다면 그만큼 함수를 제작해야 함





ChatGPT가 적절한 쿼리를 자동으로 생성






SQL을 이용한 챗봇의 장점

LLM과 데이터 기반 서비스

데이터 기반 서비스

SQL을 통한 데이터 추출



- 적절한 쿼리를 모델이 직접 작성하고 이를 이용해 필요한 정보를 가져옴
- 쿼리를 DB에 전달하여 데이터를 반환하는 하나의 함수만 필요



쿼리를 DB에 전달하여 데이터를 반환하는 함수

```
from session import conn

def query_db(query: str) -> list:
    try:
        with conn.cursor() as cursor:
            cursor.execute(query)

            # 열 이름을 가져옵니다.
            rows = cursor.fetchall()

            # 결과를 딕셔너리 형태로 변환합니다.
            columns = [col[0] for col in cursor.description]

            result = [dict(zip(columns, row)) for row in rows]
    except Exception as e:
        result = []
    finally:
        conn.close()
    return result
```


DB연결
(이번 과목에서는 생략)

쿼리 결과를 리스트로 반환

요청하려는 SQL 쿼리




이 함수를 통해 ChatGPT가 필요한 정보를 스스로 얻도록 설정



- DB에서 가져와야 하는 정보가 있다면 쿼리 함수를 통해 DB에서 정보를 가져옴
- 모든 유형에 대해 함수를 제작하지 않을 수 있음

DB에는 계정정보, 개인정보 같은 민감한 데이터도 저장됨




- 모든 테이블에 접근 가능 하다면 중요한 정보도 고객에게 넘어갈 수 있음
- 이 함수에서는 적절한 테이블만 사용할 수 있도록 권한을 설정하는 작업이 필요함


4. 웹 크롤링




실시간성 정보는 DB나 파일을 통해 처리하기 어려움




- 사람은 웹 페이지 검색을 통해 실시간 정보를 얻음



검색



페이지 선택



페이지의 내용 확인

1. 검색하면 다양한 페이지들의 목록이 제시됨
2. 원하는 페이지를 선택하고 페이지에 접속
3. 접속한 페이지의 내용을 확인하여 정보를 확인



시간 정보는 시스템 프롬프트에 입력

```
import time

system_prompt = """당신은 인공지능 챗봇입니다.

현재 시간: {current_time}

...
""".format(
    current_time=time.strftime("%Y-%m-%d %H:%M:%S", time.localtime())
)
```

원하는 형식의 문자열로 변환



웹 페이지에서 필요한 텍스트 정보를 가져오는 방법

이 문서에서 핵심 내용을 추출하여 텍스트로 변환

○○팀의 3연패, 팬들의 잘못은 없나?

8연패의 늪에 빠진 ○○팀, 팬들은 책임에서 자유로울 수 있을까?

24년 10월 21일, ○○팀은 AA팀과의 경기에서 19-2로 처참하게 패배하며 8연패의 수렁에 빠졌다. 이번 패배로 인해 팀은 이미 3년 연속 포스트시즌 진출에 실패했고, 팬들은 극도의 실망감을 감추지 못하고 있다. 하지만 일각에서는 팬들의 과도한 기대와 비판이 오히려 팀의 부진에 영향을 미치고 있다는 의견도 나오고 있다.

팀의 부진, 과연 누구의 책임인가?

사용자가 보는 페이지

```
<!DOCTYPE html>
<html lang="ko">
<head>
  <meta charset="UTF-8">
  <meta name="viewport" content="width=device-width, initial-scale=1.0">
  <title>○○팀의 3연패, 팬들의 잘못은 없나?</title>
  <style>
    body {
```

HTML 문서



URL에서 텍스트를 추출하는 함수

```
def extract_text(url: str) -> str:
    try:
        headers = {"User-Agent": "Mozilla/5.0"}
        response = requests.get(url, headers=headers, timeout=10)
        response.raise_for_status()
        soup = BeautifulSoup(response.content, "html.parser")
        text = soup.get_text(separator="\n", strip=True)
        return text

    except Exception as e:
        print(f"Error scraping {url}: {e}")
        return ""
```

url을 요청

HTML 해석용 도구

HTML내의 텍스트를 추출



필요한 정보를 담은 페이지 주소를 통해 답변하는 과정

○○팀의 8연패, 팬들의 잘못은 없나? (C 뉴스)

URL 전달

```
def extract_text(url: str) -> str:
```

○○팀의 3연패, 팬들의 잘못은 없나? 8연패의 늪에 빠진 ○○팀, 팬들은 책임에서 자유로울 수 있을까? 24년 10월 21일, ○○팀은 AA팀과의 경기에서 19-2로 처참하게 패배하며 8연패의 수렁에 빠졌다. 이번 패배로 인해 팀은 이미 3년 연속 포스트시즌 진출에 실패했고, 팬들은 극도의 실망감을 감추지 못하고 있다. 하지만 일각에서는 팬들의 과도한 기대와 비판이 오히려 팀의 부진에 영향을 미치고 있다는 의견도 나오고 있다. 팀의 부진, 과연 누구의 책임인가? ○○팀의 연패 원인으로서는 감독의 전략 부재, 주전 선수들의 부상, 경기 중 잦은 실책 등이 주로 거론된다. 하지만 이러한 원인 외에도 팬들의 지나친 압박이 선수들에게 심리적 부담을 주고 있다는 주장도 있다.

어제 ○○팀은 AA팀과의 경기에서 19-2로 패배했습니다.



사용자에게 응답

ChatGPT

텍스트로 추출된 페이지 내용



```
def google_search(query: str, num_results=10) -> list:
    "Google 검색 결과에서 상위 URL을 가져오는 함수"
    try:
        urls = [url for url in search(query, num_results=num_results)]
        return urls[:num_results]
    except Exception as e:
        print(f"Error during Google search: {e}")
        return []
```

웹에 검색하고 싶은 검색어

검색 결과 발견한 URL들 반환



열어볼 페이지들을 검색하는 역할

```
def google_search(query: str, num_results=10) -> list:  
    "Google 검색 결과에서 상위 URL을 가져오는 함수"
```



경기 결과 내용 (A 기록실)

최신 경기 결과 (□□ 공식)

○○팀의 8연패, 팬들의 잘못은 없나? (C 뉴스)

키워드 검색

페이지 선택



```
def search_web(query: str) -> List[str]:  
    """인터넷에서 query를 검색하고 상위 4개 페이지의 텍스트를 모아서 반환하는 함수  
  
    Args:  
        query (str): 웹에 검색할 문자열. 관련 정보를 웹에서 찾기 위해 검색할 적절한  
            검색어로 설정해야 함.  
  
    Returns:  
        list: 상위 4개 페이지의 텍스트 리스트  
    """  
    urls = google_search(query)  
    text_list = []  
  
    count = 0  
  
    for url in urls:  
        page_text = extract_text(url)  
        if page_text:  
            page_text = post_process(page_text)  
            page_text = f"{count + 1}. {url}:\n{page_text}\n"  
            text_list.append(page_text)  
            count += 1  
  
        if count >= 4:  
            break  
    return text_list
```

ChatGPT가 선정한 검색어

검색 후 상위 페이지들 url 추출


각 페이지의 텍스트 추출

추출된 텍스트 후처리

하나의 문자열로 이어붙여 반환




다양한 방법으로 정보를 가져와 응답에 사용



데이터 베이스



파일



웹 페이지

- 각각에 맞는 함수를 작성하고 ChatGPT에게 전달하여 알아서 활용하도록 제작
- 이 외에도 많은 소스에 대한 함수를 제작하면 정확한 챗봇을 제작할 수 있음
- 또한 원하는 기능의 함수를 구현하고 이를 사용하여 챗봇에게 제공할 수 있음