

●●● ML API 사용 매뉴얼

[동남권] 2026 ICT이노베이션스퀘어 - 온라인 코딩원



사용 API

GPT-4o mini



⚡ Serverless

OpenAI

GPT-4o mini

빠르고 경제적인 소형 모델로, 특정 작업에 집중하여 최고의 효율을 이끌어냅니다.

₩249/1M input · ₩993/1M output


Text Generation

GPT-4o-mini

텍스트 생성·대화형 AI

- 챗봇 구축
- 질의응답(Q&A)
- 문서 요약
- 보고서 작성
- 코드 생성 및 분석

Text Embedding 3 Small



⚡ Serverless

OpenAI

Text Embedding 3 Small

높은 효율성과 강력한 성능의 조화, 비용 효율적인 임베딩 작업을 위한 새로운 표준을 경험하세요.

₩32/1M input · ₩0/1M output

Text Generation

Text Embedding 3 Small

문서 검색·RAG용

- PDF 검색 챗봇
- 벡터DB 구축
- 문서 유사도 검색

GPT API 사용 시점


- AI와 대화하거나 답변을 생성할 때 사용
- **ChatOpenAI()** 코드가 있으면 LLM API 설정 필요
- 문서 요약, 질의응답, 번역, 분석 등의 작업 수행

Embedding API 사용 시점

- 문서를 검색 가능한 형태로 변환할 때 사용
- **OpenAIEmbeddings()** 코드가 있으면 임베딩 API 설정 필요
- 문서 검색(RAG) 기능 수행

1. 엘리스 클라우드 접속

좌측 상단 LXP 드롭다운 메뉴 클릭 → 엘리스 클라우드 접속



2. 사용 모델 선택

좌측의 '모델 라이브러리' 클릭 → 모델 검색 후 선택
(본 실습에서는 해당 모델만 사용 가능합니다)

***좌측의 추천 모델 체크박스를 해제 후 검색해 주세요**

The screenshot shows the '모델 라이브러리' (Model Library) page in the AI Cloud console. The interface includes a left sidebar with navigation links: 홈 (Home), 런박스 (Runbox), 인스턴스 (Instances), 비밀키 관리 (Secret Key Management), ML API, and API 키 관리 (API Key Management). The main content area is titled '모델 라이브러리' and features a search bar with the text 'gpt-4o mini'. Below the search bar, there are two model cards: 'GPT-4o mini' and 'Text Embedding 3 Small'. Both cards are highlighted with red boxes and have a hand icon pointing to them, indicating they are the models to be selected. A purple circle with the text 'OR' is placed between the two model cards. The search bar and the '추천 모델' (Recommended Model) checkbox are also highlighted with red boxes. The '추천 모델' checkbox is currently checked, and a hand icon is pointing to it, indicating it should be unchecked. The 'GPT-4o mini' card shows details such as 'Serverless', 'OpenAI', '빠르고 경제적인 소형 모델로, 특정 작업에 집중하여 최고의 효율을 이끌어냅니다.', and 'W249/1M input · W993/1M output'. The 'Text Embedding 3 Small' card shows details such as 'Serverless', 'OpenAI', '높은 효율성과 강력한 성능의 조화, 비용 효율적인 임베딩 작업을 위한 새로운 표준을 경험하세요.', and 'W32/1M input · W0/1M output'. The interface also includes a filter button, a '모형 확인하기' (Check Model) button, and a '모형 등록' (Register Model) button.

2026 동남권 ICT 이노베이션스퀘어 AI Cloud

홈
런박스
인스턴스
비밀키 관리
ML API

모델 라이브러리

추천 모델

필터

gpt-4o mini

전체 공개 모델 기관 공개 모델 + 모형 등록

모델 사용 방식

- ☐ Serverless 배포 없이 호출한 만큼 과금
- ☐ Dedicated 원하는 자원으로 직접 배포

자연어 처리

- ☐ Text Generation
- ☐ Text Classification

컴퓨터 비전

- ☐ Image Generation
- ☐ Object Detection
- ☐ Face Detection

도움이 필요하신가요?
AI클라우드 매뉴얼 바로가기 →

GPT-4o mini

Serverless

OpenAI

GPT-4o mini

빠르고 경제적인 소형 모델로, 특정 작업에 집중하여 최고의 효율을 이끌어냅니다.

W249/1M input · W993/1M output

Text Generation

OR

Text Embedding 3 Small

Serverless

OpenAI

Text Embedding 3 Small

높은 효율성과 강력한 성능의 조화, 비용 효율적인 임베딩 작업을 위한 새로운 표준을 경험하세요.

W32/1M input · W0/1M output

Text Generation

3. 엔드포인트 발급

우측 **모델 사용하기** 메뉴 선택 → **Serverless** 선택

2026 동남권 ICT 이노베이션스퀘어

AI Cloud

₩28,754

홈

런박스

인스턴스

비밀키 관리

ML API

모델 라이브러리

Dedicated 엔드포인트

Serverless 이용 현황

API 키 관리

결제 관리

크레딧

이용내역

도움이 필요하신가요?
AI클라우드 매뉴얼 바로가기

모델 라이브러리 / GPT-4o mini

GPT-4o mini

Text Generation Serverless

모델 정보 버전 정보 API

상세 정보

GPT-4o mini

GPT-4o mini

개요

이 API 서비스는 OpenAI /v1/chat/completions API를 미러링하는 프록시 엔드포인트를 제공하여, 기존 OpenAI 호환 애플리케이션과의 원활한 통합을 가능하게 하면서 사용자 정의 라우팅, 속도 제한, 캐싱 또는 비용 최적화와 같은 추가 기능을 제공할 수 있습니다.

GPT-4o mini는 2024년 7월 18일에 출시된 OpenAI의 가장 비용 효율적이고 소형인 모델로, 빠른 응답 속도가 필요한 애플리케이션, 대규모 데이터 처리 및 비용 절감이 중요한 작업에 최적화되어 있습니다. GPT-3.5 Turbo를 대체하며 더 뛰어난 지능과 멀티모달 기능을 제공합니다.

모델 사용하기

Serverless
배포 없이 호출한 만큼 과금됩니다. (VAT 별도)
₩249/1M input • ₩993/1M output

모델 정보

모델 제공자

OpenAI

모델 종류

Text Generation

사용방식 및 요금

Serverless ₩249/1M input tokens
₩993/1M output tokens

Dedicated

모델 ID

openai/gpt-4o-mini

API Rate Limit

무제한

3. 엔드포인트 발급

큰 따옴표 내부의 주소를 복사합니다.

2026 동남권 ICT 이노베이션스퀘어

AI Cloud

크레딧 W28,819

홈

런박스

인스턴스

비밀키 관리

ML API

모델 라이브러리

Dedicated 엔드포인트

Serverless 이용 현황

API 키 관리

결제 관리

크레딧

이용내역

도움이 필요하신가요?
AI클라우드 매뉴얼 바로가기

모델 라이브러리 / GPT-4o mini

GPT-4o mini

Text Generation Serverless

모델 사용하기

모델 정보

버전 정보

API

API 예시 코드

API 스펙

API 키 발급

1. API 키 발급 후 {API_KEY} 환경 변수에 저장합니다.

2. 아래 코드를 사용해 애플리케이션에서 모델, 파라미터, 지금까지의 대화를 계속 다루세요.

Python

TypeScript

cURL

```
1 import requests
2
3 url = "https://mlapi.run/40cc17ae-a89b-4f12-a7d6-13293180fc87"
4 payload = {"messages": [{"role": "user", "content": "안녕하세요"}]}
5 headers = {
6     "accept": "application/json",
7     "content-type": "application/json",
8     "Authorization": "Bearer {API_KEY}"
9 }
10
11 response = requests.post(url, json=payload, headers=headers)
```


복사하기

4. 엔드포인트 입력 (GPT-4o-mini)

실습 환경의 base_url 변수에 복사한 호출 정보를 입력합니다.
(실습별로 입력 입력 위치가 다를 수 있습니다. 변수명을 확인해주세요.)

***맨 뒤에 '/v1' 을 함께 입력해주세요**

***다음표 내부에 입력해주세요**



01 LangChain > [실습3] LangChain을 활용한 챗봇 구현

[실습3] LangChain을 활용한 챗봇 구현

실습

LangChain을 활용한 챗봇 구현

이번 실습에서는 다음 내용들을 구현하며 알아보겠습니다 :

- LangChain의 기능을 활용하여 문서를 바탕으로 질의응답이 가능한 봇을 만듭니다.
- 챗봇 개발의 기본 개념과 LangChain의 주요 기능을 학습합니다.

학습 방법

1. 파일 목록에 업로드 되어 있는 LangChain을

RunBox jupyter LangChain을 활용한 챗봇 구현 (autosaved)

```
In [ ]: from langchain_openai import ChatOpenAI
import os

if "OPENAI_API_KEY" not in os.environ:
    os.environ["OPENAI_API_KEY"] = "키를 입력해주세요"

In [ ]: ...
# 1. OpenAI 웹사이트에서 발급받은 키 사용시
llm = ChatOpenAI(model="gpt-4o")
...

# 2. Elice AI Cloud에서 발급받은 키 사용시
llm = ChatOpenAI(
    model="openai/gpt-4o-mini",
    base_url="MLAPI_URL" # (입력 필요) 예: "https://mlapi.run/.../v1"
```

LangChain을 활용한 챗봇 구현

1. Retrieval augmented generation

- 문서를 바탕으로 질의 응답을 할 수 있는 봇을 만듭니다.

2. 대화 히스토리를 고려한 RAG 채팅


CPU 0.03% MEM 643.81 MiB/8 GiB UP 0 B/s DOWN 0 B/s DISK 699.07 MiB/49.98 GiB

< 이전 13 / 13 다음 수업 >

4. 엔드포인트 입력 (Text Embedding 3 Small)

`OpenAIEmbeddings()` 내에 임베딩 모델명과 엔드포인트를 입력합니다.

```
vectorstore = Chroma.from_documents(document_s=split_s, embedding=OpenAIEmbeddings())  
retriever = vectorstore.as_retriever()
```



```
vectorstore = Chroma.from_documents(document_s=split_s, embedding = OpenAIEmbeddings(  
    model="text-embedding-3-small",  
    base_url="복사한 주소 + /v1 "  
))  
retriever = vectorstore.as_retriever()
```

*모델명 : text-embedding-3-small

*url 뒤 /v1을 꼭 입력해주세요!

*따옴표 내부에 입력해주세요

5.API 키 발급

API 키 발급 선택

2026 동남권 ICT 이노베이션스퀘어

AI Cloud

크레딧 ₩28,819

홈

런박스

인스턴스

비밀키 관리

ML API

모델 라이브러리

Dedicated 엔드포인트

Serverless 이용 현황

API 키 관리

결제 관리

크레딧

이용내역

도움이 필요하신가요?
AI클라우드 메뉴얼 바로가기

모델 라이브러리 / GPT-4o mini

GPT-4o mini

Text Generation Serverless

모델 사용하기

모델 정보

버전 정보

API

API 예시 코드

API 스펙

1. API 키 발급 후 {API_KEY} 환경 변수에 저장합니다.

2. 아래 코드를 사용해 애플리케이션에서 모델, 파라미터, 지금까지의 대화를 계속 다루세요.

Python

TypeScript

cURL

1 import requests

2

3 url = "https://mlapi.run/40cc17ae-a89b-4f12-a7d6-13293180fc87"

4 payload = {PAYLOAD}

5 headers = {

6 "accept": "application/json",

7 "content-type": "application/json",

8 "Authorization": "Bearer {API_KEY}"

9 }

10

11 response = requests.post(url, json=payload, headers=headers)


복사하기

Serverless 키 발급 선택



5.API 키 발급

키 이름과 만료일을 설정하세요
(만료일은 2026-12-31로 설정 부탁드립니다.)



5.API 키 발급

API 키가 발급되었습니다.
복사 후 안전한 곳에 기록해주세요
(보안을 위해 다시 확인할 수 없습니다.)

2026 동남권 ICT 이노베이션스퀘어

AI Cloud

크레딧 ₩28,765

홈

런박스

인스턴스

비밀키 관리

ML API

모델 라이브러리

Dedicated 엔드포인트

Serverless 이용 현황

API 키 관리

결제 관리

크레딧

이용내역

API 키 관리

ServerlessDedicated

키 이름을 검색하세요.

키 이름을 입력하세요

API 키 이름

API TEST

API Key Test

AI Custom Agent

AI Helpy

+ Serverless 키 발급

	생성자	관리
-01 23:59:59	조민준	
6-25 23:59:59	조민준	
	Meenwoo Seo	
	주윤서	

Serverless API 키 발급 확인

Serverless 키가 발급되었습니다. 보안을 위해 다시 확인할 수 없으니 키를 안전한 곳에 보관해 주세요. 키를 잃어버린 경우 재발급해야 합니다.

복사하기

닫기


Serverless 키가 발급되었습니다.

6.API 키 입력(GPT-4o-mini)

실습 환경의 API KEY 변수에 복사한 API 키를 입력합니다.

(실습별로 입력 위치가 다를 수 있습니다. 변수명을 확인해주세요.)

반드시 “내부에 입력해주세요”



The screenshot shows a RunBox JupyterLab interface. On the left, a sidebar contains a '실습' (Lab) section with a play button icon and the title 'LangChain을 활용한 챗봇 구현'. Below this, it lists the goals of the lab: implementing a chatbot using LangChain's features and learning basic chatbot development concepts. The main area displays a JupyterLab notebook titled 'LangChain을 활용한 챗봇 구현 (autosaved)'. The code cell shows the following Python code:

```
In [ ]: from langchain_openai import ChatOpenAI
import os

if "OPENAI_API_KEY" not in os.environ:
    os.environ["OPENAI_API_KEY"] = "키를 입력해주세요"

# 1. OpenAI 웹사이트에서 발급받은 키 사용시
llm = ChatOpenAI(model="gpt-4o")


# 2. Elice AI Cloud에서 발급받은 키 사용시
llm = ChatOpenAI(
    model="openai/gpt-4o-mini",
    base_url="MLAPI_URL" # (입력 필요) 예: "https://mlapi.run/.../v1"
)
```

A red box highlights the line `os.environ["OPENAI_API_KEY"] = "키를 입력해주세요"`, with a hand icon pointing to it. The bottom status bar shows system metrics: CPU 0.03%, MEM 643.81 MiB/8 GiB, UP 0 B/s, DOWN 0 B/s, and DISK 699.07 MiB/49.98 GiB. Navigation buttons at the bottom include '< 이전', '13 / 13', and '다음 수업 >'.

6.API 키 입력(Text Embedding 3 Small)

OpenAIEmbeddings() 내에 API 키를 추가합니다.

```
vectorstore = Chroma.from_documents(documents=splits, embedding = OpenAIEmbeddings(  
    model="text-embedding-3-small",  
    base_url="복사한 주소 + /v1 "  
))  
  
retriever = vectorstore.as_retriever()
```



```
vectorstore = Chroma.from_documents(documents=splits, embedding = OpenAIEmbeddings(  
    model="text-embedding-3-small",  
    base_url="복사한 주소 + /v1 ",  
    api_key="API 키를 입력하세요"  
))  
  
retriever = vectorstore.as_retriever()
```

*다음표 내부에 입력해주세요

실습을 시작하세요

/* elice */