


Motivation: 평가는 왜 필요한가

RAG 복습: 검색으로 근거를 붙인 생성




- RAG는 질문과 관련된 문서를 먼저 검색해 근거로 붙인 뒤 답을 생성하는 구조이다. 모델이 학습하지 못한 사내 문서·최신 정보를 답변에 반영할 수 있다.
- 근거가 답과 함께 제시되므로 환각을 줄이고 출처 확인이 가능해진다. 모델 재학습 없이 문서만 갱신하면 되어 유지 비용도 낮다.



RAG 파이프라인 6단계

문서 로드부터 생성까지 여섯 단계 각각의 품질이 최종 답변의 품질에 영향을 준다.



앞 4단계(인덱싱)는 배포 전에, 뒤 2단계(검색·생성)는 요청마다 실행된다.
각 단계가 실제로 무엇을 하는지부터 확인한다.



RAG 시스템에서 자주 발생하는 문제

KEY 01

검색 품질 저하

- 질문과 무관한 문서가 검색되어
답의 근거부터 잘못된다. 문서
증가·도메인 어휘가 주원인이다.

KEY 02

응답 일관성 부족

- 같은 질문에도 답이 매번
달라지고, 근거 없는 내용(환각)이
섞인다. 사용자 신뢰를 잃는
원인이다.

KEY 03

비용 증가

- 컨텍스트가 길어질수록 토큰 비용과
지연이 함께 늘어난다. 품질과
비용의 균형이 필요하다.

세 문제 모두 감각이 아니라 측정으로만 개선할 수 있다.
따라서 평가와 모니터링이 필요하다.



평가 없이 개선했을 때: 품질 회귀

발견된 오답 하나만 수정하는 방식은 다른 질문의 답변 품질을 떨어뜨릴 수 있다.

질문 A를 수정한다	질문 B가 악화된다	회귀 (regression)
조치 프롬프트에 지시를 추가하고 Top-K를 늘린다 질문 A는 정상 답변으로 바뀐다 확인한 범위 질문 A	부작용 무관한 청크가 함께 들어와 답이 흐려진다 제보가 없으면 악화된 것을 알 수 없다 확인한 범위 없음	정의 이전에 되던 질문이 개선안에서 실패하는 것 고정 평가셋이 있으면 개선과 함께 드러난다 필요한 것 기준선 고정 평가셋

개선의 근거는 수정한 질문 하나가 아니라, 같은 문항 집합에서 점수가 올라간 문항과 떨어진 문항을 함께 확인한 결과이다.



평가와 모니터링의 구분

배포 전에는 고정 평가셋으로 시험하고, 배포 후에는 실사용 트래픽을 관찰한다.



평가는 배포 전 시험이고 모니터링은 배포 후 관찰이다. 어느 한쪽이 다른 쪽을 대체할 수 없으며, 두 활동은 하나의 개선 루프를 이룬다.



//

측정하지 않으면 개선 여부를 확인하기 어렵다

//

감각에 의존해 조치하면 같은 실패가 반복되고, 지표를 기준으로 조치하면 무엇이 좋아지고 무엇이 나빠졌는지 드러난다.

Challenges: 평가는 왜 어려운가



평가의 세 단계: R·A·G

하나의 응답은 세 단계를 거쳐 만들어진다. 세 단계는 측정 대상이 달라 지표도 다르다.



종합 점수 하나만 보면 점수가 떨어졌을 때 어느 단계를 조정해야 하는지 알기 어렵다.




단계 결합과 성능 상한

각 단계가 직렬로 이어져, 앞 단계의 성능이 뒤 단계의 상한으로 작용한다.



단계 성공률이 곱해질 때



최종 답만 보면 어느 단계의 잘못인지 알 수 없다. 단계별 지표가 있어야 실패 위치를 특정할 수 있다.

Component 평가

- 검색과 생성 각 단계의 출력을 단계별로 채점한다.
어느 단계에서 실패했는지 특정할 수 있다.
- 수정할 단계를 정하는 근거가 된다.

End-to-End 평가

- 최종 답변만 보고 사용자 기준으로 채점한다.
사용자가 겪는 품질에 가장 가깝다.
- 배포 가능 여부를 판정하는 근거가 된다.

두 평가는 역할이 다르므로 함께 수행한다.
End-to-End 평가로 배포해도 되는 품질인지 판정하고, Component 평가로
실패한 단계를 찾는다.



실패의 세 유형

실패는 세 유형으로 나뉘며, 유형에 따라 수정할 위치가 다르다.

검색 실패	생성 실패	컨텍스트 활용 실패
증상 질문과 관련된 근거가 컨텍스트에 아예 없다 근거가 없으면 생성 단계에서 보완할 수 없다 처방 인덱싱 검색	증상 근거는 컨텍스트에 있는데 답이 틀린다 근거는 확보됐지만 생성 단계에서 틀린 경우이다 처방 프롬프트 모델	증상 근거가 있는데도 모른다고 답하거나 무시한다 근거가 컨텍스트 안에서 드러나지 않아 활용되지 못한 경우이다 처방 청킹 컨텍스트 구성 재순위

실패 유형을 먼저 분류해야 인덱싱·프롬프트·청킹 가운데 어디를 수정할지 정할 수 있다.

지표는 단계별로 다르고, 정답지가 필요한지도 지표마다 다르다.

단계	대표 지표	정답지 필요 여부	다루는 챕터와 도구
검색 성능	Recall@K · Precision@K · MRR · NDCG@K	정답 근거 라벨이 필요하다	「Retrieval Metrics」 · 지표 함수 직접 구현
답변 성능	Faithfulness · Answer Relevancy · Answer Correctness	Faithfulness와 Answer Relevancy는 정답지 없이 계산할 수 있고, Answer Correctness는 정답지가 필요하다	「LLM-as-a-Judge」 · 「RAGAS」
시스템 성능	요청당 비용 · p95 지연(상위 5% 응답 시간) · 처리량(초당 요청 수)	평가셋과 무관하게 실행 기록에서 산출된다	「비용·토큰」 · 「Latency·QPS」

지표 이름보다 단계와 지표의 대응을 기억한다. 어느 단계를 측정하는지와 정답지 필요 여부가 선택의 기준이 된다.

01

정량 지표

감각이 아니라 수치로
판단한다. 단계별 지표(Recall,
Faithfulness 등)로 어디에서
문제가 생겼는지 확인한다.

02

평가 파이프라인

같은 평가셋과 채점 기준으로
반복 실행할 수 있는 절차를
만든다. 채점 단계는 LLM
Judge와 RAGAS가
담당한다.

03

운영 루프

평가 → A/B 비교 → 릴리즈
게이트 → 회귀 탐지로
이어지는 루프를 만들어
운영한다.

정량 지표가 평가 파이프라인과 운영 루프의 기초가 된다.